

# Aprendizagem Adaptativa *versus* Robustez Estática: Comparação de Aprendizagem por Reforço e Neuroevolução para Controlo de Enxames

Gonçalo Pombo<sup>a</sup>, Luís Nunes<sup>a</sup>

<sup>a</sup>Instituto Universitário de Lisboa (ISCTE-IUL), ISTAR, Lisboa, Portugal

## Abstract

O controlo de enxames robóticos é abordado por duas comunidades que raramente se encontram num referencial comum: a aprendizagem por reforço multiagente (MARL), que promete adaptabilidade *em linha*, e a otimização bio-inspirada, que oferece robustez pré-programada. Este trabalho apresenta uma comparação controlada e independente do paradigma entre três controladores — uma rede de grafo neuroevoluída com atenção sobre os vizinhos, *Proximal Policy Optimisation* (PPO) e *Soft Actor-Critic* (SAC) — no mesmo simulador tridimensional de *foraging* de alta fidelidade, com seis cenários de dificuldade crescente, sob avaliação determinística e testes estatísticos. Na realização da tarefa, os métodos de gradiente dominam: o SAC resolve os seis cenários e o PPO cinco em seis, falhando o Muro em U por *exploração da recompensa* (*reward hacking*), ao passo que o controlador evolutivo colapsa nos cenários com estrangulamentos. O quadro inverte-se sob escalabilidade *zero-shot*: apenas o controlador baseado em atenção transita de  $N = 10$  para  $N = 100$  agentes sem retreino, uma vez que as políticas de dimensão fixa do PPO/SAC são estruturalmente incompatíveis com  $N \neq 20$ . A hipótese de que a inteligência adaptativa domina a robustez estática é, por isso, apenas *parcialmente* confirmada, revelando um compromisso central entre o desempenho na tarefa a um tamanho de enxame fixo e a escalabilidade para tamanhos nunca vistos.

**Keywords:** robótica de enxames, aprendizagem por reforço multiagente, neuroevolução, escalabilidade zero-shot, redes neuronais de grafos, avaliação comparativa

## 1. Introdução

Os enxames robóticos prometem soluções escaláveis e resilientes para tarefas como busca e salvamento, monitorização ambiental e logística distribuída. A questão central de engenharia é qual o paradigma de controlo que melhor mantém a operacionalidade sob incerteza. Duas escolas dominam. A *otimização bio-inspirada* (por exemplo, algoritmos evolutivos e otimização por enxame de partículas) procura num espaço global de parâmetros, *fora de linha*, controladores robustos e estáticos (Kennedy and Eberhart, 1995). A *aprendizagem por reforço multiagente* (MARL) aprende, em alternativa, políticas adaptativas *em linha* através da interação (Huh and Mohapatra, 2023). Apesar do extenso trabalho em cada uma, as comparações diretas e rigorosas entre paradigmas permanecem escassas (Majid et al., 2024; Bettini et al., 2024): os estudos costumam refinar um único algoritmo contra variantes da sua própria família, descurando as referências cruzadas entre paradigmas.

Controlar um enxame é difícil por três razões que se reforçam. O espaço de ações conjuntas cresce exponencialmente com o número de agentes, tornando inviável tratar o enxame como um único agente monolítico; a recompensa de tarefa é tipicamente esparsa e diferida, o que agrava a atribuição de crédito; e cada agente decide a partir de uma observação parcial e local, sem acesso ao estado global. Os dois paradigmas respondem a estas dificuldades de formas opostas — a MARL aprende

uma política partilhada que generaliza por experiência, a otimização bio-inspirada procura um controlador robusto num só esforço de otimização — e é precisamente essa oposição que motiva uma comparação direta e controlada.

A questão de investigação que orienta a dissertação é, em rigor, se a *inteligência adaptativa* (uma política de MARL que aprende com a experiência) supera a *robustez estática* (um controlador otimizado de uma só vez e depois congelado) em cenários de *stress* dinâmico. Responder a esta questão exige um referencial em que ambos os paradigmas sejam avaliados nas mesmas condições, com as mesmas métricas e a mesma análise estatística — algo que a literatura raramente oferece.

Este artigo aborda essa lacuna com uma avaliação comparativa imparcial. Implementámos um simulador tridimensional de *foraging* de alta fidelidade e avaliamos três controladores — uma rede de grafo neuroevoluída com auto-atenção sobre os vizinhos, PPO e SAC — em seis cenários, ao longo de três eixos: desempenho na tarefa ( $P_{\text{task}}$ ), robustez a falhas de agentes ( $R_{\text{robust}}$ ) e escalabilidade *zero-shot* ( $S_{\text{scale}}$ ), todos suportados por testes de significância não paramétricos. A nossa contribuição é dupla: (i) um protocolo de avaliação reproduzível e independente do paradigma; e (ii) a evidência de um compromisso central, em que os métodos de gradiente vencem na realização da tarefa a um tamanho de enxame fixo, enquanto apenas o controlador baseado em grafo escala para tamanhos de enxame nunca vistos. A metodologia e os resultados completos são detalhados na dissertação que acompanha este artigo.

## 2. Trabalho Relacionado

A aprendizagem por reforço profunda tem sido aplicada a sistemas de enxame com partilha de parâmetros para domar a explosão do espaço de ações conjuntas (Hüttenrauch et al., 2019), em que uma única rede é partilhada por todos os agentes homogêneos. As redes neuronais de grafos (GNN) emergiram como o principal viabilizador da escalabilidade: ao modelar o enxame como um grafo e ao aplicar atenção sobre os vizinhos, uma política treinada com poucos agentes pode ser implantada com muitos (Chen et al., 2024). O mecanismo de atenção (Vaswani et al., 2017; Veličković et al., 2018) é central nesta propriedade, por ser invariante à permutação e à cardinalidade do conjunto de vizinhos. Os controlos de enxames baseados em grafos têm-se multiplicado, com aplicações que vão da estimação distribuída em redes dinâmicas (Chen et al., 2024) ao controlo descentralizado de formação (Schmickl et al., 2025; Elrod et al., 2025), e revisões recentes consolidam a GNN como o substrato dominante para a escalabilidade em enxames (Ekechi et al., 2025).

No paradigma de aprendizagem, o esquema de treino centralizado com execução descentralizada (CTDE) tornou-se padrão para domar a não-estacionariedade do ambiente multiagente (Lowe et al., 2017; Oliehoek and Amato, 2016). No presente trabalho, contudo, os *baselines* de gradiente partilham uma única política e executam a partir da observação puramente local, sem um crítico de estado global, o que mantém a comparação ancorada num regime descentralizado comum aos três controladores.

Do lado bio-inspirado, a neuroevolução otimiza os pesos da rede sem gradientes (Salimans et al., 2017), oferecendo controladores estáveis para tarefas estáticas, mas com adaptabilidade *em linha* limitada (Kegeleirs and Birattari, 2025). As estratégias de evolução são atrativas pela simplicidade e pela paralelização trivial, mas otimizam a partir de um único escalar de aptidão por episódio, sem atribuição de crédito temporal — uma distinção que se revelará decisiva nos resultados.

Os estudos comparativos entre aprendizagem por reforço profunda e estratégias de evolução salientam a ausência de uma referência de desempenho comum entre as duas famílias (Majid et al., 2024), enquanto os referenciais padronizados de MARL permanecem focados dentro da comunidade de aprendizagem (Bettini et al., 2024). As aplicações de aprendizagem por reforço profunda à navegação de enxames (Iskandar et al., 2023) ilustram o tipo de estudo de paradigma único que este trabalho estende, com uma comparação sistemática e estatisticamente fundamentada contra a alternativa bio-inspirada.

## 3. Metodologia

### 3.1. Ambiente de simulação

O ambiente é uma tarefa de *foraging* contínua e tridimensional, numa arena circular (raio 15 m) com  $N = 20$  agentes homogêneos que devem recolher comida e transportá-la para um ninho. Utilizam-se seis cenários de dificuldade crescente: um *Sandbox* aberto; três labirintos de navegação (*Muro em U*,

*Gargalo*, *Quatro Salas*); e duas tarefas cooperativas (*Porta Cooperativa*, que exige  $\geq 3$  agentes para abrir uma passagem, e *Perceção Cooperativa*, com um alvo móvel). A Figura 1 ilustra os seis cenários. Cada agente observa uma bússola de *homing* egocêntrica para o ninho, oito raios LiDAR para deteção local de obstáculos e o estado relativo dos vizinhos — um cenário parcialmente observável, formalizável como um Dec-POMDP (Oliehoek and Amato, 2016). A bússola fornece a direção e a distância euclidiana ao ninho de forma sempre disponível (à imagem do *homing* global em formigas ou da navegação por GPS), ao passo que os obstáculos só são percebidos localmente pelo LiDAR de 5 m, preservando uma observabilidade parcial genuína.

Para evitar mínimos locais nos cenários de labirinto, a recompensa de progresso usa um potencial *geodésico* calculado pelo algoritmo de Dijkstra sobre uma grelha de ocupação dilatada, atuando como modelação de recompensa baseada em potencial (Ng et al., 1999) que não altera a política ótima e é usada apenas como sinal de treino, nunca como observação. A Figura 2 contrasta o potencial euclidiano ingênuo — que “atravessa” a parede e cria um mínimo local que cola os agentes ao obstáculo — com o campo geodésico, cujo gradiente premeia corretamente o contorno da barra.

### 3.2. Espaço de observação, de ação e recompensa

A observação de cada agente é um vetor egocêntrico que reúne a bússola de *homing* (direção e distância ao ninho), os oito raios LiDAR e o estado relativo dos  $N - 1$  vizinhos; manter o vizinho como uma entidade explícita é o que permite à GNN atender sobre um conjunto de cardinalidade variável. O espaço de ação é discreto e egocêntrico: três translações (frente/recuo, esquerda/direita, cima/baixo) de passo fixo 0.2 m, resolvidas por uma ordem determinística de *step* que aplica deslizamento ao longo das paredes (*wall-sliding*) em caso de colisão, evitando que o agente fique imobilizado num canto.

A recompensa combina seis termos: (i) uma recompensa esparsa pela entrega de comida no ninho, que domina; (ii) o progresso geodésico descrito acima (Ng et al., 1999); (iii) um bônus de exploração baseado em contagem, que premeia a visita a novas células e complementa o progresso onde este é plano; (iv) uma penalização de dispersão que desencoraja a aglomeração em “bola”, isenta nas zonas de cooperação para não sabotar a abertura da porta; (v) um custo energético por passo, que impõe pressão temporal; e (vi) a separação física inter-agente. A aptidão evolutiva da Equação 1 é, deliberadamente, distinta desta recompensa: prioriza a comida recolhida e usa o termo modelado apenas como desempate, ao passo que o PPO/SAC otimizam a recompensa densa completa.

### 3.3. Controladores

O *controlador evolutivo* (GNN) é uma rede compacta que codifica as características egocêntricas e aplica auto-atenção de produto escalar normalizado sobre o conjunto de vizinhos (Vaswani et al., 2017), produzindo uma ação invariante ao número de vizinhos. Os seus pesos são otimizados por uma estratégia de evolução  $(1+\lambda)$  (população 30, truncatura com eli-



Figura 1: Os seis cenários de avaliação, renderizados a partir da geometria real do simulador. Em cima: Sandbox (aberto, com obstáculos esféricos), Muro em U e Gargalo. Em baixo: Quatro Salas, Porta Cooperativa (passagem a âmbur, abre com  $\geq 3$  agentes) e Percepção Cooperativa (alvo móvel). O ninho é a esfera verde.




Figura 2: Potencial de recompensa no Muro em U: a distância euclidiana (esquerda) atravessa a parede e induz um mínimo local; o campo geodésico (direita), calculado por Dijkstra sobre a grelha com obstáculos dilatados, premeia o contorno e elimina a armadilha. É um sinal de treino, não uma observação.

tismo, mutação gaussiana), com uma aptidão que prioriza a tarefa,

$$J = \bar{f} \cdot 10^4 + 5000 \tanh(\bar{R}/5000), \quad (1)$$

onde  $\bar{f}$  é a média de comida recolhida e  $\bar{R}$  a média da recompensa modelada; o termo  $\tanh$  evita a saturação que, de outro modo, tornaria a seleção cega (o termo de modelação satura num teto constante e a aptidão deixa de discriminar genomas). Os *baselines de aprendizagem* são o PPO (Schulman et al., 2017) e o SAC (Haarnoja et al., 2018) da biblioteca Stable-Baselines3, com uma política de percepção multicamada partilhada ([256, 256]) sobre a observação densa da vizinhança (partilha de parâmetros). O mecanismo de atenção sobre o grafo

é, assim, instanciado apenas no controlador evolutivo, o que é precisamente o que viabiliza a sua transferência *zero-shot*. O PPO usa estimação de vantagem generalizada (Schulman et al., 2016) e o SAC, fora de política, regulariza por entropia; ambos são treinados sobre ambientes vetorizados em paralelo (*SubprocVecEnv*), com a mesma política a recolher experiência de todos os agentes do enxame, e o controlador evolutivo avalia a sua população também em paralelo. Para garantir uma comparação justa, os três controladores partilham o mesmo orçamento de tempo de treino por cenário e a mesma semente de avaliação.

### 3.4. Protocolo de avaliação

Todos os controladores são avaliados deterministicamente ao longo de 30 episódios com sementes emparelhadas por cenário. Reportamos  $P_{\text{task}}$  (taxa de sucesso, com sucesso definido como pelo menos um item recolhido) e a média de comida recolhida por episódio, uma métrica comparável entre paradigmas. A robustez ( $R_{\text{robust}}$ ) injeta a falha de 10% dos agentes a meio do episódio; a escalabilidade ( $S_{\text{scale}}$ ) testa  $N \in \{10, 20, 50, 100\}$  sem retreino. As diferenças par a par são avaliadas com o teste  $U$  de Mann–Whitney, complementado pelo teste  $t$  de Welch, a  $\alpha = 0.05$ .

## 4. Resultados

### 4.1. Desempenho na tarefa

A Tabela 1 reporta a comida recolhida por episódio — a métrica de magnitude — a par da taxa de sucesso. Salientamos a




Figura 3: Comida recolhida por episódio (média  $\pm$  desvio-padrão) por cenário e controlador. O contraste de magnitude entre os métodos de gradiente e o controlador evolutivo é evidente, mesmo onde este último regista sucesso não nulo.

primeira: uma taxa de sucesso de 100% sob a definição “pelo menos um item recolhido” é um sinal fraco, como a tabela deixa claro. Os métodos de gradiente dominam a tarefa: o SAC recolhe substancialmente nos seis cenários e o PPO em cinco de seis, falhando apenas o Muro em U, onde recolhe *zero* itens apesar de acumular uma elevada recompensa modelada — um caso claro de *exploração da recompensa*, em que o bônus de exploração é aproveitado sem efetivamente recolher. O controlador evolutivo é o mais fraco por larga margem: embora ocasionalmente atinja uma taxa de sucesso não nula (por exemplo, 97% na Percepção Cooperativa), recolhe apenas quantidades residuais (2.6 itens nesse caso, e essencialmente zero nos três labirintos). Este desfasamento entre uma elevada taxa de sucesso e um rendimento quase nulo é a assinatura da *exploração da aptidão*: a aptidão de treino sobe sem se traduzir em conclusão da tarefa. A Figura 3 visualiza estas diferenças de magnitude.

#### 4.2. Análise qualitativa da navegação

Os mapas de ocupação acumulada explicam *como* cada controlador se comporta no Muro em U (Figura 4). O controlador evolutivo fica preso abaixo da barra e nunca alcança o ninho; o PPO espalha-se pela arena a colher o bônus de exploração mas sem completar a entrega — a marca visual do *reward hacking*, em que a recompensa modelada sobe sem produzir comida; e o SAC contorna o muro pelos dois lados e converge para o ninho. A diferença não é de percepção — os três partilham a mesma observação — mas de qualidade da política aprendida sob a mesma recompensa geodésica.

#### 4.3. Escalabilidade zero-shot

O compromisso emerge sob a escalabilidade. Apenas o controlador baseado em atenção é viável para  $N \neq 20$ : a sua taxa de sucesso *aumenta* com o tamanho do enxame, de 15% em  $N = 10$  para 100% em  $N = 100$ , sem degradação per capita (Figura 5). As políticas de perceptrão multicamada do PPO/SAC têm uma entrada de dimensão fixa e são estruturalmente incompatíveis com outros tamanhos de enxame. A adaptabilidade arquitetural — a propriedade que a hipótese atribui ao MARL — manifesta-se, assim, na *representação* (grafo com atenção), e não no algoritmo de otimização.

#### 4.4. Robustez

Sob a falha de 10% dos agentes a meio do episódio, todos os paradigmas mantêm desempenho elevado (94–99% dos itens recolhidos para o PPO/SAC; 69–96% para o GNN onde funciona), sem colapso (Figura 6): a partilha de parâmetros e a observação local conferem redundância funcional ao enxame.

#### 4.5. Significância estatística

A Tabela 2 apresenta as 18 comparações par a par sobre a comida recolhida. Dezassete são significativas ( $p < 0.001$ ); a única exceção é PPO vs. SAC nas Quatro Salas ( $p = 0.53$ ), onde os dois métodos de gradiente são estatisticamente indistinguíveis. A magnitude e a consistência destas diferenças confirmam que o ordenamento dos controladores não é um artefacto da variância amostral.

### 5. Discussão

O colapso do controlador evolutivo nos cenários de labirinto não é uma propriedade da arquitetura — a mesma representação de grafo com atenção sustenta a sua vantagem de escalabilidade — mas da interação entre o método de otimização e a estrutura da recompensa. A neuroevolução otimiza a partir de um único escalar de aptidão por episódio, sem atribuição de crédito temporal; nunca aprende *qual* ação importou. Quando a recompensa de tarefa é esparsa, como nos labirintos, quase todos os genomas não recolhem comida, a aptidão reduz-se ao termo de modelação (saturado) e a população instala-se num *planalto de aptidão* onde a pressão seletiva desaparece. A mesma natureza estocástica explica a elevada variância entre execuções independentes, ausente nos métodos de gradiente: sem um gradiente a puxar cada execução para um ótimo comum, cada execução é um passeio aleatório distinto sobre a paisagem de aptidão, e encontrar o vale estreito das soluções dos labirintos depende largamente do número de gerações exploradas.

Decorrem duas implicações. Primeira, a comparação combina dois fatores — algoritmo de otimização e arquitetura de rede — pelo que a limitação observada é de *eficiência amostral* do otimizador, e não de capacidade representacional; integrar o módulo de atenção numa política treinada por gradiente é o passo natural para isolar o efeito. Segunda, o valor de engenharia não está em eleger um vencedor, mas em identificar o ponto de inflexão: a escolha do paradigma deve seguir o eixo de exigência dominante — desempenho na tarefa a um tamanho de enxame fixo (MARL) *versus* escalabilidade para tamanhos nunca vistos (grafo com atenção).

### 6. Limitações do estudo

Três limitações enquadram o alcance das conclusões. Primeira, e mais importante, a comparação é *assimétrica*: o controlador evolutivo usa uma arquitetura de grafo com atenção, enquanto os *baselines* de gradiente usam um perceptrão multicamada de entrada fixa. Isolar o efeito do otimizador exigiria treinar a mesma arquitetura de atenção por gradiente — o passo natural já identificado. Segunda, os números determinísticos

Tabela 1: Desempenho por episódio sob avaliação determinística (30 episódios com sementes emparelhadas por cenário, execução oficial): média de comida recolhida  $\pm$  desvio-padrão, com a taxa de sucesso (percentagem de episódios com pelo menos um item recolhido) entre parênteses. A comida recolhida é a métrica de magnitude comparada entre paradigmas; a taxa de sucesso, isolada, é um indicador fraco, pois um agente atinge 100% recolhendo um único item. Melhor média por linha a negrito.

| Cenário               | GNN                 | PPO                                     | SAC                                     |
|-----------------------|---------------------|-----------------------------------------|-----------------------------------------|
| Sandbox               | $0.8 \pm 0.7$ (67%) | <b><math>73.3 \pm 5.1</math> (100%)</b> | $25.2 \pm 3.6$ (100%)                   |
| Muro em U             | $0.4 \pm 0.5$ (43%) | $0.0 \pm 0.0$ (0%)                      | <b><math>20.6 \pm 1.3</math> (100%)</b> |
| Gargalo               | $0.0 \pm 0.0$ (0%)  | <b><math>41.0 \pm 1.4</math> (100%)</b> | $35.0 \pm 1.6$ (100%)                   |
| Quatro Salas          | $0.0 \pm 0.0$ (0%)  | $11.5 \pm 3.4$ (100%)                   | <b><math>11.6 \pm 3.0</math> (100%)</b> |
| Porta Cooperativa     | $0.0 \pm 0.0$ (0%)  | <b><math>67.7 \pm 1.6</math> (100%)</b> | $60.5 \pm 1.3$ (100%)                   |
| Percepção Cooperativa | $2.6 \pm 1.4$ (97%) | <b><math>17.9 \pm 1.9</math> (100%)</b> | $16.2 \pm 1.8$ (100%)                   |




Figura 4: Mapas de ocupação no Muro em U (escala logarítmica). O controlador evolutivo (esquerda) fica preso abaixo da barra; o PPO (centro) percorre a arena a explorar mas sem entregar comida (*reward hacking*); o SAC (direita) contorna o muro pelos dois lados e atinge o ninho. Mesma observação, políticas distintas.




Figura 5: Transferência *zero-shot* para tamanhos de enxame nunca vistos ( $N \in \{10, 20, 50, 100\}$ ), sem retreino. Só o controlador com atenção sobre o grafo é estruturalmente compatível com  $N \neq 20$ , e a sua taxa de sucesso melhora com o tamanho do enxame. O PPO/SAC, com entrada de dimensão fixa, são incompatíveis.

reportados resultam de uma execução de treino oficial por controlador; embora a avaliação use 30 episódios com sementes emparelhadas, a variância *entre* execuções de treino da neuro-evolução é elevada e só um protocolo de execução múltipla a poderá quantificar plenamente. Terceira, todos os resultados são em simulação; a transferência para hardware real introduz o conhecido *reality gap*, cuja mitigação por aleatorização de domínio (Tobin et al., 2017) fica como trabalho futuro. Estas limitações não invalidam o achado central — o compromisso




Figura 6: Retenção de desempenho sob falha de 10% dos agentes a meio do episódio, relativa à execução nominal. Nenhum paradigma colapsa; a redundância emerge da partilha de parâmetros e da observação puramente local.

desempenho/escalabilidade é robusto e estatisticamente suportado — mas delimitam-no com honestidade.

## 7. Conclusões

Apresentámos uma avaliação comparativa imparcial de um controlador de atenção neuroevoluído contra o PPO e o SAC num exame de *foraging* tridimensional, ao longo de seis cenários e três eixos de avaliação com suporte estatístico. A hipótese de que a inteligência adaptativa domina a robustez estática é apenas parcialmente confirmada: os métodos de gradiente vencem decisivamente na conclusão da tarefa a  $N = 20$ , enquanto apenas o controlador baseado em atenção escala *zero-shot* até  $N = 100$ . O trabalho futuro inclui uma política de atenção treinada por gradiente para separar o otimizador da arquitetura, um protocolo de execução múltipla para consolidar as estimativas

Tabela 2: Testes de significância sobre a comida recolhida (30 episódios emparelhados; teste  $U$  de Mann–Whitney,  $\alpha = 0.05$ ). “méd. A” e “méd. B” são as médias de comida recolhida de cada elemento do par.

| Cenário               | Par        | méd. A | méd. B | $p$     | Significativo |
|-----------------------|------------|--------|--------|---------|---------------|
| Sandbox               | GNN vs PPO | 0.77   | 73.30  | < 0.001 | Sim           |
| Sandbox               | GNN vs SAC | 0.77   | 25.23  | < 0.001 | Sim           |
| Sandbox               | PPO vs SAC | 73.30  | 25.23  | < 0.001 | Sim           |
| Muro em U             | GNN vs PPO | 0.43   | 0.00   | 0.0003  | Sim           |
| Muro em U             | GNN vs SAC | 0.43   | 20.63  | < 0.001 | Sim           |
| Muro em U             | PPO vs SAC | 0.00   | 20.63  | < 0.001 | Sim           |
| Gargalo               | GNN vs PPO | 0.00   | 41.03  | < 0.001 | Sim           |
| Gargalo               | GNN vs SAC | 0.00   | 35.00  | < 0.001 | Sim           |
| Gargalo               | PPO vs SAC | 41.03  | 35.00  | < 0.001 | Sim           |
| Quatro Salas          | GNN vs PPO | 0.00   | 11.50  | < 0.001 | Sim           |
| Quatro Salas          | GNN vs SAC | 0.00   | 11.60  | < 0.001 | Sim           |
| Quatro Salas          | PPO vs SAC | 11.50  | 11.60  | 0.5312  | não           |
| Porta Cooperativa     | GNN vs PPO | 0.00   | 67.73  | < 0.001 | Sim           |
| Porta Cooperativa     | GNN vs SAC | 0.00   | 60.50  | < 0.001 | Sim           |
| Porta Cooperativa     | PPO vs SAC | 67.73  | 60.50  | < 0.001 | Sim           |
| Percepção Cooperativa | GNN vs PPO | 2.63   | 17.87  | < 0.001 | Sim           |
| Percepção Cooperativa | GNN vs SAC | 2.63   | 16.23  | < 0.001 | Sim           |
| Percepção Cooperativa | PPO vs SAC | 17.87  | 16.23  | < 0.001 | Sim           |

de variância, e a validação da transferência simulação-para-real (Tobin et al., 2017).

### Agradecimentos

Este artigo foi parcialmente financiado por fundos nacionais através da Fundação para a Ciência e a Tecnologia, I.P. (FCT), Projetos Plurianuais ISTAR-Iscte UID/04466/2025 (<https://doi.org/10.54499/UID/04466/2025>).

### Referências

Bettini, M., Prorok, A., Moens, V., 2024. Benchmarl: Benchmarking multi-agent reinforcement learning. *Journal of Machine Learning Research* 25.

Chen, X., NaderiAlizadeh, N., Ribeiro, A., Saeedi Bidokhti, S., 2024. Transferable graphical marl for real-time estimation in dynamic wireless networks. *arXiv preprint arXiv:2404.03227*.

Ekechi, C.C., Elfouly, T., Alouani, A., Khattab, T., 2025. A survey on uav control with multi-agent reinforcement learning. *Drones* 9, 484.

Elrod, M., Mehrabi, N., Amin, R., Kaur, M., Cheng, L., Martin, J., Razi, A., 2025. Graph based deep reinforcement learning aided by transformers for multi-agent cooperation. *arXiv preprint arXiv:2504.08195*.

Haarnoja, T., Zhou, A., Abbeel, P., Levine, S., 2018. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor, in: *Proceedings of the 35th International Conference on Machine Learning (ICML)*, pp. 1861–1870.

Huh, D., Mohapatra, P., 2023. Multi-agent reinforcement learning: A comprehensive survey. *arXiv preprint arXiv:2312.10256*.

Hüttenrauch, M., Šošić, A., Neumann, G., 2019. Deep reinforcement learning for swarm systems. *Journal of Machine Learning Research* 20, 1–31.

Iskandar, A., Rostum, H., Kovács, B., 2023. Using deep reinforcement learning to solve a navigation problem for a swarm robotics system, in: *2023 24th International Carpathian Control Conference (ICCC)*, IEEE. pp. 185–189.

Kegeleirs, M., Birattari, M., 2025. Towards applied swarm robotics: current limitations and enablers. *Frontiers in Robotics and AI* 12. doi:10.3389/frobt.2025.1607978.

Kennedy, J., Eberhart, R., 1995. Particle swarm optimization, in: *Proceedings of ICNN’95 - International Conference on Neural Networks*, IEEE. pp. 1942–1948.

Lowe, R., Wu, Y., Tamar, A., Harb, J., Abbeel, P., Mordatch, I., 2017. Multi-agent actor-critic for mixed cooperative-competitive environments, in: *Advances in Neural Information Processing Systems (NeurIPS)*.

Majid, A.Y., Saaybi, S., Francois-Lavet, V., Prasad, R.V., Verhoeven, C., 2024. Deep reinforcement learning versus evolution strategies: A comparative survey. *IEEE Transactions on Neural Networks and Learning Systems* 35, 11939–11957.

Ng, A.Y., Harada, D., Russell, S., 1999. Policy invariance under reward transformations: Theory and application to reward shaping, in: *Proceedings of the 16th International Conference on Machine Learning (ICML)*, pp. 278–287.

Oliehoek, F.A., Amato, C., 2016. *A Concise Introduction to Decentralized POMDPs*. Springer.

Salimans, T., Ho, J., Chen, X., Sidor, S., Sutskever, I., 2017. Evolution strategies as a scalable alternative to reinforcement learning. *arXiv preprint arXiv:1703.03864*.

- Schmickl, T., et al., 2025. Scaling swarm coordination with GNNs—how far can we go? *AI* 6, 282. doi:10.3390/ai6110282.
- Schulman, J., Moritz, P., Levine, S., Jordan, M.I., Abbeel, P., 2016. High-dimensional continuous control using generalized advantage estimation, in: International Conference on Learning Representations (ICLR).
- Schulman, J., Wolski, F., Dhariwal, P., Radford, A., Klimov, O., 2017. Proximal policy optimization algorithms. arXiv preprint arXiv:1707.06347 .
- Tobin, J., Fong, R., Ray, A., Schneider, J., Zaremba, W., Abbeel, P., 2017. Domain randomization for transferring deep neural networks from simulation to the real world, in: IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), IEEE. pp. 23–30.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A.N., Kaiser, Ł., Polosukhin, I., 2017. Attention is all you need, in: Advances in Neural Information Processing Systems (NeurIPS).
- Veličković, P., Cucurull, G., Casanova, A., Romero, A., Liò, P., Bengio, Y., 2018. Graph attention networks, in: International Conference on Learning Representations (ICLR).