

Aprendizagem Adaptativa *versus* Robustez Estática: Comparação de Aprendizagem por Reforço e Neuroevolução para Controlo de Enxames

Gonalo Alexandre Pombo Santos^a, Lu s Nunes^a

^aInstituto Universit rio de Lisboa (ISCTE-IUL), ISTAR, Lisboa, Portugal

Abstract

O controlo de enxames rob ticos   abordado por duas comunidades que raramente se encontram num referencial comum: a aprendizagem por reforo multiagente (MARL) e a optimiza o bio-inspirada. Comparamos tr s controladores — uma rede de grafo neuroevolu da com aten o sobre os vizinhos, *Proximal Policy Optimisation* (PPO) e *Soft Actor-Critic* (SAC) — no mesmo simulador tridimensional de navega o cooperativa at  ao ninho, em sete cen rios de dificuldade crescente, com sete execu es de treino independentes por combina o e infer ncia n o param trica ao n vel da execu o. O resultado central   que o desempenho do controlador evolutivo depende menos do oramento de treino do que do *desenho da fun o de aptid o*: substituindo o retorno acumulado — farm vel por deambula o — por um *shaping* de *homing* terminal, converge nas 28 execu es dos quatro cen rios de gargalo e torna-se superior aos m todos de gradiente em tr s cen rios, indistingu vel do melhor deles em mais dois. Estes conservam a fiabilidade em espao aberto e uma efici ncia computacional $\approx 8\times$ superior. Sob escalabilidade *zero-shot*, s  o controlador com aten o transita de $N = 10$ para $N = 100$ sem retreino, com 100% de sucesso nas 28 combina es cen rio $\times$ dimens o. A hibridiza o com procura por novidade, sob oramento igualado, resolve o  nico cen rio que resistia aos tr s controladores (7/7 no labirinto de dee o espacial) mas, com peso fixo, degrada o desempenho onde o gradiente da tarefa basta; uma *dosagem adaptativa*, validada em campanha pr -registada, elimina esse custo mantendo o ganho. Uma replica o com $n = 28$ por brao fixa-o em 28/28 execu es contra 15/28 (Fisher exato, $p < 0,0001$) e mostra que, *sem* essa dosagem, o controlador evolutivo   indistingu vel do PPO: o que separa os braos   a explora o, n o o paradigma. Um oitavo cen rio, que comp e quatro dificuldades num labirinto quatro vezes maior, delimita o alcance destas conclus es: sem retreino nada transfere, e com treino nativo s  o controlador evolutivo o resolve, em 4 de 21 execu es. A hip tese de que a intelig ncia adaptativa domina a robustez est tica  , por isso, apenas *parcialmente* confirmada — a vantagem decisiva reside na *representa o* e no desenho do sinal de treino, n o no algoritmo de optimiza o.

Keywords: rob tica de enxames, aprendizagem por reforo multiagente, neuroevolu o, escalabilidade zero-shot, redes neuronais de grafos, avalia o comparativa

1. Introdu o

Os enxames rob ticos prometem solu es escal veis e resilientes para tarefas como busca e salvamento, monitoriza o ambiental e log stica distribu da. A quest o central de engenharia   qual o paradigma de controlo que melhor mant m a operacionalidade sob incerteza. Duas escolas dominam. A *optimiza o bio-inspirada* (por exemplo, algoritmos evolutivos e optimiza o por enxame de part culas) procura num espao global de par metros, *fora de linha*, controladores robustos e est ticos (Kennedy and Eberhart, 1995). A *aprendizagem por reforo multiagente* (MARL) aprende, em alternativa, pol ticas adaptativas *em linha* atrav s da intera o (Huh and Mohapatra, 2023).

O levantamento comparativo de refer ncia confronta os dois paradigmas apenas no plano conceptual (Majid et al., 2024), e a *suite* de refer ncia do MARL n o inclui qualquer *baseline* evolutiva (Bettini et al., 2024); que as compara es diretas sejam escassas nunca foi, tanto quanto sabemos, medido. Condu-

zimos por isso uma revis o sistem tica (PRISMA 2020; Scopus e IEEE Xplore, 2020–2026; 883 registos, 680  nicos), cujo corpo final de 58 estudos prim rios sobre controlo de enxames revela um equil brio not vel: 21 assentam exclusivamente em MARL e 23 em optimiza o bio-inspirada — dois campos igualmente produtivos. Contudo, **apenas dois** os confrontam, e um deles f -lo por hibridiza o. Existe, portanto, na literatura recuperada, **um  nico estudo** que compara empiricamente MARL com optimiza o bio-inspirada na navega o de enxames (Iskandar et al., 2024) — numa s  tarefa, sem transfer ncia para dimens es de enxame n o vistas, sem testes de robustez a falhas e sem infer ncia estat stica. O isolamento metodol gico entre as duas comunidades deixa assim de ser um diagn stico intuitivo para passar a ser uma contagem: 1 em 58.

Controlar um enxame   dif cil por tr s raz es que se reforam: o espao de a es conjuntas cresce exponencialmente com o n mero de agentes; a recompensa de tarefa   esparsa e diferida, o que agrava a atribui o de cr dito; e cada agente decide a partir de uma observa o parcial e local. Os dois paradigmas respondem de formas opostas — a MARL aprende uma

Email address: goncalopombo123@gmail.com (Gonalo Alexandre Pombo Santos)

política partilhada que generaliza por experiência, a otimização bio-inspirada procura um controlador robusto num só esforço — e a questão que daí decorre é se a *inteligência adaptativa* supera a *robustez estática* sob *stress* dinâmico. Responder-lhe exige um referencial em que ambos sejam avaliados nas mesmas condições, com as mesmas métricas e a mesma análise estatística.

É o que aqui se faz. Implementámos um simulador tridimensional próprio de navegação cooperativa até ao ninho e avaliámos três controladores — uma rede de grafo neuroevoluída com auto-atenção sobre os vizinhos, PPO e SAC — em sete cenários e ao longo de três eixos: desempenho na tarefa (P_{task}), robustez a falhas (R_{robust}) e escalabilidade *zero-shot* (S_{scale}). Cada combinação foi treinada em sete execuções independentes, o que permite tratar a *execução de treino* — e não o episódio — como unidade estatística, distinguindo o desempenho atingível da fiabilidade da convergência.

A contribuição é quintupla: (i) a quantificação da lacuna por revisão sistemática, que situa este trabalho como a segunda comparação empírica entre os dois paradigmas na navegação de enxames — e a primeira com escalabilidade, robustez e inferência estatística; (ii) um protocolo de avaliação reprodutível e independente do paradigma; (iii) a demonstração de que o alegado colapso da neuroevolução nos estrangulamentos é um artefacto do *desenho da aptidão*, corrigível por um *shaping* de *homíng* terminal não farmável; (iv) a evidência de que a escalabilidade *zero-shot* é propriedade da representação, não do otimizador; e (v) a validação, sob protocolo *pré-registado*, de uma dosagem adaptativa da pressão por novidade. Uma versão preliminar deste trabalho, com orçamento mais curto e aptidão baseada no retorno acumulado, levava à conclusão oposta sobre o paradigma evolutivo — o que ilustra a importância do segundo contributo.

2. Trabalho Relacionado

A aprendizagem por reforço profunda tem sido aplicada a sistemas de enxame com partilha de parâmetros para domar a explosão do espaço de ações conjuntas (Hüttenrauch et al., 2019), em que uma única rede é partilhada por todos os agentes homogéneos. As redes neuronais de grafos (GNN) emergiram como o principal viabilizador da escalabilidade. O mecanismo é estrutural: numa política definida sobre um grafo, o número de parâmetros treináveis não depende do número de agentes, pelo que a política aprendida se aplica diretamente a grafos maiores sem retreino — propriedade caracterizada com clareza por Chen et al. (2024), ainda que em redes multi-salto sem fios e não em robótica. Em robótica de enxame, a invariância à dimensão da vizinhança é confirmada empiricamente na exploração multi-robô com GNN hierárquicas (Zhang et al., 2022) e, por outra via, em aproximações de campo médio, nas quais o agente reage à distribuição estatística dos vizinhos em vez de a cada um individualmente, tornando o custo de coordenação independente de N (Tang et al., 2023). O mecanismo de atenção (Vaswani et al., 2017; Veličković et al., 2018) é central nesta família, por ser invariante à permutação e à cardinalidade do

conjunto de vizinhos, e sustenta igualmente a manutenção de formações sob variação da escala do enxame (Li et al., 2024).

No paradigma de aprendizagem, o treino centralizado com execução descentralizada (CTDE) tornou-se padrão para domar a não-estacionariedade (Lowe et al., 2017; Oliehoek and Amato, 2016). Aqui, contudo, os *baselines* de gradiente partilham uma única política e executam a partir da observação de cada agente, sem crítico global, o que ancora a comparação num regime descentralizado comum aos três controladores.

Do lado bio-inspirado, a neuroevolução otimiza os pesos sem gradientes (Salimans et al., 2017; Such et al., 2017), oferecendo controladores estáveis mas que, uma vez otimizados, ficam fixos durante a execução. Otimiza a partir de um único escalar de aptidão por episódio, sem atribuição de crédito temporal — uma distinção que se revelará decisiva: quando a recompensa de tarefa é esparsa, a aptidão fica refém do termo de modelação, e a escolha desse termo determina se a seleção discrimina ou fica cega.

Que esta especificação seja difícil não é observação nova: é o que motiva a linha de *desenho automático* de enxames. Hasselmann et al. (2023) geram, por procura por novidade (Lehman and Stanley, 2011), repertórios de comportamentos montados modularmente em controladores; Szpírer et al. (2024) substituem a função-objetivo por demonstrações, recuperando-a por reforço inverso; e a transferibilidade destes controladores entre plataformas foi caracterizada por Kegeleirs et al. (2024). Numa linha complementar, a evolução é tratada como processo *em linha* e distribuído (Bredeche and Fontbonne, 2022; Fontbonne et al., 2020). Na tarefa de *foraging* — próxima desta, mas com objetos a recolher — a neuroevolução é aplicada com sucesso em arenas abertas com obstáculos dispersos (Zaman et al., 2025; Biteng et al., 2025) e a afinação multiobjetivo arbitra entre recolha e energia (Ordáz-Rivas et al., 2026). Estes trabalhos empregam aptidões baseadas em retorno acumulado *sem* observar o colapso que aqui reportamos — divergência que atribuímos à ausência, nas suas arenas, de estrangulamentos de cetivos onde o termo de modelação satura (Secção 5).

Quanto ao confronto entre paradigmas, não existe uma referência de desempenho comum entre as duas famílias: os referenciais padronizados de MARL permanecem focados dentro da comunidade de aprendizagem, sem qualquer *baseline* evolutiva (Bettini et al., 2024). A única comparação empírica que a nossa revisão recuperou (Iskandar et al., 2024) — conduzida pelo grupo que havia antes aplicado aprendizagem por reforço profunda à navegação de enxames (Iskandar et al., 2023) — conclui que a aprendizagem se destaca em ambientes próximos das condições de treino, enquanto a otimização por enxame de partículas exhibe consistência superior em cenários não treinados, sem reconfiguração. É uma conclusão convergente com a que aqui se obtém por um protocolo mais exigente; a diferença está em que a sustentamos em sete cenários, sete execuções independentes por combinação e testes não paramétricos ao nível da execução, acrescentando os eixos de escalabilidade a dimensões não vistas e de robustez a falhas que aquele estudo não aborda.

3. Metodologia

3.1. Ambiente de simulação

O ambiente é uma tarefa contínua e tridimensional de navegação cooperativa até ao ninho, numa arena circular (raio 15 m) com $N = 20$ agentes homogêneos. Utilizam-se sete cenários de dificuldade crescente: um *Sandbox* aberto; três labirintos de navegação (*Beco Sem Saída* — ou *Muro em U* —, *Gargalo*, *Quatro Salas*); duas tarefas cooperativas (*Porta Cooperativa*, que exige ≥ 3 agentes para abrir uma passagem, e *Percepção Cooperativa*, com um alvo móvel); e um cenário *deceptive*, a *Porta Cooperativa com Alternativa*, em que a porta bloqueada atrai o gradiente de navegação enquanto o caminho que dispensa a cooperação é um corredor lateral que obriga a afastar-se temporariamente do ninho. A Figura 1 ilustra os sete cenários. Cada agente observa uma bússola de *homing* egocêntrica para o ninho, oito raios LiDAR para deteção local de obstáculos e o estado relativo de todos os outros agentes, sem limite de alcance — um cenário parcialmente observável, formalizável como um Dec-POMDP (Oliehoek and Amato, 2016). A bússola fornece a direção e a distância euclidiana ao ninho de forma sempre disponível (à imagem do *homing* global em formigas ou da navegação por GPS), ao passo que os obstáculos só são percebidos localmente pelo LiDAR de 8 m, preservando uma observabilidade parcial genuína.

Para evitar mínimos locais nos cenários de labirinto, a recompensa de progresso usa um potencial *geodésico* calculado pelo algoritmo de Dijkstra sobre uma grelha de ocupação dilatada, atuando como modelação de recompensa baseada em potencial (Ng et al., 1999) — sem o fator γ , pelo que a política ótima só se preserva de forma aproximada — e é usada apenas como sinal de treino, nunca como observação. A Figura 2 contrasta o potencial euclidiano ingênuo — que “atravessa” a parede e cria um mínimo local que cola os agentes ao obstáculo — com o campo geodésico, cujo gradiente premeia corretamente o contorno da barra. Esta distinção é essencial para a leitura dos resultados: o sinal de treino aponta sempre para o desvio correto, pelo que as dificuldades observadas no Muro em U são de *descoberta*, não de modelação da recompensa.

3.2. Espaço de observação, de ação e recompensa

A observação de cada agente reúne a bússola de *homing*, os oito raios LiDAR e o estado relativo dos $N - 1$ vizinhos; manter o vizinho como entidade explícita é o que permite à GNN atender sobre um conjunto de cardinalidade variável. A ação é contínua e egocêntrica — três componentes de translação em $[-1, 1]$, escaladas por um passo máximo de 0,2 m, com deslizamento ao longo das paredes em caso de colisão.

A recompensa foi deliberadamente *simplificada* face a iterações anteriores e reduz-se a quatro termos: +300 por chegada (repetível e claramente dominante); o progresso geodésico com fator 10 (Ng et al., 1999); um bônus de exploração por contagem (+0,5 por célula nova de 2×2 m), pequeno de propósito; e um custo energético de $-0,05$ por passo. As penalizações de dispersão e colisão foram anuladas no *sinal* (a física mantém-se), por competirem com a tarefa sem benefício mensurável. Não há objetos a recolher: conta-se uma *chegada* quando $k_{\min}$

agentes estão em simultâneo no ninho, de onde reaparecem na partida — $k_{\min} = 3$ nos cenários cooperativos e 1 nos labirintos, onde três converte a navegação em cooperação artificial. Uma calibração anterior, com bônus de exploração maior, produziu *exploração da recompensa*: a política deambulava a colher exploração em vez de chegar ao ninho.

3.3. Controladores

O *controlador evolutivo* (GNN) é uma rede compacta que codifica as características egocêntricas e aplica auto-atenção de produto escalar normalizado sobre o conjunto de vizinhos (Vaswani et al., 2017), produzindo uma ação invariante ao número de vizinhos. Os seus pesos são otimizados por um algoritmo genético com truncatura e elitismo (Such et al., 2017) (população $K = 30$, $e = 6$ elites preservados, mutação gaussiana esparsa com σ inicial 0,1, decaimento 0,999 e piso $\sigma_{\min} = 0,03$), guiada por uma aptidão em que a tarefa domina a seleção:

$$J(\theta_k) = \bar{f}_k \cdot \lambda_{\text{task}} + \beta \cdot \bar{h}_k, \quad \lambda_{\text{task}} = 10^4, \beta = 5000, \quad (1)$$

onde $\bar{f}_k$ é a média de chegadas e $\bar{h}_k \in [0, 1]$ é o *homing*: a fração média de aproximação ao ninho *no final* do episódio, medida por agente como $\text{clip}((\Phi_0 - \Phi_T)/\Phi_0, 0, 1)$, com Φ o potencial de navegação (geodésico nos cenários com paredes). As médias são tomadas sobre $E = 4$ episódios com sementes fixas.

A escolha de $\bar{h}$ é a decisão de desenho central deste trabalho. Numa formulação anterior, o termo de desempate era o retorno acumulado comprimido por uma *tanh*; mas o retorno acumulado é *farmável*, porque o progresso e a exploração rendem a cada passo: observaram-se genomas com retorno bruto $\approx 88\,000$ e *zero* chegadas, que deambulavam indefinidamente porque parar no ninho — a pré-condição da tarefa — corta o rendimento por passo. O *homing* terminal elimina a patologia por construção: depende apenas dos estados extremos do episódio, não do caminho, pelo que deambular não o aumenta, e a única forma de o maximizar é *terminar* junto ao ninho. Como uma única chegada (10^4) vale o dobro do *shaping* máximo (5000), a tarefa domina a seleção assim que um genoma chega ao ninho.

Os *baselines de aprendizagem* são o PPO (Schulman et al., 2017) — com estimação de vantagem generalizada (Schulman et al., 2016) — e o SAC (Haarnoja et al., 2018) da Stable-Baselines3, com uma política de percepção multicamada partilhada ([256, 256]) sobre a observação densa da vizinhança. O mecanismo de atenção sobre o grafo é, assim, instanciado apenas no controlador evolutivo, o que é precisamente o que viabiliza a sua transferência *zero-shot*. Todos treinam sobre ambientes vetorizados em paralelo, com a mesma política a recolher experiência de todos os agentes do enxame.

3.4. Protocolo de avaliação

Cada combinação (algoritmo, cenário) foi treinada em **sete execuções independentes** com sementes distintas, perfazendo $3 \times 7 \times 7 = 147$ treinos numa campanha contínua de sete dias. Cada execução do controlador evolutivo dispôs de 195 minutos sobre ≈ 30 núcleos, e cada execução de PPO/SAC de 48 minutos sobre 16 núcleos, calibrados para levar cada paradigma




Figura 1: Os sete cenários, renderizados a partir da geometria real do simulador. Da esquerda para a direita: Sandbox (aberto, com obstáculos esféricos), Muro em U, Gargalo, Quatro Salas, Porta Cooperativa (passagem a âmbar, abre com ≥ 3 agentes), Percepção Cooperativa (alvo móvel) e Porta Cooperativa com Alternativa (*deceptive*: a porta atrai, o corredor lateral resolve). O ninho é a esfera verde; a malha de círculos é a fronteira do domínio, que é uma esfera de raio 15 m — os agentes têm componente vertical de movimento, e cada parede aparece sólida a 2 m (leitura da planta) e translúcida com a altura real, que corta o domínio de lado a lado.




Figura 2: Potencial de recompensa no Muro em U: a distância euclidiana (esquerda) atravessa a parede e induz um mínimo local; o campo geodésico (direita), calculado por Dijkstra sobre a grelha com obstáculos dilatados, premeia o contorno e elimina a armadilha. É um sinal de treino, não uma observação.

ao seu planalto. Uma verificação *a posteriori* sobre as curvas (comparação emparelhada, por execução, entre o último quinto do orçamento e o anterior) mostra que 7 das 21 combinações ainda subiam significativamente no fim — notoriamente o SAC no Gargalo (+112%) e na Porta com Alternativa (+105%). A comparação mede, pois, o *desempenho atingível dentro do orçamento concedido*, com essas células a valerem como limite inferior, e os métodos de gradiente conservam uma vantagem de $\approx 8\times$ em núcleos-hora.

Cada modelo é depois avaliado deterministicamente em 20 episódios com sementes emparelhadas entre algoritmos, totalizando 140 episódios por célula. Reportamos P_{task} (taxa de sucesso, com sucesso definido como pelo menos uma chegada) e a média de chegadas por episódio, que é a métrica de magnitude comparável entre paradigmas. A robustez (R_{robust}) injeta a falha de 10% dos agentes a meio do episódio; a escalabilidade (S_{scale}) testa $N \in \{10, 20, 50, 100\}$ sem retreino.

Um ponto metodológico merece ênfase: as diferenças par a par são avaliadas sobre as **médias por execução** ($n = 7$ por grupo), com o teste U de Mann–Whitney e o δ de Cliff como tamanho de efeito, a $\alpha = 0,05$. A unidade estatística independente é a execução de treino, e não o episódio — tratar os 140 episódios como observações independentes inflacionaria artificialmente o poder do teste, pois episódios da mesma execução partilham o mesmo controlador.

4. Resultados

4.1. Desempenho na tarefa

A Tabela 1 reporta as chegadas por episódio, a taxa de sucesso e o número de execuções plenamente convergentes. Esta última coluna é essencial: uma taxa de sucesso média intermédia quase nunca significa “resolve o cenário metade das vezes”, mas sim que *algumas execuções resolvem-no integralmente e outras falham por completo*. Quinze das vinte e uma combinações algoritmo–cenário atingem 100% de sucesso em todas as execuções; as seis restantes escondem, sem exceção, esta distribuição tudo-ou-nada.

O quadro que emerge não tem um vencedor universal. O **controlador evolutivo** resolve os quatro cenários de gargalo — Gargalo, Quatro Salas e as duas Portas Cooperativas, incluindo portanto o cenário *deceptive* — nas 28 execuções correspondentes, igualando o PPO no Gargalo (121,4 chegadas/ep, empate estatístico) e destacando-se no Quatro Salas (59,8, cerca de $1,8\times$ o melhor método de gradiente) e na Porta Cooperativa com Alternativa (86,7); mas exhibe execuções degeneradas precisamente nos cenários *sem paredes* (Sandbox, 5/7; Percepção Cooperativa, 6/7), onde a paisagem de aptidão oferece ótimos locais de deambulação. O **PPO** é o mais consistente, com 100% de sucesso em seis dos sete cenários e a menor variância entre execuções. O **SAC** é fiável em espaço aberto e nos cooperativos, mas o mais frágil nos estrangulamentos físicos: no Gargalo apenas 5/7 execuções convergem, com magnitude muito dispersa ($41,4 \pm 36,8$).

4.2. O Muro em U e a bimodalidade entre execuções

O Muro em U é o único cenário que *nenhum* algoritmo resolve de forma fiável, e a sua análise ilustra por que razão a unidade estatística importa. O desempenho é bimodal nos três paradigmas: cada execução ou aprende o desvio ao beco e atinge 100% de sucesso, ou não o aprende de todo (GNN 3/7, PPO 4/7, SAC 2/7) — uma distribuição que a Figura 3 torna visível, já com $n = 28$ por braço. Nenhuma diferença entre algoritmos atinge significância, e a conclusão é que sete execuções não bastam para distinguir taxas de convergência de 2/7 a 4/7 — limitação que a replicação da Secção 4.4 vem levantar, para o braço que ali se compara.

O obstáculo não está no sinal de treino — o potencial geodésico aponta corretamente para o contorno (Figura 2) — mas

Tabela 1: Desempenho sob avaliação determinística (7 execuções de treino independentes $\times$ 20 episódios com sementes emparelhadas por cenário): média $\pm$ desvio-padrão das chegadas por episódio *entre execuções*, taxa de sucesso média entre parênteses, e número de execuções que atingem 100% de sucesso. As chegadas são a métrica de magnitude comparada entre paradigmas; a taxa de sucesso, isolada, é um indicador fraco, pois basta uma única chegada por episódio para a atingir. Melhor média por linha a negrito.

Cenário	GNN	PPO	SAC
Sandbox	38,3 $\pm$ 31,0 (86%) [5/7]	71,5 $\pm$ 1,0 (100%) [7/7]	69,2 $\pm$ 1,9 (100%) [7/7]
Muro em U	24,5 $\pm$ 32,6 (43%) [3/7]	39,6 $\pm$ 36,7 (71%) [4/7]	9,0 $\pm$ 15,1 (34%) [2/7]
Gargalo	121,4 $\pm$ 19,9 (100%) [7/7]	123,2 $\pm$ 1,2 (100%) [7/7]	41,4 $\pm$ 36,8 (72%) [5/7]
Quatro Salas	59,8 $\pm$ 13,2 (100%) [7/7]	33,6 $\pm$ 3,8 (100%) [7/7]	31,8 $\pm$ 3,3 (100%) [7/7]
Porta Cooperativa	69,8 $\pm$ 0,9 (100%) [7/7]	67,1 $\pm$ 3,7 (100%) [7/7]	62,1 $\pm$ 2,5 (100%) [7/7]
Percepção Cooperativa	19,0 $\pm$ 8,7 (91%) [6/7]	15,3 $\pm$ 0,4 (100%) [7/7]	16,1 $\pm$ 0,8 (100%) [7/7]
Porta com Alternativa	86,7 $\pm$ 2,0 (100%) [7/7]	85,3 $\pm$ 4,0 (100%) [7/7]	68,6 $\pm$ 3,4 (100%) [7/7]

na *descoberta*: o agente observa apenas a bússola de *homing* euclidiana e o LiDAR local, pelo que percorrer o desvio exige uma trajetória longa que se afasta, durante dezenas de passos, da única direção que o agente percebe como sendo o ninho. Nenhum dos mecanismos de exploração estudados (entropia, *clipped surrogate*, mutação gaussiana) garante essa descoberta — é esta a motivação da procura por novidade, avaliada de seguida.

4.3. Deceção e procura por novidade

A Porta Cooperativa com Alternativa é uma armadilha *deceptive*: o gradiente de *homing* aponta para a porta bloqueada e o caminho que dispensa a cooperação exige afastamento temporário do ninho. Para medir o efeito da procura por novidade (Lehman and Stanley, 2011) nesse regime, corremos duas campanhas com **orçamento igualado** ao da campanha final (sete execuções de 195 minutos por braço, mesmo protocolo e *seeds*), nos dois cenários vulneráveis à deceção.

No Muro em U, a hibridização elevou a taxa de convergência de 3/7 para **7/7** execuções a 100% de sucesso, com 69,8 $\pm$ 5,9 chegadas/ep contra 24,5 $\pm$ 32,6 do objetivo puro (Mann–Whitney $p = 0,026$, $\delta = +0,71$) — tornando-se a única configuração estudada que resolve de forma fiável o cenário que resistia aos três controladores base. Na Porta com Alternativa, onde o *homing* já convergia em 7/7 execuções, o quadro inverte-se: a mesma pressão por novidade degradou a magnitude (63,0 $\pm$ 21,9 vs. 86,7 $\pm$ 2,0; $p = 0,0006$, $\delta = -1,00$): todas as execuções objetivas superam todas as execuções com novidade.

Com peso fixo, a pressão por novidade é, pois, um instrumento direcionado, não um melhoramento universal: compra a descoberta do desvio onde a otimização objetiva é inconsistente e desperdiça pressão seletiva onde o gradiente da tarefa basta. O peso fixo $w = 0,5$ explica ambos os efeitos — o que motivou o teste final desta linha: uma **dosagem adaptativa**, em que w parte de 0,5 e decai ($\times 0,98$ /geração, até 0) assim que o melhor genoma por objetivo chega ao ninho durante dez gerações consecutivas.


Esta campanha foi *pré-registada* — hipótese, testes confirmatórios e regra de decisão fixados no repositório antes de existirem dados de avaliação — e corrida nos sete cenários sob o protocolo integral do artigo (sete execuções de 195 minutos, sementes 1–7, inferência por execução). Os quatro testes confirmaram a hipótese: sem degradação significativa nos cinco

cenários que o objetivo já resolve (todos $p \geq 0,21$); ganho mantido no Muro em U (7/7 execuções a 100%, 68,5 $\pm$ 13,1 vs. 24,5 $\pm$ 32,6; $p = 0,009$ unilateral, $\delta = +0,76$); custo do peso fixo no cenário *deceptive* não reproduzido (77,2 $\pm$ 16,7 vs. 86,7 $\pm$ 2,0; $p = 0,32$, $\delta = -0,35$, n.s., 7/7 a 100%); e superioridade em magnitude sobre o peso fixo nesse cenário (77,2 vs. 63,0; $\delta = +0,59$). Dois braços exploratórios completam o quadro: o objetivo puro com o *dobro* do orçamento (390 min) continua bimodal no Muro em U (4/7, 31,5 $\pm$ 35,0) — o ganho é do mecanismo, não do orçamento — e o adaptativo com esse orçamento atinge no cenário *deceptive* o melhor resultado de todo o estudo (88,7 $\pm$ 0,6, 7/7). A dosagem adaptativa fecha, assim, a tensão do peso fixo: retém a exploração enquanto ela compra descoberta e devolve a seleção ao objetivo quando ele basta.

4.4. Replicação com poder estatístico ($n = 28$)

Os testes anteriores assentam em sete execuções por braço — suficientes para inferir sobre médias, curtas onde a leitura depende de *contagens*: com $n = 7$, um teste exato de Fisher sobre a convergência não é reportável. Uma campanha final de um mês de máquina, com pré-registo próprio fixado antes de existirem dados de avaliação, repetiu por isso o cenário crítico com **quatro vezes** as execuções, em quatro braços (GNN adaptativo, GNN objetivo, PPO e SAC) e com o orçamento por execução da campanha principal. As células a $n = 28$ são autocontidas: execuções novas, que o pré-registo proíbe expressamente somar às sete anteriores.

O resultado principal confirma-se e reforça-se. O adaptativo faz 67,4 $\pm$ 13,4 chegadas/ep contra 32,5 $\pm$ 32,5 do objetivo puro ($p < 0,0001$ unilateral, $\delta = +0,61$) e, sobretudo, a convergência — agora reportável — separa os braços sem ambiguidade: **28/28 execuções a 100% de sucesso contra 15/28** (Fisher exato, $p < 0,0001$), o que confirma com quatro vezes mais execuções o 7/7 da campanha pré-registada. Ao mesmo n , o adaptativo fica acima de ambos os métodos de gradiente — PPO 35,6 $\pm$ 36,0 (14/28; $p = 0,0010$, $\delta = +0,51$) e SAC 10,1 $\pm$ 14,2 (14/28; $p < 0,0001$, $\delta = +0,99$) — ao passo que o GNN *objetivo* e o PPO permanecem indistinguíveis ($p = 0,088$). A leitura que daqui resulta é mais restrita, e mais defensável, do que uma vitória de paradigma: o que separa os braços não é a neuroevolução enquanto tal, mas a **dosagem adaptativa da exploração**. No cenário *deceptive*, a mesma campanha confirma a superioridade sobre o peso fixo com $n = 21$ (80,9 $\pm$ 15,6, 21/21 a 100%,



Cada ponto = 1 execução independente (28 por algoritmo). A barra vertical é a média reportada na tese. O braço objetivo é bimodal: as execuções que resolvem fazem-no bem, e as que não resolvem ficam a zero.

Figura 3: As 28 execuções independentes de cada braço no Muro em U. Cada ponto é uma execução (média de 20 episódios determinísticos); a barra vertical é a média. A leitura decisiva não é a diferença de médias, mas a *forma* das distribuições: o GNN objetivo e o PPO repartem-se entre execuções que resolvem o cenário e execuções que ficam a zero, praticamente sem nada pelo meio, o SAC é uniformemente fraco, e a dosagem adaptativa não deixa uma única execução por resolver.

contra $63,0 \pm 21,9$; $p = 0,0016$). Os seis pares acima são valores de p brutos: o pré-registo manda declarar a multiplicidade e ancorar a leitura no tamanho de efeito, não corrigir os valores.

4.5. Composição de dificuldades: um mapa quatro vezes maior

Cada um dos sete cenários isola uma dificuldade. Para medir o que sucede quando se compõem, construímos um oitavo — um labirinto de 103×62 m que encadeia gargalo, beco em U, quatro salas e porta cooperativa — e corremos nele duas fases **pré-registadas**. Sem retreino, nenhum dos 21 campeões dos sete cenários faz uma única chegada, e três condições de controlo (normalização das distâncias, obstáculos dispersos e dimensões da observação associadas à porta) devolvem, célula a célula, o mesmo: 84 células a zero em 1680 episódios. Com treino nativo (21 execuções por controlador, 780 minutos para o evolutivo e 192 para os métodos de gradiente), só o evolutivo resolve o mapa — em 4 das 21 execuções, contra 0 de 21 do PPO e 0 de 21 do SAC —, abaixo do limiar de 15 execuções convergentes fixado antes dos dados: a resposta é **negativa** e reporta-se com a contagem à vista. A leitura está na forma e não na média: as execuções que resolvem fazem-no com magnitude comparável entre si e as restantes ficam a zero — a assinatura bimodal do Muro em U, agora à escala de quatro dificuldades encadeadas. O que a composição degrada é a *fiabilidade* do treino, não o desempenho de quem aprende.

4.6. Escalabilidade zero-shot

Apenas o controlador baseado em atenção é viável para $N \neq 20$: transferindo sem qualquer retreino a política aprendida




Figura 4: Transferência *zero-shot* no cenário Sandbox para tamanhos de enxame nunca vistos ($N \in \{10, 20, 50, 100\}$), sem retreino. O eixo vertical são as chegadas *per capita*: a descida ($3,74 \rightarrow 1,27$) reflete a partilha do mesmo nicho por mais agentes — as chegadas *totais* crescem ($37,4 \rightarrow 127,3$) e a taxa de sucesso mantém-se em 100%. Nos sete cenários da bateria o sucesso é 100% em todas as 28 combinações, com retenção *per capita* de 58–90% nos cenários com paredes. O PPO/SAC, com entrada de dimensão fixa, são incompatíveis com $N \neq 20$ e surgem como pontos isolados.

com $N = 20$ para $N \in \{10, 50, 100\}$, mantém 100% de sucesso nas **28 combinações** cenário $\times$ dimensão — a bateria cobre os sete cenários, incluindo labirintos e tarefas cooperativas, e não apenas a arena aberta (Figura 4). O padrão da eficiência *per capita* desarma a objeção natural do congestionamento: a retenção em $N = 100$ (face a $N = 20$) é mais alta nos cenários com estrutura física (Porta com Alternativa 90%, Porta Cooperativa 88%, Muro em U 78%) e mais baixa nos cenários abertos (Sandbox 39%, Percepção Cooperativa 45%), onde cem agentes partilham um recurso finito — diluição de recurso, não falha de coordenação; um colapso por congestionamento teria a assinatura inversa. Os casos intermédios matizam a leitura sem a inverter: o Quatro Salas retém 66% e o Gargalo 58% — o cenário de passagem única, onde a saturação do fluxo tem mais margem para morder —, mas mesmo aí o sucesso permanece em 100% e as chegadas totais crescem de 138,6 ($N = 20$) para 403,6 ($N = 100$). As chegadas totais no Sandbox crescem monotonicamente ($37,4 \rightarrow 65,8 \rightarrow 97,5 \rightarrow 127,3$ para $N = 10, 20, 50, 100$). As políticas de percepção multicamada do PPO/SAC têm uma entrada de dimensão fixa ($\mathbb{R}^{111}$, calibrada para $N = 20$) e são estruturalmente incompatíveis com outros tamanhos de enxame. A adaptabilidade arquitetural — a propriedade que a hipótese atribui ao MARL — manifesta-se, assim, na *representação* (grafo com atenção), e não no algoritmo de otimização.

4.7. Robustez

Sob a falha de 10% dos agentes a meio do episódio, todos os paradigmas mantêm desempenho elevado, com retenção entre 92% e 106% nas 21 combinações com desempenho de base, sem colapso. Os valores pontualmente acima de 100% correspondem a episódios em que a perda de agentes reduziu o congestionamento nas passagens estreitas. A robustez, sendo transversal aos três paradigmas, não constitui critério discriminante

entre eles: a partilha de parâmetros confere ao enxame uma redundância funcional em que nenhum agente é insubstituível.

4.8. Significância estatística

As 21 comparações par a par sobre as médias de chegadas por execução ($n = 7$ por grupo; teste U de Mann–Whitney com δ de Cliff, $\alpha = 0,05$) constam por inteiro da dissertação; resume-se aqui o que decidem. O controlador evolutivo é significativamente superior a *ambos* os métodos de gradiente em três cenários (Quatro Salas, Porta Cooperativa e Percepção Cooperativa) e superior ao SAC em mais dois (Gargalo e Porta com Alternativa), empatando com o PPO nesses dois. Os métodos de gradiente são superiores no Sandbox, onde as execuções degeneradas do evolutivo pesam ($\delta = \pm 1,00$). No Muro em U nenhuma comparação atinge significância.

5. Discussão

Em campanhas exploratórias anteriores, o controlador evolutivo colapsava em todos os cenários de estrangulamento, e a mecânica desse colapso merece registro porque é o achado metodológico deste trabalho. A neuroevolução otimiza a partir de um único escalar de aptidão por episódio, sem atribuição de crédito temporal: nunca aprende *qual* ação, em *que* instante, importou. Quando a recompensa de tarefa é esparsa, quase todos os genomas ficam a zero chegadas, a aptidão reduz-se ao termo de modelação e — na formulação inicial, saturada por uma tanh do retorno acumulado — converge para um valor comum a toda a população: um *planalto de aptidão* onde a pressão seletiva se anula.

A cura não foi mais orçamento, mas *melhor desenho da aptidão*. Substituir o retorno acumulado, farmável por deambulação, pelo *homing* terminal, que só é maximizável terminando junto ao ninho, restaurou o gradiente de seleção nos labirintos: 28/28 execuções convergentes nos quatro cenários de gargalo, com magnitudes que igualam ou superam os métodos de gradiente. O “colapso do evolutivo” era, portanto, um artefacto do desenho da aptidão, e não uma limitação intrínseca do paradigma. A ressalva é que esta sensibilidade ao desenho é, em si mesma, um custo de engenharia que os métodos de gradiente, com atribuição de crédito passo a passo, não pagam na mesma medida.

Este achado permite reconciliar um aparente desacordo com a literatura. Os trabalhos recentes que evoluem *foraging* de enxames com aptidões baseadas em retorno acumulado reportam sucesso e escalabilidade, sem qualquer sinal do colapso aqui descrito (Zaman et al., 2025; Biteng et al., 2025). A divergência não é contraditória: as suas arenas são espaços abertos com obstáculos dispersos, nos quais o termo de modelação permanece informativo em todo o percurso e o gradiente de seleção nunca se anula. O planalto de aptidão exige uma condição adicional que essas arenas não satisfazem — um estrangulamento decetivo, no qual a direção que maximiza o termo de modelação é precisamente a que não conduz ao objetivo. É essa a razão pela qual o efeito só se manifesta em cenários como o labirinto em U, e pela qual pode ter passado despercebido a

uma literatura que avalia maioritariamente em arenas abertas. A implicação prática é direta: a robustez de uma aptidão não se afere na tarefa fácil, mas na estrutura que a decompõe.

A distribuição da variância é igualmente informativa. O controlador evolutivo é quase determinístico nos labirintos com gradiente geodésico informativo (desvios de 1–2 chegadas/ep nas duas Portas), mas bimodal nos cenários abertos, onde a paisagem de aptidão oferece ótimos locais de deambulação. O SAC exhibe o padrão inverso — estável em espaço aberto, lotaria nos estrangulamentos —, sugerindo que a exploração por entropia máxima não gera com fiabilidade as trajetórias longas e coordenadas que atravessam passagens estreitas.

Daqui decorre que o valor não está em eleger um vencedor, mas em mapear os eixos de escolha: estrutura do cenário, variabilidade da dimensão do enxame e orçamento de cómputo. Em enxames de dimensão fixa e conhecida, o MARL por gradiente é preferível em espaço aberto e com pouco orçamento de treino; quando a dimensão é variável ou a missão exige escalar sem retreino, a arquitetura de grafo com atenção é a única opção viável entre as estudadas.

6. Limitações do Estudo

Quatro limitações enquadram o alcance das conclusões. Primeira, e mais importante, a comparação é *assimétrica*: o controlador evolutivo usa uma arquitetura de grafo com atenção, os *baselines* de gradiente um perceptrão de entrada fixa; isolar o efeito do otimizador exigiria treinar a mesma arquitetura por gradiente. Segunda, a replicação a $n = 28$ cobriu apenas o Muro em U: as restantes combinações mantêm sete execuções por configuração, e é aí que o poder estatístico continua a faltar — nos cenários que ficaram bimodais a $n = 7$ (Sandbox, 5/7; SAC no Gargalo, 5/7), distinguir taxas de convergência exige uma bateria maior. Terceira, a composição de dificuldades foi medida num *único* mapa (Secção 4.5): o que dele se conclui delimita o alcance destes controladores nesta composição e não em qualquer outra, e a contagem de execuções que o resolvem é reportada como descritiva, por compromisso fixado antes dos dados. Quarta, todos os resultados são em simulação, com o *reality gap* por medir (Tobin et al., 2017). Nenhuma invalida os achados centrais — a dependência da neuroevolução face ao desenho da aptidão e o contraste de escalabilidade são estatisticamente suportados — mas delimitam-nos.

7. Conclusões

Comparámos um controlador de atenção neuroevoluído com o PPO e o SAC na navegação cooperativa tridimensional até ao ninho, em sete cenários e três eixos, com sete execuções independentes por combinação e significância aferida ao nível da execução. A hipótese de que a inteligência adaptativa domina a robustez estática é apenas parcialmente confirmada. Com o desenho adequado da aptidão, o controlador evolutivo é superior aos métodos de gradiente em três dos sete cenários, indistinguível do melhor deles em mais dois, e é o único a escalar *zero-shot* até $N = 100$; os métodos de gradiente preservam a fiabilidade em espaço aberto e $\approx 8\times$ de vantagem em

núcleos-hora. A decepção espacial, que nenhum paradigma base resolveu, cedeu à procura por novidade doseada adaptativamente — 28/28 execuções contra 15/28 na replicação a $n = 28$ (Fisher exato, $p < 0,0001$) —, mas o mesmo movimento delimita a conclusão: sem essa dosagem, o evolutivo é indistinguível do PPO ($p = 0,088$). O que a evidência sustenta não é a superioridade de um paradigma de otimização, mas a de um *mecanismo* — a exploração doseada ao longo do treino — em princípio transponível para qualquer um deles. Um oitavo cenário, que compõe quatro destas dificuldades, delimita o alcance de tudo isto: sem retreino nada transfere e, com treino nativo, só o evolutivo o resolve — em 4 de 21 execuções, abaixo do limiar pré-registado. Como trabalho futuro ficam uma política de atenção treinada por gradiente, que separaria o otimizador da arquitetura, o alargamento da bateria aos restantes cenários bimodais, o re-armamento do *schedule* adaptativo sob estagnação e a validação simulação-para-real (Tobin et al., 2017).

Agradecimentos

This work was partially supported by national funds through Fundação para a Ciência e a Tecnologia, I.P. (FCT), ISTAR-Iscte Pluriannual Projects UID/04466/2025 (<https://doi.org/10.54499/UID/04466/2025>).

Referências

- Bettini, M., Prorok, A., Moens, V., 2024. Benchmark: Benchmarking multi-agent reinforcement learning. *Journal of Machine Learning Research* 25, 1–10.
- Biteng, P., Zaman, T.U., Lu, Q., 2025. Training robot swarms for adaptive foraging in environments with obstacles, in: *IEEE International Conference on Mechatronics and Automation (ICMA)*, IEEE. doi:10.1109/ICMA65362.2025.11120654.
- Bredecche, N., Fontbonne, N., 2022. Social learning in swarm robotics. *Philosophical Transactions of the Royal Society B: Biological Sciences* 377, 20200309. doi:10.1098/rstb.2020.0309.
- Chen, X., NaderiAlizadeh, N., Ribeiro, A., Saeedi Bidokhti, S., 2024. Transferable graphical marl for real-time estimation in dynamic wireless networks. *arXiv preprint arXiv:2404.03227*.
- Fontbonne, N., Dauchot, O., Bredecche, N., 2020. Distributed on-line learning in swarm robotics with limited communication bandwidth, in: *IEEE Congress on Evolutionary Computation (CEC)*, IEEE. doi:10.1109/CEC48606.2020.9185697.
- Haarnoja, T., Zhou, A., Abbeel, P., Levine, S., 2018. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor, in: *Proceedings of the 35th International Conference on Machine Learning (ICML)*, pp. 1861–1870.
- Hasselmann, K., Ligt, A., Birattari, M., 2023. Automatic modular design of robot swarms based on repertoires of behaviors generated via novelty search. *Swarm and Evolutionary Computation* 83, 101395. doi:10.1016/j.swevo.2023.101395.
- Huh, D., Mohapatra, P., 2023. Multi-agent reinforcement learning: A comprehensive survey. *arXiv preprint arXiv:2312.10256*.
- Hüttenrauch, M., Šošić, A., Neumann, G., 2019. Deep reinforcement learning for swarm systems. *Journal of Machine Learning Research* 20, 1–31.
- Iskandar, A., Hammoud, A., Kovács, B., 2024. Swarm robotics navigation task: A comparative study of reinforcement learning and particle swarm optimization methodologies. *Mekhatronika, Automatizatsiya, Upravlenie* 25, 471–478. doi:10.17587/mau.25.471-478.
- Iskandar, A., Rostum, H., Kovács, B., 2023. Using deep reinforcement learning to solve a navigation problem for a swarm robotics system, in: *2023 24th International Carpathian Control Conference (ICCC)*, IEEE. pp. 185–189.
- Kegeleirs, M., Ramos, D.G., Hasselmann, K., Garattoni, L., Francesca, G., Birattari, M., 2024. Transferability in the automatic off-line design of robot swarms: From sim-to-real to embodiment and design-method transfer across different platforms. *IEEE Robotics and Automation Letters* 9, 2758–2765. doi:10.1109/LRA.2024.3360013.
- Kennedy, J., Eberhart, R., 1995. Particle swarm optimization, in: *Proceedings of ICNN'95 - International Conference on Neural Networks*, IEEE. pp. 1942–1948.
- Lehman, J., Stanley, K.O., 2011. Abandoning objectives: Evolution through the search for novelty alone. *Evolutionary Computation* 19, 189–223. doi:10.1162/EVC0_a_00025.
- Li, X., Zhou, R., Sun, G., 2024. Adaptive shape formation against swarm-scale variants in robot swarms. *IEEE Robotics and Automation Letters* 9. doi:10.1109/LRA.2024.3414210.
- Lowe, R., Wu, Y., Tamar, A., Harb, J., Abbeel, P., Mordatch, I., 2017. Multi-agent actor-critic for mixed cooperative-competitive environments, in: *Advances in Neural Information Processing Systems (NeurIPS)*.
- Majid, A.Y., Saaybi, S., Francois-Lavet, V., Prasad, R.V., Verhoeven, C., 2024. Deep reinforcement learning versus evolution strategies: A comparative survey. *IEEE Transactions on Neural Networks and Learning Systems* 35, 11939–11957. doi:10.1109/TNNLS.2023.3264540.
- Ng, A.Y., Harada, D., Russell, S., 1999. Policy invariance under reward transformations: Theory and application to reward shaping, in: *Proceedings of the 16th International Conference on Machine Learning (ICML)*, pp. 278–287.
- Oliehoek, F.A., Amato, C., 2016. *A Concise Introduction to Decentralized POMDPs*. Springer.
- Ordáz-Rivas, E., Rodríguez-Liñán, A., Torres-Treviño, L., 2026. Multi-objective optimization in autonomous foraging using swarm robots. *Swarm and Evolutionary Computation* 101, 102294. doi:10.1016/j.swevo.2026.102294.
- Salimans, T., Ho, J., Chen, X., Sidor, S., Sutskever, I., 2017. Evolution strategies as a scalable alternative to reinforcement learning. *arXiv preprint arXiv:1703.03864*.
- Schulman, J., Moritz, P., Levine, S., Jordan, M.I., Abbeel, P., 2016. High-dimensional continuous control using generalized advantage estimation, in: *International Conference on Learning Representations (ICLR)*.
- Schulman, J., Wolski, F., Dhariwal, P., Radford, A., Klimov, O., 2017. Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*.
- Such, F.P., Madhavan, V., Conti, E., Lehman, J., Stanley, K.O., Clune, J., 2017. Deep neuroevolution: Genetic algorithms are a competitive alternative for training deep neural networks for reinforcement learning. *arXiv preprint arXiv:1712.06567*.
- Szpirer, J., Ramos, D.G., Birattari, M., 2024. Automatic design of robot swarms that perform composite missions: an approach based on inverse reinforcement learning, in: *IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, IEEE. doi:10.1109/IROS58592.2024.10801506.
- Tang, H., Zhang, H., Shi, Z., Chen, X., Ding, W., Zhang, X.P., 2023. Autonomous swarm robot coordination via mean-field control embedding multi-agent reinforcement learning, in: *IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, IEEE. doi:10.1109/IROS55552.2023.10341749.
- Tobin, J., Fong, R., Ray, A., Schneider, J., Zaremba, W., Abbeel, P., 2017. Domain randomization for transferring deep neural networks from simulation to the real world, in: *IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, IEEE. pp. 23–30.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A.N., Kaiser, L., Polosukhin, I., 2017. Attention is all you need, in: *Advances in Neural Information Processing Systems (NeurIPS)*.
- Veličković, P., Cucurull, G., Casanova, A., Romero, A., Liò, P., Bengio, Y., 2018. Graph attention networks, in: *International Conference on Learning Representations (ICLR)*.
- Zaman, T.U., Biteng, P., Lu, Q., 2025. Evolving adaptive foraging robot swarms with NEAT in environments with obstacles, in: *8th International Conference on Intelligent Robotics and Control Engineering (IRCE)*, IEEE. doi:10.1109/IRCE66030.2025.11203043.
- Zhang, H., Cheng, J., Zhang, L., Li, Y., Zhang, W., 2022. H2GNN: Hierarchical-hops graph neural networks for multi-robot exploration in unknown environments. *IEEE Robotics and Automation Letters* 7, 3435–3442. doi:10.1109/LRA.2022.3146912.