

Aprendizagem Adaptativa *versus* Robustez Estática: Comparação de Aprendizagem por Reforço e Neuroevolução para Controlo de Enxames

Gonçalo Pombo^a, Luís Nunes^a

^aInstituto Universitário de Lisboa (ISCTE-IUL), ISTAR, Lisboa, Portugal

Abstract

O controlo de enxames robóticos é abordado por duas comunidades que raramente se encontram num referencial comum: a aprendizagem por reforço multiagente (MARL), que promete adaptabilidade *em linha*, e a otimização bio-inspirada, que oferece robustez pré-programada. Este trabalho apresenta uma comparação controlada e independente do paradigma entre três controladores — uma rede de grafo neuroevoluída com atenção sobre os vizinhos, *Proximal Policy Optimisation* (PPO) e *Soft Actor-Critic* (SAC) — no mesmo simulador tridimensional de *foraging* de alta fidelidade, em sete cenários de dificuldade crescente, com sete execuções de treino independentes por combinação, sob avaliação determinística emparelhada e testes não paramétricos ao nível da execução. O resultado central é que o desempenho do controlador evolutivo depende menos do orçamento de treino do que do *desenho da função de aptidão*: substituindo o retorno acumulado — que é farmável por deambulação — por um *shaping* de *homing* terminal, o controlador converge nas 28 execuções dos quatro labirintos não-decetivos e torna-se estatisticamente superior aos métodos de gradiente em três cenários, indistinguível do melhor deles em mais dois. Os métodos de gradiente conservam duas vantagens sólidas: fiabilidade em espaço aberto, onde o evolutivo ocasionalmente degenera, e uma eficiência computacional cerca de 8× superior. Sob escalabilidade *zero-shot*, apenas o controlador baseado em atenção transita de $N = 10$ para $N = 100$ agentes sem retreino, mantendo 100% de sucesso. A hipótese de que a inteligência adaptativa domina a robustez estática é, por isso, apenas *parcialmente* confirmada: a vantagem decisiva reside na *representação* e no desenho do sinal de treino, e não no algoritmo de otimização.

Keywords: robótica de enxames, aprendizagem por reforço multiagente, neuroevolução, escalabilidade zero-shot, redes neuronais de grafos, avaliação comparativa

1. Introdução

Os enxames robóticos prometem soluções escaláveis e resilientes para tarefas como busca e salvamento, monitorização ambiental e logística distribuída. A questão central de engenharia é qual o paradigma de controlo que melhor mantém a operacionalidade sob incerteza. Duas escolas dominam. A *otimização bio-inspirada* (por exemplo, algoritmos evolutivos e otimização por enxame de partículas) procura num espaço global de parâmetros, *fora de linha*, controladores robustos e estáticos (Kennedy and Eberhart, 1995). A *aprendizagem por reforço multiagente* (MARL) aprende, em alternativa, políticas adaptativas *em linha* através da interação (Huh and Mohapatra, 2023). Apesar do extenso trabalho em cada uma, as comparações diretas e rigorosas entre paradigmas permanecem escassas (Majid et al., 2024; Bettini et al., 2024): os estudos costumam refinar um único algoritmo contra variantes da sua própria família, descurando as referências cruzadas entre paradigmas.

Controlar um enxame é difícil por três razões que se reforçam. O espaço de ações conjuntas cresce exponencialmente com o número de agentes, tornando inviável tratar o enxame como um único agente monolítico; a recompensa de tarefa é tipicamente esparsa e diferida, o que agrava a atribuição de crédito; e cada agente decide a partir de uma observação parcial e

local, sem acesso ao estado global. Os dois paradigmas respondem a estas dificuldades de formas opostas — a MARL aprende uma política partilhada que generaliza por experiência, a otimização bio-inspirada procura um controlador robusto num só esforço de otimização — e é precisamente essa oposição que motiva uma comparação direta e controlada.

A questão de investigação que orienta a dissertação é, em rigor, se a *inteligência adaptativa* (uma política de MARL que aprende com a experiência) supera a *robustez estática* (um controlador otimizado de uma só vez e depois congelado) em cenários de *stress* dinâmico. Responder a esta questão exige um referencial em que ambos os paradigmas sejam avaliados nas mesmas condições, com as mesmas métricas e a mesma análise estatística — algo que a literatura raramente oferece.

Este artigo aborda essa lacuna com uma avaliação comparativa imparcial. Implementámos um simulador tridimensional de *foraging* de alta fidelidade e avaliamos três controladores — uma rede de grafo neuroevoluída com auto-atenção sobre os vizinhos, PPO e SAC — em sete cenários e ao longo de três eixos: desempenho na tarefa (P_{task}), robustez a falhas de agentes (R_{robust}) e escalabilidade *zero-shot* (S_{scale}). Cada combinação (algoritmo, cenário) foi treinada em sete execuções independentes, o que permite tratar a *execução de treino* — e não o episódio — como unidade estatística, distinguindo o desempenho atingível da fiabilidade da convergência.

A nossa contribuição é tripla: (i) um protocolo de avaliação reprodutível e independente do paradigma, com significância aferida ao nível da execução; (ii) a demonstração de que o alegado colapso da neuroevolução em cenários de estrangulamento é um artefacto do *desenho da aptidão*, e não uma limitação intrínseca do paradigma, corrigível por um *shaping* de *homing* terminal não farmável; e (iii) a evidência de que a escalabilidade *zero-shot* é uma propriedade da representação (grafo com atenção), e não do otimizador. Uma versão preliminar deste trabalho, com um orçamento de treino mais curto e uma aptidão baseada no retorno acumulado, levava à conclusão oposta sobre o paradigma evolutivo — circunstância que ilustra a importância metodológica do segundo contributo. A metodologia e os resultados completos são detalhados na dissertação que acompanha este artigo.

2. Trabalho Relacionado

A aprendizagem por reforço profunda tem sido aplicada a sistemas de enxame com partilha de parâmetros para domar a explosão do espaço de ações conjuntas (Hüttenrauch et al., 2019), em que uma única rede é partilhada por todos os agentes homogêneos. As redes neuronais de grafos (GNN) emergiram como o principal viabilizador da escalabilidade: ao modelar o enxame como um grafo e ao aplicar atenção sobre os vizinhos, uma política treinada com poucos agentes pode ser implantada com muitos (Chen et al., 2024). O mecanismo de atenção (Vaswani et al., 2017; Veličković et al., 2018) é central nesta propriedade, por ser invariante à permutação e à cardinalidade do conjunto de vizinhos. Os controlos de enxames baseados em grafos têm-se multiplicado, com aplicações que vão da estimação distribuída em redes dinâmicas (Chen et al., 2024) ao controlo descentralizado de formação (Schmickl et al., 2025; Elrod et al., 2025), e revisões recentes consolidam a GNN como o substrato dominante para a escalabilidade em enxames (Ekechi et al., 2025).

No paradigma de aprendizagem, o esquema de treino centralizado com execução descentralizada (CTDE) tornou-se padrão para domar a não-estacionariedade do ambiente multiagente (Lowe et al., 2017; Oliehoek and Amato, 2016). No presente trabalho, contudo, os *baselines* de gradiente partilham uma única política e executam a partir da observação puramente local, sem um crítico de estado global, o que mantém a comparação ancorada num regime descentralizado comum aos três controladores.

Do lado bio-inspirado, a neuroevolução otimiza os pesos da rede sem gradientes (Salimans et al., 2017), oferecendo controladores estáveis para tarefas estáticas, mas com adaptabilidade *em linha* limitada (Kegeleirs and Birattari, 2025). As estratégias de evolução são atrativas pela simplicidade e pela paralelização trivial, mas otimizam a partir de um único escalar de aptidão por episódio, sem atribuição de crédito temporal — uma distinção que se revelará decisiva. Quando a recompensa de tarefa é esparsa, a aptidão fica refém do termo de modelação, e a escolha desse termo determina se a seleção discrimina ou fica cega. A procura por novidade (Lehman and Stanley, 2011) propõe abandonar por completo o objetivo, selecionando comportamentos

pela sua raridade — uma resposta ao mesmo problema de decação que aqui abordamos por via do desenho da aptidão.

Os estudos comparativos entre aprendizagem por reforço profunda e estratégias de evolução salientam a ausência de uma referência de desempenho comum entre as duas famílias (Majid et al., 2024), enquanto os referenciais padronizados de MARL permanecem focados dentro da comunidade de aprendizagem (Bettini et al., 2024). As aplicações de aprendizagem por reforço profunda à navegação de enxames (Iskandar et al., 2023) ilustram o tipo de estudo de paradigma único que este trabalho estende, com uma comparação sistemática e estatisticamente fundamentada contra a alternativa bio-inspirada.

3. Metodologia

3.1. Ambiente de simulação

O ambiente é uma tarefa de *foraging* contínua e tridimensional, numa arena circular (raio 15 m) com $N = 20$ agentes homogêneos que devem recolher comida e transportá-la para um ninho. Utilizam-se sete cenários de dificuldade crescente: um *Sandbox* aberto; três labirintos de navegação (*Muro em U*, *Gargalo*, *Quatro Salas*); duas tarefas cooperativas (*Porta Cooperativa*, que exige ≥ 3 agentes para abrir uma passagem, e *Perceção Cooperativa*, com um alvo móvel); e um cenário *deceptive*, a *Porta Cooperativa com Alternativa*, em que a porta bloqueada atrai o gradiente de navegação enquanto o único caminho viável é um corredor lateral que obriga a afastar-se temporariamente do ninho. A Figura 1 ilustra os sete cenários. Cada agente observa uma bússola de *homing* egocêntrica para o ninho, oito raios LiDAR para deteção local de obstáculos e o estado relativo dos vizinhos — um cenário parcialmente observável, formalizável como um Dec-POMDP (Oliehoek and Amato, 2016). A bússola fornece a direção e a distância euclidiana ao ninho de forma sempre disponível (à imagem do *homing* global em formigas ou da navegação por GPS), ao passo que os obstáculos só são percecionados localmente pelo LiDAR de 8 m, preservando uma observabilidade parcial genuína.

Para evitar mínimos locais nos cenários de labirinto, a recompensa de progresso usa um potencial *geodésico* calculado pelo algoritmo de Dijkstra sobre uma grelha de ocupação dilatada, atuando como modelação de recompensa baseada em potencial (Ng et al., 1999) que não altera a política ótima e é usada apenas como sinal de treino, nunca como observação. A Figura 2 contrasta o potencial euclidiano ingênuo — que “atravessa” a parede e cria um mínimo local que cola os agentes ao obstáculo — com o campo geodésico, cujo gradiente premeia corretamente o contorno da barra. Esta distinção é essencial para a leitura dos resultados: o sinal de treino aponta sempre para o desvio correto, pelo que as dificuldades observadas no Muro em U são de *descoberta*, não de modelação da recompensa.

3.2. Espaço de observação, de ação e recompensa

A observação de cada agente é um vetor egocêntrico que reúne a bússola de *homing* (direção e distância ao ninho), os oito raios LiDAR e o estado relativo dos $N - 1$ vizinhos; manter o vizinho como uma entidade explícita é o que permite à GNN atender sobre um conjunto de cardinalidade variável. O espaço de




Figura 1: Os sete cenários de avaliação, renderizados a partir da geometria real do simulador. Em cima: Sandbox (aberto, com obstáculos esféricos), Muro em U, Gargalo e Quatro Salas. Em baixo: Porta Cooperativa (passagem a âmbar, abre com ≥ 3 agentes), Percepção Cooperativa (alvo móvel) e Porta Cooperativa com Alternativa (cenário *deceptive*: a porta atrai, o corredor lateral resolve). O ninho é a esfera verde.




Figura 2: Potencial de recompensa no Muro em U: a distância euclidiana (esquerda) atravessa a parede e induz um mínimo local; o campo geodésico (direita), calculado por Dijkstra sobre a grelha com obstáculos dilatados, premeia o contorno e elimina a armadilha. É um sinal de treino, não uma observação.

ação é discreto e egocêntrico: três translações (frente/recuo, esquerda/direita, cima/baixo) de passo fixo 0.2 m, resolvidas por uma ordem determinística de *step* que aplica deslizamento ao longo das paredes (*wall-sliding*) em caso de colisão, evitando que o agente fique imobilizado num canto.

A recompensa foi deliberadamente *simplificada* face a iterações anteriores, e reduz-se a quatro termos: (i) uma recompensa de tarefa de +300 por recolha, repetível ao longo do episódio e claramente dominante; (ii) o progresso geodésico descrito acima, com fator 10 (Ng et al., 1999); (iii) um bônus de exploração baseado em contagem (+0.5 por célula nova de 2×2 m), pequeno de propósito; e (iv) um custo energético de -0.05 por passo, que impõe pressão temporal. As penalizações secundárias de dispersão e de colisão foram anuladas no *sinal de recompensa* (a física de colisão e separação mantém-se), depois de se verificar que competiam com a tarefa sem benefício mensurável. O número de agentes exigidos em simultâneo no ninho

é definido por cenário: $k_{\min} = 3$ nos cenários em que a cooperação é o objeto de estudo, e $k_{\min} = 1$ nos labirintos de navegação pura, onde exigir três agentes converteria um problema de navegação numa cooperação artificial. Uma calibração anterior, com um bônus de exploração maior, produziu *exploração da recompensa*: a política aprendia a deambular a colher exploração em vez de convergir para a recolha.

3.3. Controladores

O *controlador evolutivo* (GNN) é uma rede compacta que codifica as características egocêntricas e aplica auto-atenção de produto escalar normalizado sobre o conjunto de vizinhos (Vaswani et al., 2017), produzindo uma ação invariante ao número de vizinhos. Os seus pesos são otimizados por uma estratégia de evolução com truncatura e elitismo (população $K = 30$, $e = 6$ elites preservados, mutação gaussiana esparsa com σ inicial 0.1, decaimento 0.999 e piso $\sigma_{\min} = 0.03$), guiada por uma aptidão em que a tarefa domina a seleção:

$$J(\theta_k) = \bar{f}_k \cdot \lambda_{\text{task}} + \beta \cdot \bar{h}_k, \quad \lambda_{\text{task}} = 10^4, \beta = 5000, \quad (1)$$

onde $\bar{f}_k$ é a média de comida recolhida e $\bar{h}_k \in [0, 1]$ é o *homing*: a fração média de aproximação ao ninho *no final* do episódio, medida por agente como $\text{clip}((\Phi_0 - \Phi_T)/\Phi_0, 0, 1)$, com Φ o potencial de navegação (geodésico nos cenários com paredes). As médias são tomadas sobre $E = 4$ episódios com sementes fixas.

A escolha de $\bar{h}$ é a decisão de desenho central deste trabalho. Numa formulação anterior, o termo de desempate era o retorno acumulado comprimido por uma *tanh*; mas o retorno acumulado é *farmável*, porque o progresso e a exploração rendem a cada passo: observaram-se genomas com retorno bruto $\approx 88\,000$ e *zero* recolhas, que deambulavam indefinidamente porque parar no ninho — a pré-condição da tarefa — corta o

rendimento por passo. O *homing* terminal elimina a patologia por construção: depende apenas dos estados extremos do episódio, não do caminho, pelo que deambular não o aumenta, e a única forma de o maximizar é *terminar* junto ao ninho. Como uma única recolha (10^4) vale o dobro do *shaping* máximo (5000), a tarefa domina a seleção assim que um genoma recolhe.

Os *baselines de aprendizagem* são o PPO (Schulman et al., 2017) e o SAC (Haarnoja et al., 2018) da biblioteca Stable-Baselines3, com uma política de percepção multicamada partilhada ([256, 256]) sobre a observação densa da vizinhança (partilha de parâmetros). O mecanismo de atenção sobre o grafo é, assim, instanciado apenas no controlador evolutivo, o que é precisamente o que viabiliza a sua transferência *zero-shot*. O PPO usa estimação de vantagem generalizada (Schulman et al., 2016) e o SAC, fora de política, regulariza por entropia; ambos são treinados sobre ambientes vetorizados em paralelo (*SubprocVecEnv*), com a mesma política a recolher experiência de todos os agentes do enxame, e o controlador evolutivo avalia a sua população também em paralelo.

3.4. Protocolo de avaliação

Cada combinação (algoritmo, cenário) foi treinada em **sete execuções independentes** com sementes distintas, perfazendo $3 \times 7 \times 7 = 147$ treinos numa campanha contínua de sete dias. Cada execução do controlador evolutivo dispôs de 195 minutos sobre ≈ 30 núcleos, e cada execução de PPO/SAC de 48 minutos sobre 16 núcleos; todos os regimes atingem o planalto de aprendizagem, pelo que a comparação mede o *desempenho atingível*, embora os métodos de gradiente conservem uma vantagem de $\approx 8\times$ em núcleos-hora.

Cada modelo é depois avaliado deterministicamente em 20 episódios com sementes emparelhadas entre algoritmos, totalizando 140 episódios por célula. Reportamos P_{task} (taxa de sucesso, com sucesso definido como pelo menos um item recolhido) e a média de comida recolhida por episódio, que é a métrica de magnitude comparável entre paradigmas. A robustez (R_{robust}) injeta a falha de 10% dos agentes a meio do episódio; a escalabilidade (S_{scale}) testa $N \in \{10, 20, 50, 100\}$ sem retreino.

Um ponto metodológico merece ênfase: as diferenças par a par são avaliadas sobre as **médias por execução** ($n = 7$ por grupo), com o teste U de Mann–Whitney e o δ de Cliff como tamanho de efeito, a $\alpha = 0.05$. A unidade estatística independente é a execução de treino, e não o episódio — tratar os 140 episódios como observações independentes inflacionaria artificialmente o poder do teste, pois episódios da mesma execução partilham o mesmo controlador.

4. Resultados

4.1. Desempenho na tarefa

A Tabela 1 reporta a comida recolhida por episódio, a taxa de sucesso e o número de execuções plenamente convergentes. Esta última coluna é essencial: uma taxa de sucesso média intermédia quase nunca significa “resolve o cenário metade das




Figura 3: Comida recolhida por episódio (média $\pm$ desvio-padrão) por cenário e controlador. As barras de erro largas do controlador evolutivo no Sandbox e no Muro em U refletem bimodalidade entre execuções, não ruído de avaliação.

vezes”, mas sim que *algumas execuções resolvem-no integralmente e outras falham por completo*. Quinze das vinte e uma combinações algoritmo–cenário atingem 100% de sucesso em todas as execuções; as seis restantes escondem, sem exceção, esta distribuição tudo-ou-nada.

O quadro que emerge não tem um vencedor universal. O **controlador evolutivo** resolve os quatro cenários de gargalo não-decetivos nas 28 execuções correspondentes, destacando-se no Gargalo (121.4 recolhas/ep), no Quatro Salas (59.8, cerca de $1.8\times$ o melhor método de gradiente) e na Porta Cooperativa com Alternativa (86.7); mas exhibe execuções degeneradas precisamente nos cenários *sem paredes* (Sandbox, 5/7; Percepção Cooperativa, 6/7), onde a paisagem de aptidão oferece ótimos locais de deambulação. O **PPO** é o mais consistente, com 100% de sucesso em seis dos sete cenários e a menor variância entre execuções. O **SAC** é fiável em espaço aberto e nos cooperativos, mas o mais frágil nos estrangulamentos físicos: no Gargalo apenas 5/7 execuções convergem, com magnitude muito dispersa (41.4 ± 36.8).


4.2. O Muro em U e a bimodalidade entre execuções

O Muro em U é o único cenário que *nenhum* algoritmo resolve de forma fiável, e a sua análise ilustra por que razão a unidade estatística importa. O desempenho é bimodal nos três paradigmas: cada execução ou aprende o desvio ao beco e atinge 100% de sucesso, ou não o aprende de todo (GNN 3/7, PPO 4/7, SAC 2/7). A Figura 4 mostra a distribuição por execução. Nenhuma diferença entre algoritmos atinge significância, e a conclusão honesta é que sete execuções não bastam para distinguir taxas de convergência de 2/7 a 4/7.

O obstáculo não está no sinal de treino — o potencial geodésico aponta corretamente para o contorno (Figura 2) — mas na *descoberta*: o agente observa apenas a bússola de *homing* euclidiana e o LiDAR local, pelo que percorrer o desvio exige uma trajetória longa que se afasta, durante dezenas de passos, da única direção que o agente percebe como sendo o ninho. Nenhum dos mecanismos de exploração estudados (entropia, *clipped surrogate*, mutação gaussiana) garante essa descoberta.

Tabela 1: Desempenho sob avaliação determinística (7 execuções de treino independentes $\times$ 20 episódios com sementes emparelhadas por cenário): média $\pm$ desvio-padrão da comida recolhida por episódio *entre execuções*, taxa de sucesso média entre parênteses, e número de execuções que atingem 100% de sucesso. A comida recolhida é a métrica de magnitude comparada entre paradigmas; a taxa de sucesso, isolada, é um indicador fraco, pois um agente atinge 100% recolhendo um único item. Melhor média por linha a negrito.

Cenário	GNN	PPO	SAC
Sandbox	38.3 $\pm$ 31.0 (86%) [5/7]	71.5 $\pm$ 1.0 (100%) [7/7]	69.2 $\pm$ 1.9 (100%) [7/7]
Muro em U	24.5 $\pm$ 32.7 (43%) [3/7]	39.6 $\pm$ 36.7 (71%) [4/7]	9.0 $\pm$ 15.1 (34%) [2/7]
Gargalo	121.4 $\pm$ 20.0 (100%) [7/7]	123.2 $\pm$ 1.2 (100%) [7/7]	41.4 $\pm$ 36.8 (72%) [5/7]
Quatro Salas	59.8 $\pm$ 13.2 (100%) [7/7]	33.6 $\pm$ 3.8 (100%) [7/7]	31.8 $\pm$ 3.3 (100%) [7/7]
Porta Cooperativa	69.8 $\pm$ 1.0 (100%) [7/7]	67.1 $\pm$ 3.7 (100%) [7/7]	62.1 $\pm$ 2.5 (100%) [7/7]
Percepção Cooperativa	19.0 $\pm$ 8.7 (91%) [6/7]	15.3 $\pm$ 0.4 (100%) [7/7]	16.1 $\pm$ 0.8 (100%) [7/7]
Porta c/ Alternativa	86.7 $\pm$ 2.0 (100%) [7/7]	85.3 $\pm$ 4.0 (100%) [7/7]	68.6 $\pm$ 3.4 (100%) [7/7]



Cada ponto = 1 run independente (7 runs/algoritmo; média de 20 episódios determinísticos). Métrica de tarefa: mesma unidade para os três algoritmos.

Figura 4: Distribuição das recolhas por episódio no Muro em U, agregando as sete execuções de cada controlador. A dispersão não é ruído de avaliação: reflete execuções de treino que resolvem integralmente o cenário e execuções que falham por completo.

4.3. Deceção e procura por novidade

A Porta Cooperativa com Alternativa foi desenhada como armadilha *deceptive*: o gradiente de *homing* aponta para a porta bloqueada e o caminho viável exige afastamento temporário do ninho. Numa experiência controlada anterior à campanha final, um controlador com *blend* de novidade (Lehman and Stanley, 2011) ($w = 0.5$, 600 minutos) obteve 81.3 ± 1.9 recolhas/ep contra 64.5 do melhor controlador puramente objetivo então disponível — +26%, com Wilcoxon emparelhado $p = 8.7 \times 10^{-5}$ e δ de Cliff = +1.00. A ressalva é que essa execução dispôs de um orçamento $\approx 3\times$ superior, pelo que o resultado mede o efeito conjunto de novidade e orçamento.

A campanha final matiza a conclusão: com o orçamento normal, a própria aptidão de *homing* resolve o cenário de forma consistente (7/7 execuções a 100%, 86.7 ± 2.0 recolhas/ep), acima inclusive do resultado com novidade. A pressão por novidade *consolidou* a fuga ao ótimo local num regime em que a otimização objetiva só o conseguia de forma inconsistente, mas não é condição *necessária* no cenário estudado: dada profundidade de treino suficiente, o *shaping* de *homing* encontra o corredor alternativo de forma fiável. O contributo da novidade fica assim circunscrito a regimes de orçamento curto ou




Figura 5: Transferência *zero-shot* para tamanhos de enxame nunca vistos ($N \in \{10, 20, 50, 100\}$), sem retreino. O eixo vertical é a recolha *per capita*: a sua descida ($3.82 \rightarrow 1.36$) reflete a partilha de um recurso finito por mais agentes — as recolhas *totais* crescem ($38.2 \rightarrow 136.3$) e a taxa de sucesso mantém-se em 100% em todas as dimensões. O PPO/SAC, com entrada de dimensão fixa, são incompatíveis com $N \neq 20$ e surgem como pontos isolados.

de deceção mais severa.

4.4. Escalabilidade zero-shot

Apenas o controlador baseado em atenção é viável para $N \neq 20$: transferindo sem qualquer retreino a política aprendida com $N = 20$, mantém 100% de sucesso em todas as dimensões testadas, e as recolhas totais crescem monotonicamente ($38.2 \rightarrow 63.0 \rightarrow 98.5 \rightarrow 136.3$ para $N = 10, 20, 50, 100$), sem colapso de coordenação por congestionamento (Figura 5). A recolha *per capita* diminui, refletindo a partilha de um recurso finito por mais agentes, e não uma falha do controlador. As políticas de percepção multicamada do PPO/SAC têm uma entrada de dimensão fixa ($\mathbb{R}^{111}$, calibrada para $N = 20$) e são estruturalmente incompatíveis com outros tamanhos de enxame. A adaptabilidade arquitetural — a propriedade que a hipótese atribui ao MARL — manifesta-se, assim, na *representação* (grafo com atenção), e não no algoritmo de otimização.

4.5. Robustez

Sob a falha de 10% dos agentes a meio do episódio, todos os paradigmas mantêm desempenho elevado, com retenção entre 92% e 106% em todas as combinações com desempenho de base, sem colapso (Figura 6). Os valores pontualmente acima




Figura 6: Retenção de desempenho sob falha de 10% dos agentes a meio do episódio, relativa à execução nominal. Nenhum paradigma colapsa; a redundância emerge da partilha de parâmetros e da observação puramente local.

de 100% correspondem a episódios em que a perda de agentes reduziu o congestionamento nas passagens estreitas. A robustez, sendo transversal aos três paradigmas, não constitui critério discriminante entre eles: a partilha de parâmetros e a observação local conferem ao enxame uma redundância funcional em que nenhum agente é insubstituível.

4.6. Significância estatística

A Tabela 2 apresenta as 21 comparações par a par sobre as médias de recolhas por execução ($n = 7$ por grupo). O controlador evolutivo é significativamente superior a *ambos* os métodos de gradiente em três cenários (Quatro Salas, Porta Cooperativa e Percepção Cooperativa) e superior ao SAC em mais dois (Gargalo e Porta com Alternativa), empatando com o PPO nesses dois. Os métodos de gradiente são superiores no Sandbox, onde as execuções degeneradas do evolutivo pesam ($\delta = \pm 1.00$). No Muro em U nenhuma comparação atinge significância.

5. Discussão

Em campanhas exploratórias anteriores, o controlador evolutivo colapsava em todos os cenários de estrangulamento, e a mecânica desse colapso merece registo porque é o achado metodológico deste trabalho. A neuroevolução otimiza a partir de um único escalar de aptidão por episódio, sem atribuição de crédito temporal: nunca aprende *qual* ação, em *que* instante, importou. Quando a recompensa de tarefa é esparsa, quase todos os genomas recolhem zero, a aptidão reduz-se ao termo de modelação e — na formulação inicial, saturada por uma tanh do retorno acumulado — converge para um valor comum a toda a população: um *planalto de aptidão* onde a pressão seletiva se anula.

A cura não foi mais orçamento, mas *melhor desenho da aptidão*. Substituir o retorno acumulado, farmável por deambulação, pelo *homing* terminal, que só é maximizável terminando junto ao ninho, restaurou o gradiente de seleção nos labirintos: 28/28 execuções convergentes nos quatro cenários de gargalo não-decetivos, com magnitudes que igualam ou superam os métodos de gradiente. O “colapso do evolutivo” era, portanto, um artefacto do desenho da aptidão, e não uma limitação intrínseca do paradigma. A ressalva é que esta sensibilidade ao desenho é, em si mesma, um custo de engenharia que os métodos de gradiente, com atribuição de crédito passo a passo, não pagam na mesma medida.

A distribuição da variância pelos cenários é igualmente informativa. O controlador evolutivo é quase determinístico nos labirintos com gradiente geodésico informativo (desvios de 1–2 recolhas/ep nas duas Portas), mas bimodal nos cenários abertos: sem paredes que canalizem o *homing*, a paisagem de aptidão oferece ótimos locais de deambulação dos quais algumas execuções não escapam. O SAC exhibe o padrão inverso — estável em espaço aberto, lotaria nos estrangulamentos físicos —, sugerindo que a exploração por entropia máxima, eficaz em espaço aberto, não gera com fiabilidade as trajetórias longas e coordenadas que atravessam passagens estreitas.

Decorrem duas implicações de engenharia. Primeira, a comparação combina dois fatores — algoritmo de otimização e arquitetura de rede — pelo que integrar o módulo de atenção numa política treinada por gradiente é o passo natural para isolar o efeito do otimizador. Segunda, o valor não está em eleger um vencedor, mas em mapear os eixos de escolha: estrutura do cenário, variabilidade da dimensão do enxame e orçamento de cómputo. Em enxames de dimensão fixa e conhecida, com prioridade na eficiência da tarefa e orçamento de treino curto, o MARL por gradiente é preferível; quando a dimensão é variável ou a missão exige escalar sem retreino, a arquitetura de grafo com atenção é a única opção viável entre as estudadas.

6. Limitações do estudo

Três limitações enquadram o alcance das conclusões. Primeira, e mais importante, a comparação é *assimétrica*: o controlador evolutivo usa uma arquitetura de grafo com atenção, enquanto os *baselines* de gradiente usam um perceptrão multicamada de entrada fixa. Isolar o efeito do otimizador exigiria treinar a mesma arquitetura de atenção por gradiente — o passo natural já identificado. Segunda, sete execuções por configuração, embora suficientes para estabelecer significância na maioria das células, limitam o poder estatístico precisamente onde ele mais faz falta: nos cenários bimodais, distinguir taxas de convergência de 2/7 a 4/7 exigiria uma bateria substancialmente maior. Terceira, todos os resultados são em simulação; a transferência para hardware real introduz o conhecido *reality gap*, cuja mitigação por aleatorização de domínio (Tobin et al., 2017) fica como trabalho futuro. Estas limitações não invalidam os achados centrais — a dependência da neuroevolução face ao desenho da aptidão e o contraste de escalabilidade são robustos e estatisticamente suportados — mas delimitam-nos com honestidade.

7. Conclusões

Apresentámos uma avaliação comparativa imparcial de um controlador de atenção neuroevoluído contra o PPO e o SAC num enxame de *foraging* tridimensional, ao longo de sete cenários e três eixos de avaliação, com sete execuções de treino independentes por combinação e significância aferida ao nível da execução. A hipótese de que a inteligência adaptativa domina a robustez estática é apenas parcialmente confirmada, e o quadro é mais rico do que o antecipado. Com o desenho adequado

Tabela 2: Testes de significância sobre as *médias de recolhas por execução* ($n = 7$ por grupo; teste U de Mann–Whitney com δ de Cliff, $\alpha = 0.05$). A unidade independente é a execução de treino, não o episódio. “méd. A” e “méd. B” são as médias de comida recolhida de cada elemento do par.

Cenário	Par	méd. A	méd. B	p	δ	Significativo
Sandbox	GNN vs PPO	38.31	71.46	0.0006	−1.00	Sim
Sandbox	GNN vs SAC	38.31	69.24	0.0021	−1.00	Sim
Sandbox	PPO vs SAC	71.46	69.24	0.0297	+0.71	Sim
Muro em U	GNN vs PPO	24.54	39.62	0.1552	−0.47	não
Muro em U	GNN vs SAC	24.54	8.99	0.5714	+0.18	não
Muro em U	PPO vs SAC	39.62	8.99	0.0526	+0.63	não
Gargalo	GNN vs PPO	121.39	123.17	0.2086	+0.43	não
Gargalo	GNN vs SAC	121.39	41.44	0.0006	+1.00	Sim
Gargalo	PPO vs SAC	123.17	41.44	0.0006	+1.00	Sim
Quatro Salas	GNN vs PPO	59.76	33.58	0.0006	+1.00	Sim
Quatro Salas	GNN vs SAC	59.76	31.82	0.0006	+1.00	Sim
Quatro Salas	PPO vs SAC	33.58	31.82	0.3374	+0.33	não
Porta Cooperativa	GNN vs PPO	69.81	67.06	0.0262	+0.71	Sim
Porta Cooperativa	GNN vs SAC	69.81	62.09	0.0006	+1.00	Sim
Porta Cooperativa	PPO vs SAC	67.06	62.09	0.0175	+0.76	Sim
Percepção Cooperativa	GNN vs PPO	18.98	15.33	0.0297	+0.71	Sim
Percepção Cooperativa	GNN vs SAC	18.98	16.11	0.0297	+0.71	Sim
Percepção Cooperativa	PPO vs SAC	15.33	16.11	0.0547	−0.63	não
Porta c/ Alternativa	GNN vs PPO	86.70	85.25	0.8477	+0.08	não
Porta c/ Alternativa	GNN vs SAC	86.70	68.61	0.0006	+1.00	Sim
Porta c/ Alternativa	PPO vs SAC	85.25	68.61	0.0021	+1.00	Sim

da aptidão, o controlador evolutivo deixou de ser o elo fraco na tarefa: é estatisticamente superior aos métodos de gradiente em três dos sete cenários, indistinguível do melhor deles em mais dois, e é o único a escalar *zero-shot* até $N = 100$. Os métodos de gradiente preservam a fiabilidade em espaço aberto e uma vantagem de $\approx 8\times$ em núcleos-hora. Permanece um desafio transversal: a exploração sob decepção espacial, que nenhum dos paradigmas resolveu de forma consistente. O trabalho futuro inclui uma política de atenção treinada por gradiente para separar o otimizador da arquitetura, o alargamento da bateria estatística nos cenários bimodais, e a validação da transferência simulação-para-real (Tobin et al., 2017).

Agradecimentos

This work was partially supported by national funds through Fundação para a Ciência e a Tecnologia, I.P. (FCT), ISTAR-Iscte Pluriannual Projects UID/04466/2025 (<https://doi.org/10.54499/UID/04466/2025>).

Referências

Bettini, M., Prorok, A., Moens, V., 2024. Benchmarl: Benchmarking multi-agent reinforcement learning. *Journal of Machine Learning Research* 25.

Chen, X., NaderiAlizadeh, N., Ribeiro, A., Saeedi Bidokhti, S., 2024. Transferable graphical marl for real-time estimation in dynamic wireless networks. *arXiv preprint arXiv:2404.03227*.

Ekechi, C.C., Elfouly, T., Alouani, A., Khattab, T., 2025. A survey on uav control with multi-agent reinforcement learning. *Drones* 9, 484.

Elrod, M., Mehrabi, N., Amin, R., Kaur, M., Cheng, L., Martin, J., Razi, A., 2025. Graph based deep reinforcement learning aided by transformers for multi-agent cooperation. *arXiv preprint arXiv:2504.08195*.

Haarnoja, T., Zhou, A., Abbeel, P., Levine, S., 2018. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor, in: *Proceedings of the 35th International Conference on Machine Learning (ICML)*, pp. 1861–1870.

Huh, D., Mohapatra, P., 2023. Multi-agent reinforcement learning: A comprehensive survey. *arXiv preprint arXiv:2312.10256*.

Hüttenrauch, M., Šošić, A., Neumann, G., 2019. Deep reinforcement learning for swarm systems. *Journal of Machine Learning Research* 20, 1–31.

Iskandar, A., Rostum, H., Kovács, B., 2023. Using deep reinforcement learning to solve a navigation problem for a swarm robotics system, in: *2023 24th International Carpathian Control Conference (ICCC)*, IEEE. pp. 185–189.

Kegeleirs, M., Birattari, M., 2025. Towards applied swarm robotics: current limitations and enablers. *Frontiers in Robotics and AI* 12. doi:10.3389/frobt.2025.1607978.

Kennedy, J., Eberhart, R., 1995. Particle swarm optimization, in: *Proceedings of ICNN’95 - International Conference on Neural Networks*, IEEE. pp. 1942–1948.

Lehman, J., Stanley, K.O., 2011. Abandoning objectives: Evolution through the search for novelty alone. *Evolutionary Computation* 19, 189–223. doi:10.1162/EVC0_a_00025.

- Lowe, R., Wu, Y., Tamar, A., Harb, J., Abbeel, P., Mordatch, I., 2017. Multi-agent actor-critic for mixed cooperative-competitive environments, in: *Advances in Neural Information Processing Systems (NeurIPS)*.
- Majid, A.Y., Saaybi, S., Francois-Lavet, V., Prasad, R.V., Verhoeven, C., 2024. Deep reinforcement learning versus evolution strategies: A comparative survey. *IEEE Transactions on Neural Networks and Learning Systems* 35, 11939–11957.
- Ng, A.Y., Harada, D., Russell, S., 1999. Policy invariance under reward transformations: Theory and application to reward shaping, in: *Proceedings of the 16th International Conference on Machine Learning (ICML)*, pp. 278–287.
- Oliehoek, F.A., Amato, C., 2016. *A Concise Introduction to Decentralized POMDPs*. Springer.
- Salimans, T., Ho, J., Chen, X., Sidor, S., Sutskever, I., 2017. Evolution strategies as a scalable alternative to reinforcement learning. *arXiv preprint arXiv:1703.03864*.
- Schmickl, T., et al., 2025. Scaling swarm coordination with GNNs—how far can we go? *AI* 6, 282. doi:10.3390/ai6110282.
- Schulman, J., Moritz, P., Levine, S., Jordan, M.I., Abbeel, P., 2016. High-dimensional continuous control using generalized advantage estimation, in: *International Conference on Learning Representations (ICLR)*.
- Schulman, J., Wolski, F., Dhariwal, P., Radford, A., Klimov, O., 2017. Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*.
- Tobin, J., Fong, R., Ray, A., Schneider, J., Zaremba, W., Abbeel, P., 2017. Domain randomization for transferring deep neural networks from simulation to the real world, in: *IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, IEEE. pp. 23–30.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A.N., Kaiser, Ł., Polosukhin, I., 2017. Attention is all you need, in: *Advances in Neural Information Processing Systems (NeurIPS)*.
- Veličković, P., Cucurull, G., Casanova, A., Romero, A., Liò, P., Bengio, Y., 2018. Graph attention networks, in: *International Conference on Learning Representations (ICLR)*.