

Aprendizagem Adaptativa *versus* Robustez Estática: Comparação de Aprendizagem por Reforço e Neuroevolução para Controlo de Enxames

Gonçalo Pombo^a, Luís Nunes^a

^aInstituto Universitário de Lisboa (ISCTE-IUL), ISTAR, Lisboa, Portugal

Abstract

O controlo de enxames robóticos é abordado por duas comunidades que raramente se encontram num referencial comum: a aprendizagem por reforço multiagente (MARL), que promete adaptabilidade *em linha*, e a otimização bio-inspirada, que oferece robustez pré-programada. Este trabalho apresenta uma comparação controlada e independente do paradigma entre três controladores — uma rede de grafo neuroevoluída com atenção sobre os vizinhos, *Proximal Policy Optimisation* (PPO) e *Soft Actor-Critic* (SAC) — no mesmo simulador tridimensional de *foraging* de alta fidelidade, em sete cenários de dificuldade crescente, com sete execuções de treino independentes por combinação, sob avaliação determinística emparelhada e testes não paramétricos ao nível da execução. O resultado central é que o desempenho do controlador evolutivo depende menos do orçamento de treino do que do *desenho da função de aptidão*: substituindo o retorno acumulado — que é farmável por deambulação — por um *shaping* de *homing* terminal, o controlador converge nas 28 execuções dos quatro cenários de gargalo e torna-se estatisticamente superior aos métodos de gradiente em três cenários, indistinguível do melhor deles em mais dois. Os métodos de gradiente conservam duas vantagens sólidas: fiabilidade em espaço aberto, onde o evolutivo ocasionalmente degenera, e uma eficiência computacional cerca de 8× superior. Sob escalabilidade *zero-shot*, apenas o controlador baseado em atenção transita de $N = 10$ para $N = 100$ agentes sem retreino, mantendo 100% de sucesso nos sete cenários — com eficiência por agente quase intacta precisamente nos labirintos, onde o congestionamento seria a expectativa. A hibridização com procura por novidade, sob orçamento igualado, resolve o único cenário que resistia aos três controladores (7/7 execuções no labirinto de decepção espacial), mas, com peso fixo, degrada o desempenho onde o gradiente da tarefa basta; uma *dosagem adaptativa* do peso de novidade, validada numa campanha pré-registada, elimina esse custo mantendo o ganho — e o objetivo puro, mesmo com o dobro do orçamento, permanece incapaz de resolver o labirinto de forma fiável. A hipótese de que a inteligência adaptativa domina a robustez estática é, por isso, apenas *parcialmente* confirmada: a vantagem decisiva reside na *representação* e no desenho do sinal de treino, e não no algoritmo de otimização.

Keywords: robótica de enxames, aprendizagem por reforço multiagente, neuroevolução, escalabilidade zero-shot, redes neuronais de grafos, avaliação comparativa

1. Introdução

Os enxames robóticos prometem soluções escaláveis e resilientes para tarefas como busca e salvamento, monitorização ambiental e logística distribuída. A questão central de engenharia é qual o paradigma de controlo que melhor mantém a operacionalidade sob incerteza. Duas escolas dominam. A *otimização bio-inspirada* (por exemplo, algoritmos evolutivos e otimização por enxame de partículas) procura num espaço global de parâmetros, *fora de linha*, controladores robustos e estáticos (Kennedy and Eberhart, 1995). A *aprendizagem por reforço multi-agente* (MARL) aprende, em alternativa, políticas adaptativas *em linha* através da interação (Huh and Mohapatra, 2023).

Que as comparações diretas entre os dois paradigmas sejam escassas é afirmação recorrente (Majid et al., 2024; Bettini et al., 2024); é também, tanto quanto sabemos, uma afirmação que nunca foi medida. Conduzimos por isso uma revisão sistemática (PRISMA 2020; Scopus e IEEE Xplore, 2020–2026;

883 registos, 680 únicos), cujo corpo final de 58 estudos primários sobre controlo de enxames revela um equilíbrio notável: 21 assentam exclusivamente em MARL e 23 em otimização bio-inspirada — dois campos igualmente produtivos. Contudo, **apenas dois** os confrontam, e um deles fá-lo por hibridização. Existe, portanto, na literatura recuperada, **um único estudo** que compara empiricamente MARL com otimização bio-inspirada na navegação de enxames (Iskandar et al., 2024) — numa só tarefa, sem transferência para dimensões de exame não vistas, sem testes de robustez a falhas e sem inferência estatística. O isolamento metodológico entre as duas comunidades deixa assim de ser um diagnóstico intuitivo para passar a ser uma contagem: 1 em 58.

Controlar um enxame é difícil por três razões que se reforçam. O espaço de ações conjuntas cresce exponencialmente com o número de agentes, tornando inviável tratar o enxame como um único agente monolítico; a recompensa de tarefa é tipicamente esparsa e diferida, o que agrava a atribuição de crédito; e cada agente decide a partir de uma observação parcial e local, sem acesso ao estado global. Os dois paradigmas respon-

dem a estas dificuldades de formas opostas — a MARL aprende uma política partilhada que generaliza por experiência, a otimização bio-inspirada procura um controlador robusto num só esforço de otimização — e é precisamente essa oposição que motiva uma comparação direta e controlada.

A questão de investigação que orienta a dissertação é, em rigor, se a *inteligência adaptativa* (uma política de MARL que aprende com a experiência) supera a *robustez estática* (um controlador otimizado de uma só vez e depois congelado) em cenários de *stress* dinâmico. Responder a esta questão exige um referencial em que ambos os paradigmas sejam avaliados nas mesmas condições, com as mesmas métricas e a mesma análise estatística — algo que a literatura raramente oferece.

Este artigo aborda essa lacuna com uma avaliação comparativa imparcial. Implementámos um simulador tridimensional de *foraging* de alta fidelidade e avaliamos três controladores — uma rede de grafo neuroevoluída com auto-atenção sobre os vizinhos, PPO e SAC — em sete cenários e ao longo de três eixos: desempenho na tarefa (P_{task}), robustez a falhas de agentes (R_{robust}) e escalabilidade *zero-shot* (S_{scale}). Cada combinação (algoritmo, cenário) foi treinada em sete execuções independentes, o que permite tratar a *execução de treino* — e não o episódio — como unidade estatística, distinguindo o desempenho atingível da fiabilidade da convergência.

A nossa contribuição é quántupla: (i) a quantificação da lacuna, por revisão sistemática, que situa este trabalho como a segunda comparação empírica entre os dois paradigmas na navegação de enxames — e a primeira com escalabilidade, robustez e inferência estatística; (ii) um protocolo de avaliação reproduzível e independente do paradigma, com significância aferida ao nível da execução; (iii) a demonstração de que o alegado colapso da neuroevolução em cenários de estrangulamento é um artefacto do *desenho da aptidão*, e não uma limitação intrínseca do paradigma, corrigível por um *shaping* de *homíng* terminal não farmável; (iv) a evidência de que a escalabilidade *zero-shot* é uma propriedade da representação (grafo com atenção), e não do otimizador; e (v) a validação, sob protocolo *pré-registado* (hipótese, testes e regra de decisão fixados antes dos dados), de uma dosagem adaptativa da pressão por novidade que retém o ganho desta onde a deceção morde sem o seu custo onde não morde. Uma versão preliminar deste trabalho, com um orçamento de treino mais curto e uma aptidão baseada no retorno acumulado, levava à conclusão oposta sobre o paradigma evolutivo — circunstância que ilustra a importância metodológica do segundo contributo. A metodologia e os resultados completos são detalhados na dissertação que acompanha este artigo.

2. Trabalho Relacionado

A aprendizagem por reforço profunda tem sido aplicada a sistemas de enxame com partilha de parâmetros para domar a explosão do espaço de ações conjuntas (Hüttenrauch et al., 2019), em que uma única rede é partilhada por todos os agentes homogêneos. As redes neuronais de grafos (GNN) emergiram como o principal viabilizador da escalabilidade. O mecanismo é estrutural: numa política definida sobre um grafo, o número de parâmetros treináveis não depende do número de

agentes, pelo que a política aprendida se aplica diretamente a grafos maiores sem retreino — propriedade caracterizada com clareza por Chen et al. (2024), ainda que em redes multi-salto sem fios e não em robótica. Em robótica de enxame, a invariância à dimensão da vizinhança é confirmada empiricamente na exploração multi-robô com GNN hierárquicas (Zhang et al., 2022) e, por outra via, em aproximações de campo médio, nas quais o agente reage à distribuição estatística dos vizinhos em vez de a cada um individualmente, tornando o custo de coordenação independente de N (Tang et al., 2023). O mecanismo de atenção (Vaswani et al., 2017; Veličković et al., 2018) é central nesta família, por ser invariante à permutação e à cardinalidade do conjunto de vizinhos, e sustenta igualmente a manutenção de formações sob variação da escala do enxame (Li et al., 2024).

No paradigma de aprendizagem, o esquema de treino centralizado com execução descentralizada (CTDE) tornou-se padrão para domar a não-estacionariedade do ambiente multiagente (Lowe et al., 2017; Oliehoek and Amato, 2016). No presente trabalho, contudo, os *baselines* de gradiente partilham uma única política e executam a partir da observação puramente local, sem um crítico de estado global, o que mantém a comparação ancorada num regime descentralizado comum aos três controladores.

Do lado bio-inspirado, a neuroevolução otimiza os pesos da rede sem gradientes (Salimans et al., 2017), oferecendo controladores estáveis para tarefas estáticas, mas com adaptabilidade *em linha* limitada (Kegeleirs and Birattari, 2025). As estratégias de evolução são atrativas pela simplicidade e pela paralelização trivial, mas otimizam a partir de um único escalar de aptidão por episódio, sem atribuição de crédito temporal — uma distinção que se revelará decisiva. Quando a recompensa de tarefa é esparsa, a aptidão fica refém do termo de modelação, e a escolha desse termo determina se a seleção discrimina ou fica cega.

Que esta especificação seja difícil não é observação nova: é precisamente o que motiva a linha de *desenho automático* de enxames, na qual se procura dispensar a função-objetivo. Haselmann et al. (2023) geram, por procura por novidade (Lehman and Stanley, 2011), repertórios de comportamentos que são depois montados modularmente em controladores; Szpirer et al. (2024) substituem a função-objetivo por demonstrações, recuperando-a por aprendizagem por reforço inversa; e a transferibilidade destes controladores da simulação para plataformas físicas distintas foi caracterizada por Kegeleirs et al. (2024). Numa linha complementar, a evolução é tratada como processo *em linha* e distribuído, propagando-se os controladores entre robôs durante a própria missão (Bredeche and Fontbonne, 2022; Fontbonne et al., 2020). Na tarefa de *foraging* — a mesma que aqui se estuda — a neuroevolução é aplicada com sucesso em arenas abertas com obstáculos dispersos (Zaman et al., 2025; Biteng et al., 2025) e a afinação multiobjetivo de regras de interação arbitra entre recolha e energia (Ordáz-Rivas et al., 2026). É de notar que estes trabalhos empregam aptidões baseadas em retorno acumulado sem observar o colapso que aqui reportamos: uma divergência que atribuímos à ausência, nas suas arenas, de estrangulamentos decetivos onde o termo de modelação satura (Secção 5).

Quanto ao confronto entre paradigmas, os estudos existentes

salientam a ausência de uma referência de desempenho comum entre as duas famílias (Majid et al., 2024), enquanto os referenciais padronizados de MARL permanecem focados dentro da comunidade de aprendizagem, sem qualquer *baseline* evolutiva (Bettini et al., 2024). A única comparação empírica que a nossa revisão recuperou (Iskandar et al., 2024) — conduzida pelo grupo que havia antes aplicado aprendizagem por reforço profunda à navegação de enxames (Iskandar et al., 2023) — conclui que a aprendizagem se destaca em ambientes próximos das condições de treino, enquanto a otimização por enxame de partículas exhibe consistência superior em cenários não treinados, sem reconfiguração. É uma conclusão convergente com a que aqui se obtém por um protocolo mais exigente; a diferença está em que a sustentamos em sete cenários, sete execuções independentes por combinação e testes não paramétricos ao nível da execução, acrescentando os eixos de escalabilidade a dimensões não vistas e de robustez a falhas que aquele estudo não aborda.

3. Metodologia

3.1. Ambiente de simulação

O ambiente é uma tarefa de *foraging* contínua e tridimensional, numa arena circular (raio 15 m) com $N = 20$ agentes homogêneos que devem recolher comida e transportá-la para um ninho. Utilizam-se sete cenários de dificuldade crescente: um *Sandbox* aberto; três labirintos de navegação (*Muro em U*, *Gargalo*, *Quatro Salas*); duas tarefas cooperativas (*Porta Cooperativa*, que exige ≥ 3 agentes para abrir uma passagem, e *Percepção Cooperativa*, com um alvo móvel); e um cenário *deceptive*, a *Porta Cooperativa com Alternativa*, em que a porta bloqueada atrai o gradiente de navegação enquanto o único caminho viável é um corredor lateral que obriga a afastar-se temporariamente do ninho. A Figura 1 ilustra os sete cenários. Cada agente observa uma bússola de *homing* egocêntrica para o ninho, oito raios LiDAR para deteção local de obstáculos e o estado relativo dos vizinhos — um cenário parcialmente observável, formalizável como um Dec-POMDP (Oliehoek and Amato, 2016). A bússola fornece a direção e a distância euclidiana ao ninho de forma sempre disponível (à imagem do *homing* global em formigas ou da navegação por GPS), ao passo que os obstáculos só são percecionados localmente pelo LiDAR de 8 m, preservando uma observabilidade parcial genuína.

Para evitar mínimos locais nos cenários de labirinto, a recompensa de progresso usa um potencial *geodésico* calculado pelo algoritmo de Dijkstra sobre uma grelha de ocupação dilatada, atuando como modelação de recompensa baseada em potencial (Ng et al., 1999) que não altera a política ótima e é usada apenas como sinal de treino, nunca como observação. A Figura 2 contrasta o potencial euclidiano ingênuo — que “atravessa” a parede e cria um mínimo local que cola os agentes ao obstáculo — com o campo geodésico, cujo gradiente premeia corretamente o contorno da barra. Esta distinção é essencial para a leitura dos resultados: o sinal de treino aponta sempre para o desvio correto, pelo que as dificuldades observadas no *Muro em U* são de *descoberta*, não de modelação da recompensa.

3.2. Espaço de observação, de ação e recompensa

A observação de cada agente é um vetor egocêntrico que reúne a bússola de *homing* (direção e distância ao ninho), os oito raios LiDAR e o estado relativo dos $N - 1$ vizinhos; manter o vizinho como uma entidade explícita é o que permite à GNN atender sobre um conjunto de cardinalidade variável. O espaço de ação é contínuo e egocêntrico: três componentes de translação em $[-1, 1]$ (frontal, lateral e vertical), escaladas por um passo máximo de 0.2 m e resolvidas por uma ordem determinística de *step* que aplica deslizamento ao longo das paredes (*wall-sliding*) em caso de colisão, evitando que o agente fique imobilizado num canto.

A recompensa foi deliberadamente *simplificada* face a iterações anteriores, e reduz-se a quatro termos: (i) uma recompensa de tarefa de +300 por recolha, repetível ao longo do episódio e claramente dominante; (ii) o progresso geodésico descrito acima, com fator 10 (Ng et al., 1999); (iii) um bônus de exploração baseado em contagem (+0.5 por célula nova de 2×2 m), pequeno de propósito; e (iv) um custo energético de -0.05 por passo, que impõe pressão temporal. As penalizações secundárias de dispersão e de colisão foram anuladas no *sinal de recompensa* (a física de colisão e separação mantém-se), depois de se verificar que competiam com a tarefa sem benefício mensurável. O número de agentes exigidos em simultâneo no ninho é definido por cenário: $k_{\min} = 3$ nos cenários em que a cooperação é o objeto de estudo, e $k_{\min} = 1$ nos labirintos de navegação pura, onde exigir três agentes converteria um problema de navegação numa cooperação artificial. Uma calibração anterior, com um bônus de exploração maior, produziu *exploração da recompensa*: a política aprendia a deambular a colher exploração em vez de convergir para a recolha.

3.3. Controladores

O *controlador evolutivo* (GNN) é uma rede compacta que codifica as características egocêntricas e aplica auto-atenção de produto escalar normalizado sobre o conjunto de vizinhos (Vaswani et al., 2017), produzindo uma ação invariante ao número de vizinhos. Os seus pesos são otimizados por uma estratégia de evolução com truncatura e elitismo (população $K = 30$, $e = 6$ elites preservados, mutação gaussiana esparsa com σ inicial 0.1, decaimento 0.999 e piso $\sigma_{\min} = 0.03$), guiada por uma aptidão em que a tarefa domina a seleção:

$$J(\theta_k) = \bar{f}_k \cdot \lambda_{\text{task}} + \beta \cdot \bar{h}_k, \quad \lambda_{\text{task}} = 10^4, \beta = 5000, \quad (1)$$

onde $\bar{f}_k$ é a média de comida recolhida e $\bar{h}_k \in [0, 1]$ é o *homing*: a fração média de aproximação ao ninho *no final* do episódio, medida por agente como $\text{clip}((\Phi_0 - \Phi_T)/\Phi_0, 0, 1)$, com Φ o potencial de navegação (geodésico nos cenários com paredes). As médias são tomadas sobre $E = 4$ episódios com sementes fixas.

A escolha de $\bar{h}$ é a decisão de desenho central deste trabalho. Numa formulação anterior, o termo de desempate era o retorno acumulado comprimido por uma *tanh*; mas o retorno acumulado é *farmável*, porque o progresso e a exploração rendem a cada passo: observaram-se genomas com retorno bruto $\approx 88\,000$ e *zero* recolhas, que deambulavam indefinidamente porque parar no ninho — a pré-condição da tarefa — corta o




Figura 1: Os sete cenários de avaliação, renderizados a partir da geometria real do simulador. Em cima: Sandbox (aberto, com obstáculos esféricos), Muro em U, Gargalo e Quatro Salas. Em baixo: Porta Cooperativa (passagem a âmbar, abre com ≥ 3 agentes), Percepção Cooperativa (alvo móvel) e Porta Cooperativa com Alternativa (cenário *deceptive*: a porta atrai, o corredor lateral resolve). O ninho é a esfera verde.




Figura 2: Potencial de recompensa no Muro em U: a distância euclidiana (esquerda) atravessa a parede e induz um mínimo local; o campo geodésico (direita), calculado por Dijkstra sobre a grelha com obstáculos dilatados, premeia o contorno e elimina a armadilha. É um sinal de treino, não uma observação.

rendimento por passo. O *homing* terminal elimina a patologia por construção: depende apenas dos estados extremos do episódio, não do caminho, pelo que deambular não o aumenta, e a única forma de o maximizar é *terminar* junto ao ninho. Como uma única recolha (10^4) vale o dobro do *shaping* máximo (5000), a tarefa domina a seleção assim que um genoma recolhe.

Os *baselines de aprendizagem* são o PPO (Schulman et al., 2017) e o SAC (Haarnoja et al., 2018) da biblioteca Stable-Baselines3, com uma política de percepção multicamada partilhada ([256, 256]) sobre a observação densa da vizinhança (partilha de parâmetros). O mecanismo de atenção sobre o grafo é, assim, instanciado apenas no controlador evolutivo, o que é precisamente o que viabiliza a sua transferência *zero-shot*. O PPO usa estimação de vantagem generalizada (Schulman et al., 2016) e o SAC, fora de política, regulariza por entropia; ambos são treinados sobre ambientes vetorizados em paralelo (*Sub-*

procVecEnv), com a mesma política a recolher experiência de todos os agentes do enxame, e o controlador evolutivo avalia a sua população também em paralelo.

3.4. Protocolo de avaliação

Cada combinação (algoritmo, cenário) foi treinada em **sete execuções independentes** com sementes distintas, perfazendo $3 \times 7 \times 7 = 147$ treinos numa campanha contínua de sete dias. Cada execução do controlador evolutivo dispôs de 195 minutos sobre ≈ 30 núcleos, e cada execução de PPO/SAC de 48 minutos sobre 16 núcleos; todos os regimes atingem o planalto de aprendizagem, pelo que a comparação mede o *desempenho atingível*, embora os métodos de gradiente conservem uma vantagem de $\approx 8\times$ em núcleos-hora.

Cada modelo é depois avaliado deterministicamente em 20 episódios com sementes emparelhadas entre algoritmos, totalizando 140 episódios por célula. Reportamos P_{task} (taxa de sucesso, com sucesso definido como pelo menos um item recolhido) e a média de comida recolhida por episódio, que é a métrica de magnitude comparável entre paradigmas. A robustez (R_{robust}) injeta a falha de 10% dos agentes a meio do episódio; a escalabilidade (S_{scale}) testa $N \in \{10, 20, 50, 100\}$ sem retreino.

Um ponto metodológico merece ênfase: as diferenças par a par são avaliadas sobre as **médias por execução** ($n = 7$ por grupo), com o teste U de Mann–Whitney e o δ de Cliff como tamanho de efeito, a $\alpha = 0.05$. A unidade estatística independente é a execução de treino, e não o episódio — tratar os 140 episódios como observações independentes inflacionaria artificialmente o poder do teste, pois episódios da mesma execução partilham o mesmo controlador.




Figura 3: Comida recolhida por episódio (média $\pm$ desvio-padrão) por cenário e controlador. As barras de erro largas do controlador evolutivo no Sandbox e no Muro em U refletem bimodalidade entre execuções, não ruído de avaliação.

4. Resultados

4.1. Desempenho na tarefa


A Tabela 1 reporta a comida recolhida por episódio, a taxa de sucesso e o número de execuções plenamente convergentes. Esta última coluna é essencial: uma taxa de sucesso média intermédia quase nunca significa “resolve o cenário metade das vezes”, mas sim que *algumas execuções resolvem-no integralmente e outras falham por completo*. Quinze das vinte e uma combinações algoritmo–cenário atingem 100% de sucesso em todas as execuções; as seis restantes escondem, sem exceção, esta distribuição tudo-ou-nada.

O quadro que emerge não tem um vencedor universal. O **controlador evolutivo** resolve os quatro cenários de gargalo — Gargalo, Quatro Salas e as duas Portas Cooperativas, incluindo portanto o cenário *deceptive* — nas 28 execuções correspondentes, igualando o PPO no Gargalo (121.4 recolhas/ep, empate estatístico) e destacando-se no Quatro Salas (59.8, cerca de $1.8\times$ o melhor método de gradiente) e na Porta Cooperativa com Alternativa (86.7); mas exhibe execuções degeneradas precisamente nos cenários *sem paredes* (Sandbox, 5/7; Percepção Cooperativa, 6/7), onde a paisagem de aptidão oferece ótimos locais de deambulação. O PPO é o mais consistente, com 100% de sucesso em seis dos sete cenários e a menor variância entre execuções. O SAC é fiável em espaço aberto e nos cooperativos, mas o mais frágil nos estrangulamentos físicos: no Gargalo apenas 5/7 execuções convergem, com magnitude muito dispersa (41.4 ± 36.8).

4.2. O Muro em U e a bimodalidade entre execuções

O Muro em U é o único cenário que *nenhum* algoritmo resolve de forma fiável, e a sua análise ilustra por que razão a unidade estatística importa. O desempenho é bimodal nos três paradigmas: cada execução ou aprende o desvio ao beco e atinge 100% de sucesso, ou não o aprende de todo (GNN 3/7, PPO 4/7, SAC 2/7). A Figura 4 mostra a distribuição por execução. Nenhuma diferença entre algoritmos atinge significância, e a conclusão honesta é que sete execuções não bastam para distinguir taxas de convergência de 2/7 a 4/7.

O obstáculo não está no sinal de treino — o potencial geodésico aponta corretamente para o contorno (Figura 2) — mas



Cada ponto = 1 run independente (7 runs/algoritmo; média de 20 episódios determinísticos). Métrica de tarefa: mesma unidade para os três algoritmos.

Figura 4: Distribuição das recolhas por episódio no Muro em U, agregando as sete execuções de cada controlador. A dispersão não é ruído de avaliação: reflete execuções de treino que resolvem integralmente o cenário e execuções que falham por completo.

na *descoberta*: o agente observa apenas a bússola de *homing* euclidiana e o LiDAR local, pelo que percorrer o desvio exige uma trajetória longa que se afasta, durante dezenas de passos, da única direção que o agente percceciona como sendo o ninho. Nenhum dos mecanismos de exploração estudados (entropia, *clipped surrogate*, mutação gaussiana) garante essa descoberta — é esta a motivação da procura por novidade, avaliada de seguida.

4.3. Deceção e procura por novidade

Numa experiência preliminar na Porta Cooperativa com Alternativa — desenhada como armadilha *deceptive*: o gradiente de *homing* aponta para a porta bloqueada e o caminho viável exige afastamento temporário do ninho —, um controlador com *blend* de novidade (Lehman and Stanley, 2011) ($w = 0.5$, 600 minutos) obteve 81.3 ± 1.9 recolhas/ep contra 64.5 do melhor controlador puramente objetivo então disponível (+26%; Wilcoxon emparelhado $p = 8.7 \times 10^{-5}$). Duas ressalvas eram incontornáveis: a execução com novidade dispôs de um orçamento $\approx 3\times$ superior, e este é o único teste do artigo cuja unidade estatística é o episódio ($n = 20$, um só modelo por braço) e não a execução de treino, pelo que o seu p não é comparável com os restantes (os artefactos brutos desta execução preliminar não foram retidos; os valores são o registo da altura). Para isolar o efeito, corremos duas campanhas com **orçamento igualado** ao da campanha final (sete execuções de 195 minutos por braço, mesmo protocolo e *seeds*), nos dois cenários vulneráveis à deceção.

No Muro em U, a hibridização elevou a taxa de convergência de 3/7 para 7/7 execuções a 100% de sucesso, com 69.8 ± 5.9 recolhas/ep contra 24.5 ± 32.6 do objetivo puro (Mann–Whitney $p = 0.026$, $\delta = +0.71$) — tornando-se a única configuração estudada que resolve de forma fiável o cenário que resistia aos três controladores base. Na Porta com Alternativa, onde o *homing* já convergia em 7/7 execuções, o quadro inverte-se: a mesma

Tabela 1: Desempenho sob avaliação determinística (7 execuções de treino independentes $\times$ 20 episódios com sementes emparelhadas por cenário): média $\pm$ desvio-padrão da comida recolhida por episódio *entre execuções*, taxa de sucesso média entre parênteses, e número de execuções que atingem 100% de sucesso. A comida recolhida é a métrica de magnitude comparada entre paradigmas; a taxa de sucesso, isolada, é um indicador fraco, pois um agente atinge 100% recolhendo um único item. Melhor média por linha a negrito.

Cenário	GNN	PPO	SAC
Sandbox	38.3 $\pm$ 31.0 (86%) [5/7]	71.5 $\pm$ 1.0 (100%) [7/7]	69.2 $\pm$ 1.9 (100%) [7/7]
Muro em U	24.5 $\pm$ 32.6 (43%) [3/7]	39.6 $\pm$ 36.7 (71%) [4/7]	9.0 $\pm$ 15.1 (34%) [2/7]
Gargalo	121.4 $\pm$ 19.9 (100%) [7/7]	123.2 $\pm$ 1.2 (100%) [7/7]	41.4 $\pm$ 36.8 (72%) [5/7]
Quatro Salas	59.8 $\pm$ 13.2 (100%) [7/7]	33.6 $\pm$ 3.8 (100%) [7/7]	31.8 $\pm$ 3.3 (100%) [7/7]
Porta Cooperativa	69.8 $\pm$ 0.9 (100%) [7/7]	67.1 $\pm$ 3.7 (100%) [7/7]	62.1 $\pm$ 2.5 (100%) [7/7]
Percepção Cooperativa	19.0 $\pm$ 8.7 (91%) [6/7]	15.3 $\pm$ 0.4 (100%) [7/7]	16.1 $\pm$ 0.8 (100%) [7/7]
Porta c/ Alternativa	86.7 $\pm$ 2.0 (100%) [7/7]	85.3 $\pm$ 4.0 (100%) [7/7]	68.6 $\pm$ 3.4 (100%) [7/7]

pressão por novidade degradou a magnitude (63.0 ± 21.9 vs. 86.7 ± 2.0 ; $p = 0.0006$, $\delta = -1.00$), desmascarando o +26% preliminar como artefacto do orçamento triplo.

Com peso fixo, a pressão por novidade é, pois, um instrumento direcionado, não um melhoramento universal: compra a descoberta do desvio onde a otimização objetiva é inconsistente e desperdiça pressão seletiva onde o gradiente da tarefa basta. O peso fixo $w = 0.5$ explica ambos os efeitos — o que motivou o teste final desta linha: uma **dosagem adaptativa**, em que w parte de 0.5 e decai ($\times 0.98$ /geração, até 0) assim que o melhor genoma por objetivo recolhe durante dez gerações consecutivas.

Esta campanha foi *pré-registada* — hipótese, testes confirmatórios e regra de decisão fixados no repositório antes de existirem dados de avaliação — e corrida nos sete cenários sob o protocolo integral do artigo (sete execuções de 195 minutos, sementes 1–7, inferência por execução). Os quatro testes confirmaram a hipótese: sem degradação significativa nos cinco cenários que o objetivo já resolve (todos $p \geq 0.21$); ganho mantido no Muro em U (7/7 execuções a 100%, 68.5 ± 13.1 vs. 24.5 ± 32.6 ; $p = 0.009$ unilateral, $\delta = +0.76$); custo do peso fixo no cenário *deceptive* não reproduzido (77.2 ± 16.7 vs. 86.7 ± 2.0 ; $p = 0.32$, $\delta = -0.35$, n.s., 7/7 a 100%); e superioridade em magnitude sobre o peso fixo nesse cenário (77.2 vs. 63.0 ; $\delta = +0.59$). Dois braços exploratórios completam o quadro: o objetivo puro com o *dobro* do orçamento (390 min) continua bimodal no Muro em U (4/7, 31.5 ± 35.0) — o ganho é do mecanismo, não do orçamento — e o adaptativo com esse orçamento atinge no cenário *deceptive* o melhor resultado de todo o estudo (88.7 ± 0.6 , 7/7). A dosagem adaptativa fecha, assim, a tensão do peso fixo: retém a exploração enquanto ela compra descoberta e devolve a seleção ao objetivo quando ele basta.

4.4. Escalabilidade zero-shot

Apenas o controlador baseado em atenção é viável para $N \neq 20$: transferindo sem qualquer retreino a política aprendida com $N = 20$ para $N \in \{10, 50, 100\}$, mantém 100% de sucesso nas **28 combinações** cenário $\times$ dimensão — a bateria cobre os sete cenários, incluindo labirintos e tarefas cooperativas, e não apenas a arena aberta (Figura 5). O padrão da eficiência *per capita* desarma a objeção natural do congestionamento: a retenção em $N = 100$ (face a $N = 20$) é mais alta nos cenários com estrutura física (Porta com Alternativa 90%, Porta




Figura 5: Transferência *zero-shot* no cenário Sandbox para tamanhos de exame nunca vistos ($N \in \{10, 20, 50, 100\}$), sem retreino. O eixo vertical é a recolha *per capita*: a sua descida ($3.74 \rightarrow 1.27$) reflete a partilha de um recurso finito por mais agentes — as recolhas *totais* crescem ($37.4 \rightarrow 127.3$) e a taxa de sucesso mantém-se em 100%. Nos sete cenários da bateria o sucesso é 100% em todas as 28 combinações, com retenção *per capita* de 58–90% nos cenários com paredes. O PPO/SAC, com entrada de dimensão fixa, são incompatíveis com $N \neq 20$ e surgem como pontos isolados.

Cooperativa 88%, Muro em U 78%) e mais baixa nos cenários abertos (Sandbox 39%, Percepção Cooperativa 45%), onde cem agentes partilham um recurso finito — diluição de recurso, não falha de coordenação; um colapso por congestionamento teria a assinatura inversa. Os casos intermédios matizam a leitura sem a inverter: o Quatro Salas retém 66% e o Gargalo 58% — o cenário de passagem única, onde a saturação do fluxo tem mais margem para morder —, mas mesmo aí o sucesso permanece em 100% e as recolhas totais crescem de 138.6 ($N = 20$) para 403.6 ($N = 100$). As recolhas totais no Sandbox crescem monotonicamente ($37.4 \rightarrow 65.8 \rightarrow 97.5 \rightarrow 127.3$ para $N = 10, 20, 50, 100$). As políticas de percepção multicamada do PPO/SAC têm uma entrada de dimensão fixa ($\mathbb{R}^{111}$, calibrada para $N = 20$) e são estruturalmente incompatíveis com outros tamanhos de exame. A adaptabilidade arquitetural — a propriedade que a hipótese atribui ao MARL — manifesta-se, assim, na *representação* (grafo com atenção), e não no algoritmo de otimização.

4.5. Robustez

Sob a falha de 10% dos agentes a meio do episódio, todos os paradigmas mantêm desempenho elevado, com retenção en-




Figura 6: Retenção de desempenho sob falha de 10% dos agentes a meio do episódio, relativa à execução nominal. Nenhum paradigma colapsa; a redundância emerge da partilha de parâmetros e da observação puramente local.

tre 92% e 106% em todas as combinações com desempenho de base, sem colapso (Figura 6). Os valores pontualmente acima de 100% correspondem a episódios em que a perda de agentes reduziu o congestionamento nas passagens estreitas. A robustez, sendo transversal aos três paradigmas, não constitui critério discriminante entre eles: a partilha de parâmetros e a observação local conferem ao enxame uma redundância funcional em que nenhum agente é insubstituível.

4.6. Significância estatística

A Tabela 2 apresenta as 21 comparações par a par sobre as médias de recolhas por execução ($n = 7$ por grupo). O controlador evolutivo é significativamente superior a *ambos* os métodos de gradiente em três cenários (Quatro Salas, Porta Cooperativa e Percepção Cooperativa) e superior ao SAC em mais dois (Gargalo e Porta com Alternativa), empatando com o PPO nesses dois. Os métodos de gradiente são superiores no Sandbox, onde as execuções degeneradas do evolutivo pesam ($\delta = \pm 1.00$). No Muro em U nenhuma comparação atinge significância.

5. Discussão

Em campanhas exploratórias anteriores, o controlador evolutivo colapsava em todos os cenários de estrangulamento, e a mecânica desse colapso merece registo porque é o achado metodológico deste trabalho. A neuroevolução otimiza a partir de um único escalar de aptidão por episódio, sem atribuição de crédito temporal: nunca aprende *qual* ação, em *que* instante, importou. Quando a recompensa de tarefa é esparsa, quase todos os genomas recolhem zero, a aptidão reduz-se ao termo de modelação e — na formulação inicial, saturada por uma tanh do retorno acumulado — converge para um valor comum a toda a população: um *planalto de aptidão* onde a pressão seletiva se anula.

A cura não foi mais orçamento, mas *melhor desenho da aptidão*. Substituir o retorno acumulado, farmável por deambulação, pelo *homing* terminal, que só é maximizável terminando junto ao ninho, restaurou o gradiente de seleção nos labirintos: 28/28 execuções convergentes nos quatro cenários de gargalo, com magnitudes que igualam ou superam os métodos de gradiente. O “colapso do evolutivo” era, portanto, um artefacto do desenho da aptidão, e não uma limitação intrínseca do paradigma. A ressalva é que esta sensibilidade ao desenho é, em si

mesma, um custo de engenharia que os métodos de gradiente, com atribuição de crédito passo a passo, não pagam na mesma medida.

Este achado permite reconciliar um aparente desacordo com a literatura. Os trabalhos recentes que evoluem *foraging* de enxames com aptidões baseadas em retorno acumulado reportam sucesso e escalabilidade, sem qualquer sinal do colapso aqui descrito (Zaman et al., 2025; Biteng et al., 2025). A divergência não é contraditória: as suas arenas são espaços abertos com obstáculos dispersos, nos quais o termo de modelação permanece informativo em todo o percurso e o gradiente de seleção nunca se anula. O planalto de aptidão exige uma condição adicional que essas arenas não satisfazem — um estrangulamento decetivo, no qual a direção que maximiza o termo de modelação é precisamente a que não conduz ao objetivo. É essa a razão pela qual o efeito só se manifesta em cenários como o labirinto em U, e pela qual pode ter passado despercebido a uma literatura que avalia maioritariamente em arenas abertas. A implicação prática é direta: a robustez de uma aptidão não se afere na tarefa fácil, mas na estrutura que a decompõe.

A distribuição da variância pelos cenários é igualmente informativa. O controlador evolutivo é quase determinístico nos labirintos com gradiente geodésico informativo (desvios de 1–2 recolhas/ep nas duas Portas), mas bimodal nos cenários abertos: sem paredes que canalizem o *homing*, a paisagem de aptidão oferece ótimos locais de deambulação dos quais algumas execuções não escapam. O SAC exhibe o padrão inverso — estável em espaço aberto, lotaria nos estrangulamentos físicos —, sugerindo que a exploração por entropia máxima, eficaz em espaço aberto, não gera com fiabilidade as trajetórias longas e coordenadas que atravessam passagens estreitas.

Decorrem duas implicações de engenharia. Primeira, a comparação combina dois fatores — algoritmo de otimização e arquitetura de rede — pelo que integrar o módulo de atenção numa política treinada por gradiente é o passo natural para isolar o efeito do otimizador. Segunda, o valor não está em eleger um vencedor, mas em mapear os eixos de escolha: estrutura do cenário, variabilidade da dimensão do enxame e orçamento de cómputo. Em enxames de dimensão fixa e conhecida, com prioridade na eficiência da tarefa e orçamento de treino curto, o MARL por gradiente é preferível; quando a dimensão é variável ou a missão exige escalar sem retreino, a arquitetura de grafo com atenção é a única opção viável entre as estudadas.

6. Limitações do estudo

Três limitações enquadram o alcance das conclusões. Primeira, e mais importante, a comparação é *assimétrica*: o controlador evolutivo usa uma arquitetura de grafo com atenção, enquanto os *baselines* de gradiente usam um perceptrão multicamada de entrada fixa. Isolar o efeito do otimizador exigiria treinar a mesma arquitetura de atenção por gradiente — o passo natural já identificado. Segunda, sete execuções por configuração, embora suficientes para estabelecer significância na maioria das células, limitam o poder estatístico precisamente onde ele mais faz falta: nos cenários bimodais, distinguir taxas

Tabela 2: Testes de significância sobre as *médias de recolhas por execução* ($n = 7$ por grupo; teste U de Mann–Whitney com δ de Cliff, $\alpha = 0.05$). A unidade independente é a execução de treino, não o episódio. “méd. A” e “méd. B” são as médias de comida recolhida de cada elemento do par.

Cenário	Par	méd. A	méd. B	p	δ	Significativo
Sandbox	GNN vs PPO	38.31	71.46	0.0006	−1.00	Sim
Sandbox	GNN vs SAC	38.31	69.24	0.0021	−1.00	Sim
Sandbox	PPO vs SAC	71.46	69.24	0.0297	+0.71	Sim
Muro em U	GNN vs PPO	24.54	39.62	0.1552	−0.47	não
Muro em U	GNN vs SAC	24.54	8.99	0.5714	+0.18	não
Muro em U	PPO vs SAC	39.62	8.99	0.0526	+0.63	não
Gargalo	GNN vs PPO	121.39	123.17	0.2086	+0.43	não
Gargalo	GNN vs SAC	121.39	41.44	0.0006	+1.00	Sim
Gargalo	PPO vs SAC	123.17	41.44	0.0006	+1.00	Sim
Quatro Salas	GNN vs PPO	59.76	33.58	0.0006	+1.00	Sim
Quatro Salas	GNN vs SAC	59.76	31.82	0.0006	+1.00	Sim
Quatro Salas	PPO vs SAC	33.58	31.82	0.3374	+0.33	não
Porta Cooperativa	GNN vs PPO	69.81	67.06	0.0262	+0.71	Sim
Porta Cooperativa	GNN vs SAC	69.81	62.09	0.0006	+1.00	Sim
Porta Cooperativa	PPO vs SAC	67.06	62.09	0.0175	+0.76	Sim
Percepção Cooperativa	GNN vs PPO	18.98	15.33	0.0297	+0.71	Sim
Percepção Cooperativa	GNN vs SAC	18.98	16.11	0.0297	+0.71	Sim
Percepção Cooperativa	PPO vs SAC	15.33	16.11	0.0547	−0.63	não
Porta c/ Alternativa	GNN vs PPO	86.70	85.25	0.8477	+0.08	não
Porta c/ Alternativa	GNN vs SAC	86.70	68.61	0.0006	+1.00	Sim
Porta c/ Alternativa	PPO vs SAC	85.25	68.61	0.0021	+1.00	Sim

de convergência de 2/7 a 4/7 exigiria uma bateria substancialmente maior. Terceira, todos os resultados são em simulação; a transferência para hardware real introduz o conhecido *reality gap*, cuja mitigação por aleatorização de domínio (Tobin et al., 2017) fica como trabalho futuro. Estas limitações não invalidam os achados centrais — a dependência da neuroevolução face ao desenho da aptidão e o contraste de escalabilidade são robustos e estatisticamente suportados — mas delimitam-nos com honestidade.

7. Conclusões

Apresentamos uma avaliação comparativa imparcial de um controlador de atenção neuroevoluído contra o PPO e o SAC num enxame de *foraging* tridimensional, ao longo de sete cenários e três eixos de avaliação, com sete execuções de treino independentes por combinação e significância aferida ao nível da execução. A hipótese de que a inteligência adaptativa domina a robustez estática é apenas parcialmente confirmada, e o quadro é mais rico do que o antecipado. Com o desenho adequado da aptidão, o controlador evolutivo deixou de ser o elo fraco na tarefa: é estatisticamente superior aos métodos de gradiente em três dos sete cenários, indistinguível do melhor deles em mais dois, e é o único a escalar *zero-shot* até $N = 100$. Os métodos de gradiente preservam a fiabilidade em espaço aberto e uma vantagem de $\approx 8\times$ em núcleos-hora. A exploração sob decepção espacial, que nenhum dos paradigmas base resolveu de forma consistente, cedeu apenas à hibridização com procura por novidade (7/7 execuções no Muro em U, sob orçamento igualado) — um mecanismo que, com peso fixo, degrada simetricamente o desempenho onde o gradiente da tarefa basta, mas cuja dosagem adaptativa, validada numa campanha pré-registada, retém o ganho sem custo mensurável em nenhum dos sete cenários; com o dobro do orçamento, o objetivo puro permanece bimodal

no Muro em U (4/7) e o adaptativo atinge o melhor resultado do estudo no cenário *deceptive* (88.7 ± 0.6). O trabalho futuro inclui uma política de atenção treinada por gradiente para separar o otimizador da arquitetura, o alargamento da bateria estatística nos cenários bimodais, o refinamento do *schedule* adaptativo (re-armamento sob estagnação), e a validação da transferência simulação-para-real (Tobin et al., 2017).

Agradecimentos

This work was partially supported by national funds through Fundação para a Ciência e a Tecnologia, I.P. (FCT), ISTAR-Iscte Pluriannual Projects UID/04466/2025 (<https://doi.org/10.54499/UID/04466/2025>).

Referências

- Bettini, M., Prorok, A., Moens, V., 2024. Benchmarl: Benchmarking multi-agent reinforcement learning. *Journal of Machine Learning Research* 25.
- Biteng, P., Zaman, T.U., Lu, Q., 2025. Training robot swarms for adaptive foraging in environments with obstacles, in: *IEEE International Conference on Mechatronics and Automation (ICMA)*, IEEE. doi:10.1109/ICMA65362.2025.11120654.
- Bredeche, N., Fontbonne, N., 2022. Social learning in swarm robotics. *Philosophical Transactions of the Royal Society B: Biological Sciences* 377, 20200309. doi:10.1098/rstb.2020.0309.
- Chen, X., NaderiAlizadeh, N., Ribeiro, A., Saeedi Bidokhti, S., 2024. Transferable graphical marl for real-time estimation in dynamic wireless networks. *arXiv preprint arXiv:2404.03227*.

- Fontbonne, N., Dauchot, O., Bredeche, N., 2020. Distributed on-line learning in swarm robotics with limited communication bandwidth, in: *IEEE Congress on Evolutionary Computation (CEC)*, IEEE. doi:10.1109/CEC48606.2020.9185697.
- Haarnoja, T., Zhou, A., Abbeel, P., Levine, S., 2018. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor, in: *Proceedings of the 35th International Conference on Machine Learning (ICML)*, pp. 1861–1870.
- Hasselmann, K., Ligot, A., Birattari, M., 2023. Automatic modular design of robot swarms based on repertoires of behaviors generated via novelty search. *Swarm and Evolutionary Computation* 83, 101395. doi:10.1016/j.swevo.2023.101395.
- Huh, D., Mohapatra, P., 2023. Multi-agent reinforcement learning: A comprehensive survey. *arXiv preprint arXiv:2312.10256*.
- Hüttenrauch, M., Šošić, A., Neumann, G., 2019. Deep reinforcement learning for swarm systems. *Journal of Machine Learning Research* 20, 1–31.
- Iskandar, A., Hammoud, A., Kovács, B., 2024. Swarm robotics navigation task: A comparative study of reinforcement learning and particle swarm optimization methodologies. *Mekhatronika, Avtomatizatsiya, Upravlenie* 25, 471–478. doi:10.17587/mau.25.471-478.
- Iskandar, A., Rostum, H., Kovács, B., 2023. Using deep reinforcement learning to solve a navigation problem for a swarm robotics system, in: *2023 24th International Carpathian Control Conference (ICCC)*, IEEE. pp. 185–189.
- Kegeleirs, M., Birattari, M., 2025. Towards applied swarm robotics: current limitations and enablers. *Frontiers in Robotics and AI* 12. doi:10.3389/frobt.2025.1607978.
- Kegeleirs, M., Ramos, D.G., Hasselmann, K., Garattoni, L., Francesca, G., Birattari, M., 2024. Transferability in the automatic off-line design of robot swarms: From sim-to-real to embodiment and design-method transfer across different platforms. *IEEE Robotics and Automation Letters* 9, 2758–2765. doi:10.1109/LRA.2024.3360013.
- Kennedy, J., Eberhart, R., 1995. Particle swarm optimization, in: *Proceedings of ICNN'95 - International Conference on Neural Networks*, IEEE. pp. 1942–1948.
- Lehman, J., Stanley, K.O., 2011. Abandoning objectives: Evolution through the search for novelty alone. *Evolutionary Computation* 19, 189–223. doi:10.1162/EVC0_a_00025.
- Li, X., Zhou, R., Sun, G., 2024. Adaptive shape formation against swarm-scale variants in robot swarms. *IEEE Robotics and Automation Letters* 9. doi:10.1109/LRA.2024.3414210.
- Lowe, R., Wu, Y., Tamar, A., Harb, J., Abbeel, P., Mordatch, I., 2017. Multi-agent actor-critic for mixed cooperative-competitive environments, in: *Advances in Neural Information Processing Systems (NeurIPS)*.
- Majid, A.Y., Saaybi, S., Francois-Lavet, V., Prasad, R.V., Verhoeven, C., 2024. Deep reinforcement learning versus evolution strategies: A comparative survey. *IEEE Transactions on Neural Networks and Learning Systems* 35, 11939–11957.
- Ng, A.Y., Harada, D., Russell, S., 1999. Policy invariance under reward transformations: Theory and application to reward shaping, in: *Proceedings of the 16th International Conference on Machine Learning (ICML)*, pp. 278–287.
- Oliehoek, F.A., Amato, C., 2016. *A Concise Introduction to Decentralized POMDPs*. Springer.
- Ordáz-Rivas, E., Rodríguez-Liñán, A., Torres-Treviño, L., 2026. Multi-objective optimization in autonomous foraging using swarm robots. *Swarm and Evolutionary Computation* 92, 102294. doi:10.1016/j.swevo.2026.102294.
- Salimans, T., Ho, J., Chen, X., Sidor, S., Sutskever, I., 2017. Evolution strategies as a scalable alternative to reinforcement learning. *arXiv preprint arXiv:1703.03864*.
- Schulman, J., Moritz, P., Levine, S., Jordan, M.I., Abbeel, P., 2016. High-dimensional continuous control using generalized advantage estimation, in: *International Conference on Learning Representations (ICLR)*.
- Schulman, J., Wolski, F., Dhariwal, P., Radford, A., Klimov, O., 2017. Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*.
- Szipirer, J., Ramos, D.G., Birattari, M., 2024. Automatic design of robot swarms that perform composite missions: an approach based on inverse reinforcement learning, in: *IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, IEEE. doi:10.1109/IROS58592.2024.10801506.
- Tang, H., Zhang, H., Shi, Z., Chen, X., Ding, W., Zhang, X.P., 2023. Autonomous swarm robot coordination via mean-field control embedding multi-agent reinforcement learning, in: *IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, IEEE. doi:10.1109/IROS55552.2023.10341749.
- Tobin, J., Fong, R., Ray, A., Schneider, J., Zaremba, W., Abbeel, P., 2017. Domain randomization for transferring deep neural networks from simulation to the real world, in: *IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, IEEE. pp. 23–30.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A.N., Kaiser, Ł., Polosukhin, I., 2017. Attention is all you need, in: *Advances in Neural Information Processing Systems (NeurIPS)*.

Veličković, P., Cucurull, G., Casanova, A., Romero, A., Liò, P., Bengio, Y., 2018. Graph attention networks, in: International Conference on Learning Representations (ICLR).

Zaman, T.U., Biteng, P., Lu, Q., 2025. Evolving adaptive foraging robot swarms with NEAT in environments with obstacles, in: 8th International Conference on Intelligent Robotics and Control Engineering (IRCE), IEEE. doi:10.1109/IRCE66030.2025.11203043.

Zhang, H., Cheng, J., Zhang, L., Li, Y., Zhang, W., 2022. H2GNN: Hierarchical-hops graph neural networks for multi-robot exploration in unknown environments. IEEE Robotics and Automation Letters 7, 3435–3442. doi:10.1109/LRA.2022.3146912.