



INSTITUTO
UNIVERSITÁRIO
DE LISBOA

Aprendizagem por Reforço para Controlo de Enxames

Gonçalo Santos

Mestrado em Inteligência Artificial

Orientador:

Doutor Luís Nunes, Professor do Departamento de Ciências e
Tecnologias da Informação,
Iscte – Instituto Universitário de Lisboa

2025

[Página intencionalmente deixada em branco.]

Departamento de Ciências e Tecnologias da Informação

Reinforcement Learning para Controlo de Enxames

Gonçalo Santos

Mestrado em Inteligência Artificial

Orientador:

Doutor Luís Nunes, Professor do Departamento de Ciências e
Tecnologias da Informação,
Iscte – Instituto Universitário de Lisboa

2025

[Página intencionalmente deixada em branco.]

Aos meus pais e a todos que apoiaram este percurso.

[Página intencionalmente deixada em branco.]

Agradecimentos

Gostaria de expressar a minha gratidão aos meus familiares, por me terem apoiado ao longo desta jornada académica, e à minha namorada, por ter estado sempre ao meu lado nos bons e nos maus momentos. Agradeço também aos colegas e amigos que fiz ao longo do tempo, bem como aos professores, por terem dado o seu melhor para nos ensinar. Por fim, agradeço à TAISCTE por ter feito parte deste meu percurso de mestrado.

[Página intencionalmente deixada em branco.]

Resumo

Esta dissertação propõe um estudo comparativo rigoroso entre a Aprendizagem por Reforço Multiagente (MARL) e a Otimização Bio-inspirada para o controlo de enxames robóticos. Através de um simulador de alta fidelidade e da implementação do algoritmo RS2C (baseado em *Graph Neural Networks* ou Redes Neurais em Grafo), pretende-se validar a hipótese de que a inteligência adaptativa supera a robustez estática em cenários de stress dinâmico.

PALAVRAS CHAVE: Robótica de Enxame, MARL, Otimização Bio-inspirada, GNNs.

[Página intencionalmente deixada em branco.]

Índice

Agradecimentos	iii
Resumo	v
Lista de Figuras	ix
Lista de Acrónimos	xi
Capítulo 1. Introdução	1
1.1. Enquadramento e Motivação	1
1.2. Definição do Problema e Justificação da Tese	2
1.3. Objetivos da Tese	3
Capítulo 2. Fundamentos Teóricos e Tecnologias	5
2.1. Introdução ao Capítulo	5
2.2. Swarm Intelligence (SI) e Robótica de Enxame	6
2.3. Paradigmas de Controlo para Enxames	6
2.4. Abordagem 1: Otimização Bio-inspirada	7
2.5. Abordagem 2: Multi-Agent Reinforcement Learning (MARL)	8
Capítulo 3. Estado da Arte	9
3.1. Introdução ao Capítulo	9
3.2. Metodologia da Revisão Sistemática	9
3.3. Análise dos Melhores Resultados	12
3.4. Lacunas Identificadas e Oportunidade de Melhoria	13
3.5. Artigos-Chave e Ligação ao Problema	14
3.6. Conclusão Parcial	14
3.7. Síntese Comparativa da Literatura	15
Capítulo 4. Implementação e Metodologia Experimental	17
4.1. Arquitetura de Software e Stack Tecnológica	17
4.2. Pipeline de Testes e Recolha de Dados	17
4.3. O Ambiente de Simulação	18
4.4. Algoritmo 1: Multi-Agent Reinforcement Learning (RS2C)	19
4.5. Algoritmo 2: Otimização Bio-inspirada (Benchmark)	21
4.6. Métricas de Avaliação	22
4.7. Tratamento Estatístico	22

Capítulo 5. Conclusões e Trabalhos Futuros	23
5.1. Conclusões da Proposta	23
5.2. Contributos Esperados	23
5.3. Trabalhos Futuros (Roadmap)	24
Referências	25

Lista de Figuras

Figura 3.1 Fluxograma PRISMA 2020: Seleção focada em estudos recentes e quantitativos.

12

[Página intencionalmente deixada em branco.]

Lista de Acrónimos

:

[Página intencionalmente deixada em branco.]

CAPÍTULO 1

Introdução

1.1. Enquadramento e Motivação

A robótica de enxame (*Swarm Robotics*), enquanto subcampo da inteligência artificial e dos sistemas multiagente, representa uma mudança de paradigma fundamental na engenharia contemporânea, transitando de arquiteturas monolíticas e robôs complexos para a coordenação de grandes grupos de agentes simples [1]. Esta transição fundamenta-se na premissa de que a inteligência não reside na complexidade individual de cada membro, mas sim na sofisticação das interações locais entre eles. Desde as primeiras conceptualizações em meados da década de 1990 até às aplicações de ponta em 2025, a motivação central deste campo permanece constante: a emulação da inteligência coletiva observada na natureza — como em colónias de formigas ou cardumes — para atingir robustez, flexibilidade e escalabilidade superiores através de comportamento emergente [2], [3].

A urgência no desenvolvimento destes sistemas é impulsionada por aplicações críticas em ambientes de elevada incerteza e perigosidade, tais como a vigilância persistente de infraestruturas, a exploração espacial e a resposta a desastres naturais [4]. Nestes cenários, a redundância intrínseca do enxame é a sua maior vantagem: o sistema é desenhado para ser resiliente a falhas individuais, garantindo que a perda de um único agente não comprometa a integridade da missão global [5].

No entanto, a implementação prática desta visão descentralizada enfrenta barreiras técnicas significativas no que toca ao controlo. Métodos tradicionais, frequentemente dependentes de uma unidade central de processamento ou de modelos matemáticos globais, falham invariavelmente ao escalar o número de agentes (N). Este fenómeno, conhecido como a “explosão da complexidade de interações”, ocorre porque o espaço de estados e ações cresce exponencialmente com o aumento da população do enxame, tornando impossível a programação explícita de todas as contingências operacionais [6]. Conforme discutido por Riviere et al. (2020), a verdadeira escalabilidade exige que as políticas de controlo sejam independentes do número total de agentes, um desafio que as abordagens convencionais ainda têm dificuldade em endereçar de forma eficiente [1].

Neste contexto, a comunidade científica dividiu-se historicamente em duas abordagens principais para o desenho destes controladores descentralizados:

- (1) **Otimização Bio-inspirada:** Métodos como o *Particle Swarm Optimization* (PSO) e Algoritmos Evolutivos (AE) focam-se na robustez *offline* [3]. Tratam o desenho do controlador como um problema de otimização estocástica, procurando os pesos ótimos de uma rede neural ou parâmetros de regras heurísticas antes da

implantação real [7], [8]. Embora robustos, estes métodos tendem a ser estáticos, podendo carecer de adaptabilidade perante mudanças dinâmicas e imprevistas no ambiente [9].

- (2) **Multi-Agent Reinforcement Learning (MARL):** Focado na adaptabilidade *online*, o MARL utiliza o paradigma de aprendizagem sequencial para que os agentes descubram políticas cooperativas através da interação direta com o ambiente [10]. A grande promessa do MARL reside na sua capacidade de ajuste em tempo real e na aprendizagem de políticas complexas formalizadas como um *Decentralized Partially Observable Markov Decision Process* (Dec-POMDP) [11].

A pertinência desta investigação sustenta-se na lacuna identificada por autores como Iskandar et al. (2024), que sublinham a escassez de estudos que comparem diretamente a eficiência e a robustez destas duas escolas em cenários operacionais dinâmicos [12]. Esta tese surge da necessidade urgente de validar qual destas estruturas melhor responde aos desafios de escalabilidade e adaptação exigidos pelas aplicações robóticas de 2025, propondo uma avaliação comparativa rigorosa entre a inteligência adaptativa do MARL e a robustez consolidada da otimização bio-inspirada [13].

1.2. Definição do Problema e Justificação da Tese

Apesar do crescimento exponencial no interesse por sistemas autónomos descentralizados, existe uma lacuna crítica na literatura científica: a escassez de uma comparação direta (*benchmarking*) e rigorosa do desempenho de paradigmas concorrentes em cenários de controlo de enxames que sejam, simultaneamente, complexos e dinâmicos [12], [13]. O estado da arte atual revela que, embora existam múltiplos *frameworks* de controlo, a maioria das investigações foca-se no refinamento de um algoritmo isolado, negligenciando a validação cruzada necessária para determinar a aplicabilidade industrial de cada método [14].

O *Multi-Agent Reinforcement Learning* (MARL), embora promissor devido à sua capacidade de aprender comportamentos emergentes complexos, enfrenta desafios teóricos profundos. Entre estes, destaca-se a **não-estacionaridade** do ambiente: como todos os agentes aprendem e alteram as suas políticas simultaneamente, a dinâmica do sistema do ponto de vista de um agente individual muda constantemente, violando a propriedade de Markov necessária para a convergência de algoritmos tradicionais [11]. Além disso, a explosão do espaço de ações conjuntas em enxames de grande escala dificulta a estabilidade do treino e a otimização de funções de recompensa esparsas.

Por outro lado, os métodos evolutivos e bio-inspirados (como o PSO) têm demonstrado uma robustez consolidada, tratando o controlo como a exploração de uma superfície de *fitness* global [8]. Contudo, como notado por Kegeleirs et al. (2025), estas abordagens resultam frequentemente em controladores estáticos que carecem de adaptabilidade em tempo real perante mudanças estruturais imprevistas no ambiente [15]. Esta rigidez cria o que a literatura denomina como *Deployment Gap* (fosso de implantação), onde algoritmos otimizados em laboratório falham ao enfrentar o ruído e a incerteza do mundo real.

Portanto, a definição do problema desta tese é a **necessidade de uma avaliação comparativa rigorosa e sistemática**. Este estudo visa determinar qual o *framework* de controlo que melhor responde aos desafios práticos do controlo de enxames através de três eixos fundamentais:

- **Desempenho da Tarefa:** Avaliar a eficiência absoluta na concretização de objetivos globais (ex: taxa de cobertura de área ou taxa de recolha em *foraging*). Seguindo a linha de Iskandar et al. (2024), pretende-se quantificar se a convergência mais lenta do MARL resulta, de facto, numa política final superior em eficiência energética comparativamente aos métodos bio-inspirados [12].
- **Escalabilidade (Zero-Shot Transfer):** Analisar como a *performance* se degrada à medida que o número de agentes (N) aumenta para além do cenário de treino. É crucial validar se as arquiteturas baseadas em *Graph Neural Networks* (GNNs), defendidas por Sun et al. (2024), permitem uma escalabilidade superior face à rigidez dos controladores evolutivos fixos [16].
- **Robustez e Adaptação Dinâmica:** Testar a resiliência do sistema perante a perda súbita de agentes (falhas de *hardware*) ou a introdução de obstáculos móveis imprevistos. O objetivo é verificar se a capacidade de aprendizagem contínua do MARL compensa a sua complexidade de implementação face à estabilidade *offline* dos algoritmos evolutivos.

Esta tese justifica-se pela urgência de transformar o controlo de enxames de uma disciplina puramente teórica numa ferramenta de engenharia fiável. Através do uso de um simulador de alta-fidelidade, este trabalho pretende fornecer dados quantitativos que orientem a escolha do paradigma de controlo em função dos requisitos de missão e da disponibilidade de recursos computacionais.

1.3. Objetivos da Tese

Com base na definição do problema e na lacuna de investigação identificada na literatura recente, o objetivo geral desta dissertação é **desenvolver um *framework* de simulação de alta-fidelidade e realizar um *benchmarking* comparativo rigoroso entre o *Multi-Agent Reinforcement Learning* (MARL) e algoritmos de otimização bio-inspirados** (e.g., Algoritmos Evolutivos) aplicados ao controlo descentralizado de enxames [15], [17]. Pretende-se determinar, de forma quantitativa, em que condições a inteligência adaptativa e emergente do MARL supera a robustez estática das abordagens de otimização tradicionais [18].

Para atingir o objetivo geral, foram definidos os seguintes objetivos específicos:

- **Desenvolver um Ambiente de Simulação de Referência:** Projetar e implementar um simulador em ambiente Python capaz de modelar tarefas fundamentais de enxame, como vigilância cooperativa e *foraging* dinâmico [13]. O ambiente deve contemplar modelos físicos realistas, restrições de comunicação

(r_c) e a simulação de falhas súbitas de agentes para testar a resiliência do sistema [5].

- **Implementar um Framework MARL Escalável (RS2C):** Desenvolver o algoritmo *Robust and Scalable Swarm Control* (RS2C) baseado na arquitetura de Treino Centralizado com Execução Descentralizada (CTDE) [16]. Este objetivo inclui a integração de *Graph Attention Networks* (GATs) para garantir a invariância à permutação, permitindo que a política aprendida seja aplicada a enxames de diferentes dimensões (N) sem necessidade de retreino (*Zero-Shot Transfer*).
- **Implementar Baselines de Otimização Bio-inspirada:** Desenvolver controladores baseados em Algoritmos Evolutivos (AE) ou *Particle Swarm Optimization* (PSO) para servirem como termo de comparação de desempenho [7]. Estes controladores serão otimizados *offline* para encontrar os pesos ótimos de redes neurais estáticas, representando o paradigma de robustez pré-programada [3].
- **Realizar uma Análise Comparativa e Estatística:** Executar experiências controladas utilizando as métricas de performance da tarefa, escalabilidade e robustez a perturbações [12]. Os resultados deverão ser validados através de tratamento estatístico rigoroso (e.g., testes *t-student*), garantindo que as conclusões sobre a superioridade de um paradigma sobre o outro são cientificamente sustentadas.

CAPÍTULO 2

Fundamentos Teóricos e Tecnologias

2.1. Introdução ao Capítulo

Este capítulo estabelece os fundamentos teóricos e os alicerces tecnológicos necessários para uma compreensão aprofundada do controlo descentralizado de enxames. A transição de sistemas robóticos isolados para coletivos coordenados exige uma base conceptual que interliga a biologia, a engenharia de controlo e a aprendizagem automática avançada. Assim, o presente capítulo visa dotar a dissertação do rigor matemático e técnico indispensável para suportar a investigação proposta.

Em primeiro lugar, serão definidos e contextualizados os conceitos de *Swarm Intelligence* (SI) e *Swarm Robotics* (SR). Esta análise inicial é fundamental para compreender como comportamentos globais complexos e auto-organizados podem emergir a partir de regras de interação locais extremamente simples. Conforme discutido por Riviere et al. (2020), a robustez destes sistemas reside precisamente na sua natureza descentralizada, o que impõe desafios únicos ao desenho de controladores eficientes.

Posteriormente, o foco incidirá sobre as duas principais classes de paradigmas de controlo que constituem o núcleo do *benchmarking* desta tese:

- (1) **Otimização Bio-inspirada:** Serão explorados algoritmos como a Otimização por Enxame de Partículas (*Particle Swarm Optimization* - PSO) e os Algoritmos Evolutivos (AE). Estas técnicas tratam o controlo como um problema de busca num espaço de parâmetros global, focando-se na convergência para soluções estáveis e robustas em cenários estáticos.
- (2) **Multi-Agent Reinforcement Learning (MARL):** Será introduzida a formalização matemática do problema através do modelo de Processo de Decisão de Markov Parcialmente Observável Descentralizado (*Dec-POMDP*). Esta secção detalhará como a aprendizagem por reforço permite a emergência de políticas adaptativas através da interação *online*, abordando conceitos críticos como a arquitetura *Centralized Training with Decentralized Execution* (CTDE) e o papel das *Graph Neural Networks* (GNNs) na garantia da escalabilidade do enxame, tal como defendido por Sun et al. (2024).

Ao estabelecer estas definições, este capítulo permite identificar o “Deployment Gap” (fosso de implantação) discutido por Kegeleirs et al. (2025), justificando a necessidade de uma metodologia rigorosa para validar a transição destes algoritmos do domínio da simulação para aplicações reais de alta fidelidade [15].

2.2. Swarm Intelligence (SI) e Robótica de Enxame

A Inteligência de Enxame (*Swarm Intelligence* - SI) refere-se ao comportamento coletivo e coordenado de sistemas descentralizados e auto-organizados, sejam eles naturais ou artificiais [2]. Este paradigma baseia-se na observação de sistemas biológicos — tais como colônias de formigas, enxames de abelhas ou cardumes de peixes — onde agentes individuais com capacidades cognitivas limitadas conseguem, através de interações sociais simples, resolver problemas de elevada complexidade que excederiam a capacidade de qualquer indivíduo isolado [3].

A Robótica de Enxame (*Swarm Robotics* - SR) surge como a aplicação direta dos princípios de SI ao domínio de sistemas multi-robô [15]. Ao contrário da robótica cooperativa tradicional, a SR foca-se na coordenação de um grande número de agentes, tipicamente homogêneos e de baixo custo, que operam sem uma infraestrutura de controlo centralizada ou um mapa global do ambiente. O controlo nestes sistemas é inerentemente distribuído, o que confere ao coletivo três propriedades fundamentais identificadas na literatura:

- **Robustez:** A redundância do sistema garante que a missão prossiga mesmo perante a falha de múltiplos agentes [1].
- **Escalabilidade:** O sistema mantém a sua eficiência independentemente da dimensão do enxame (N), uma vez que as interações são predominantemente locais.
- **Flexibilidade:** O enxame consegue adaptar-se a diferentes tarefas e ambientes dinâmicos sem necessidade de reprogramação externa.

O alicerce técnico destes sistemas reside no comportamento emergente. Conforme discutido por Riviere et al. (2020), as ações globais coordenadas emergem de um ciclo de *feedback* contínuo entre regras de interação locais simples e o ambiente. Um mecanismo crítico para esta emergência é a **estigmergia**, um método de coordenação indireta onde os agentes alteram o ambiente (por exemplo, através de trilhos de feromonas ou comunicação local ruidosa), influenciando as ações subsequentes de outros membros do grupo.

No entanto, projetar manualmente estas regras locais para atingir um objetivo global específico é um desafio de engenharia não trivial. Como não existe um “conhecimento global” partilhado, o desenho do controlador deve garantir que a soma das micro-decisões individuais resulte na macro-estabilidade do enxame. Este desafio justifica a exploração de métodos de Aprendizagem Automática Avançada, onde, em vez de programar regras explícitas, o sistema “aprende” ou “evolui” as interações ótimas através de reforço ou otimização.

2.3. Paradigmas de Controlo para Enxames

O controlo de sistemas multi-robô em larga escala foca-se primordialmente no desenho das chamadas “regras locais” de interação. O desafio fundamental reside na resolução do problema inverso da robótica de enxame: como determinar comportamentos individuais simples que, quando executados em paralelo, resultem numa macro-estabilidade e no

cumprimento de um objetivo global. Existem duas abordagens principais na literatura contemporânea que esta tese se propõe a analisar e comparar:

(1) **Otimização Bio-inspirada (Offline):** Esta categoria abrange duas subfamílias principais frequentemente utilizadas em robótica:

- **Algoritmos Evolutivos (AE):** Inspirados na seleção natural (Darwin), utilizam operadores como mutação e cruzamento para evoluir uma população de controladores ao longo de gerações.
- **Inteligência de Enxame (SI):** Inspirados em comportamentos sociais (e.g., bandos de pássaros), como o *Particle Swarm Optimization* (PSO), onde a solução emerge do movimento cooperativo de partículas no espaço de busca.

Ambas as abordagens procuram *offline* o melhor conjunto de parâmetros fixos, maximizando uma função de *fitness*. Embora gerem comportamentos robustos, resultam frequentemente em controladores rígidos perante mudanças ambientais não previstas.

(2) **Aprendizagem por Reforço (Online/Adaptativa):** ... (o resto mantém-se)

Esta distinção é crucial para o *benchmarking* proposto, pois permite avaliar se o custo computacional e a complexidade de treino da aprendizagem automática são justificados por um ganho real em adaptabilidade face às soluções otimizadas tradicionais.

2.4. Abordagem 1: Otimização Bio-inspirada

Esta abordagem utiliza algoritmos de busca meta-heurística para navegar no vasto espaço de parâmetros θ de um controlador — frequentemente representado por uma rede neuronal (*Neuroevolution*) ou uma máquina de estados — com o intuito de maximizar uma função de desempenho global $J(\theta)$.

Algoritmos Evolutivos (AE): Inspirados pelos mecanismos da seleção natural, os AEs mantêm uma população diversificada de controladores candidatos. Estes sofrem iterativamente processos de seleção (baseada na *fitness*), recombinação (cruzamento de parâmetros) e mutação (introdução de variações aleatórias). Este ciclo de “geração e teste” permite explorar espaços de busca não-lineares e complexos sem necessidade de gradientes, sendo particularmente eficaz na descoberta de heurísticas robustas para tarefas como a formação de padrões ou a navegação em grupo.

Otimização por Enxame de Partículas (PSO): O PSO modela cada controlador candidato como uma “partícula” que navega num espaço de busca multidimensional. A inovação crucial deste método reside na partilha de informação social: cada partícula ajusta a sua velocidade e posição baseada na sua melhor experiência pessoal (*pBest*) e na melhor experiência coletiva descoberta por todo o enxame (*gBest*). Estudos de Hassen e Amin (2025) demonstram que variantes modernas de PSO são extremamente eficientes na navegação reativa, embora a convergência do enxame indique tipicamente a descoberta de

um controlador estático que pode falhar em cenários onde a topologia do problema muda subitamente [7].

2.5. Abordagem 2: Multi-Agent Reinforcement Learning (MARL)

O MARL representa a fronteira da Aprendizagem Automática aplicada a sistemas coletivos, focando-se na aprendizagem de políticas adaptativas (π) através da interação sequencial. O problema é formalizado matematicamente como um **Processo de Decisão de Markov Parcialmente Observável Descentralizado (Dec-POMDP)**, definido pela tupla $\langle \mathcal{I}, \mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R}, \Omega, \mathcal{O}, \gamma \rangle$, onde os agentes devem maximizar o retorno esperado com base em observações locais e incompletas do estado global [10], [11].

O Desafio da Não-Estacionaridade: A principal barreira teórica na aplicação de MARL a enxames é a não-estacionaridade do ambiente. Num sistema multiagente, as transições de estado para um agente i dependem das ações de todos os outros agentes. Como todos os robôs estão a aprender e a alterar as suas políticas simultaneamente, a dinâmica do ambiente é instável, o que viola a propriedade fundamental de Markov e dificulta a convergência dos algoritmos tradicionais de agente único.

Arquitetura CTDE e Escalabilidade com GNNs: Para mitigar a instabilidade, utiliza-se a arquitetura de **Treinamento Centralizado com Execução Descentralizada (CTDE)**. Nesta abordagem, um componente “Crítico” tem acesso ao estado global durante a fase de treino para estabilizar os sinais de recompensa, enquanto o “Ator” (controlador do robô) utiliza apenas observações locais durante a fase de execução [16].

Contudo, para garantir que o enxame é verdadeiramente escalável, a investigação moderna tem integrado **Graph Neural Networks (GNNs)** e mecanismos de atenção espacial. Ao modelar o enxame como um grafo dinâmico $G = (V, E)$, onde os nós são robôs e as arestas são ligações de comunicação, é possível aprender políticas invariantes ao número de agentes. Como demonstrado por Sun et al. (2024), esta abordagem permite o **Zero-Shot Transfer**, onde um controlador treinado com um pequeno grupo de agentes pode ser diretamente aplicado a enxames de centenas de robôs sem necessidade de retreino [16]. Esta tese visa precisamente validar se este paradigma de aprendizagem adaptativa supera as limitações de rigidez das abordagens bio-inspiradas em cenários de stress dinâmico [5].

CAPÍTULO 3

Estado da Arte

3.1. Introdução ao Capítulo

Este capítulo apresenta uma Revisão Sistemática da Literatura (SLR) rigorosa, centrada nos paradigmas de controlo de enxames discutidos no capítulo anterior. Numa área em constante evolução como a Robótica de Enxame, onde as publicações científicas transitaram das conceptualizações iniciais da década de 1990 para aplicações críticas e complexas em 2025, torna-se imperativo adotar um método de análise que seja simultaneamente metódico e reproduzível. O objetivo primordial desta revisão não é apenas sumarizar o conhecimento existente, mas sim analisar de que forma a Aprendizagem Automática — especificamente o *Multi-Agent Reinforcement Learning* (MARL) — e os métodos de Otimização Bio-inspirada (como o PSO e AE) têm convergido ou divergido na resolução de problemas de coordenação descentralizada [4].

A motivação para esta análise sistemática reside na observação de que a comunidade científica tem, historicamente, operado em silos: a literatura de MARL foca-se predominantemente na estabilidade do treino sob condições de não-estacionaridade, enquanto a literatura de otimização prioriza a robustez de controladores estáticos. Esta divisão tem dificultado a realização de confrontos diretos que validem qual o paradigma mais resiliente perante o chamado “Deployment Gap” (fosso de implantação). Conforme discutido por Iskandar et al. (2024), a falta de um referencial comum de desempenho impede uma compreensão clara de quando a adaptabilidade *online* compensa a complexidade computacional do treino em larga escala [12].

Desta forma, a estrutura desta SLR foca-se em identificar e mapear as lacunas de *benchmarking* que justificam a necessidade desta dissertação. Através da taxonomia aqui apresentada, serão exploradas as tendências de escalabilidade via *Graph Neural Networks* (GNNs), defendidas por Sun et al. (2024), e as abordagens de hibridização emergentes que tentam fundir a eficácia dos algoritmos evolutivos com a flexibilidade do RL [16], [19]. Ao finalizar este capítulo, será possível sustentar a validade da metodologia proposta no Capítulo 4 como a resposta necessária às limitações encontradas na literatura contemporânea [15].

3.2. Metodologia da Revisão Sistemática

Para garantir o rigor científico, a reprodutibilidade e a transparência no processo de seleção da informação, foi adotada uma metodologia baseada no protocolo PRISMA (*Preferred Reporting Items for Systematic Reviews and Meta-Analyses*, versão 2020). A adoção deste

protocolo permite mitigar o viés de seleção e assegurar que a análise crítica das tecnologias MARL e de otimização bio-inspirada se fundamenta numa amostra representativa e qualificada da literatura contemporânea.

3.2.1. Critérios de Seleção e Rigor Técnico

A pesquisa priorizou bases de dados com elevado fator de impacto na área da computação e robótica: **IEEE Xplore**, **ACM Digital Library** e **Scopus**. Fontes genéricas ou não indexadas foram descartadas para garantir a qualidade da *baseline*.

O critério de inclusão principal focou-se na formalização matemática do problema: foram selecionados apenas estudos que modelassem o controlo de enxame como um **Processo de Decisão de Markov Parcialmente Observável Descentralizado (Dec-POMDP)** ou problemas de otimização equivalentes. Artigos anteriores a 2020 ou que apresentassem abordagens puramente teóricas sem validação em simulação dinâmica foram excluídos na fase de triagem, garantindo que o Estado da Arte reflete apenas as tecnologias de ponta atuais.

3.2.2. Protocolo de Pesquisa e Bases de Dados

A fase de levantamento bibliográfico foi conduzida entre Setembro e Outubro de 2025, recorrendo a fontes de dados fidedignas e amplamente reconhecidas pela comunidade científica. O fluxo de trabalho, desde a captura inicial até à leitura técnica detalhada, foi centralizado na plataforma **Mendeley**. Esta ferramenta foi crucial não apenas para a organização dos artigos, mas também para a gestão automática de metadados, deteção de duplicados e anotação técnica, garantindo a integridade e a rastreabilidade da bibliografia apresentada ao longo da dissertação.

As bases de dados científicas indexadas foram selecionadas estrategicamente para cobrir tanto a especificidade técnica da engenharia como o impacto global das publicações:

- **IEEE Xplore e ACM Digital Library:** Consultadas pela sua especialização em computação, robótica e engenharia eletrotécnica, onde se encontram os principais desenvolvimentos em algoritmos de controlo descentralizado.
- **Scopus e Google Scholar:** Utilizadas para garantir uma abrangência multidisciplinar e capturar artigos de alto impacto e revisões de literatura que estabelecem o estado da arte em inteligência artificial.

A *string* de pesquisa foi desenhada utilizando operadores booleanos para capturar a interseção precisa entre o domínio da Robótica de Enxame e as soluções tecnológicas em análise:

("Swarm Robotics"OR "Multi-Robot Systems") AND ("Reinforcement Learning"OR "MARL"OR "Bio-inspired Optimization"OR "PSO") AND ("Control"OR "Navigation").

Esta combinação de termos permitiu filtrar estudos que abordassem simultaneamente o paradigma de controlo (MARL ou Otimização) e a aplicação prática em enxames (Navegação/Controlo), excluindo automaticamente literatura focada em agentes isolados ou aplicações puramente teóricas sem componente robótica.

3.2.3. Processo de Seleção (Fluxo PRISMA)

O rigor do processo de seleção é fundamental para assegurar que o corpo de literatura analisado é robusto e diretamente relevante para os objetivos desta dissertação. O fluxo de trabalho seguiu três fases críticas, documentadas detalhadamente no fluxograma da Figura 3.1:

- (1) **Identificação:** A pesquisa inicial nas bases de dados selecionadas retornou um total de **145 artigos**. Todos os registos foram importados para o software **Mendeley**, facilitando a triagem inicial e a deteção de duplicados. Após a remoção automática e manual de 25 duplicados, restaram 120 registos únicos para análise de mérito.
- (2) **Triagem (Screening):** Foram **excluídos 60 artigos após a leitura integral de títulos e resumos**. O principal critério de exclusão nesta fase residiu no desvio do âmbito técnico, nomeadamente estudos focados exclusivamente em biologia animal teórica ou sistemas robóticos de agente único, que não oferecem contributos para a problemática da coordenação descentralizada.
- (3) **Elegibilidade:** Dos restantes 60 artigos lidos na íntegra, 34 foram excluídos por apresentarem falta de dados comparativos quantitativos ou metodologias obsoletas que não consideravam ambientes dinâmicos e ruidosos. Esta fase foi crucial para garantir que apenas estudos com validade estatística e relevância para o controlo de enxames moderno fossem retidos.

No final deste processo, **26 artigos** foram selecionados para a fase de análise qualitativa e extração de dados técnicos, servindo de base para a taxonomia apresentada de seguida.




FIGURA 3.1. Fluxograma PRISMA 2020: Seleção focada em estudos recentes e quantitativos.

3.3. Análise dos Melhores Resultados

3.3.1. Subgrupo A: Otimização Bio-inspirada (A Referência de Eficiência)

Os estudos mais relevantes neste grupo, como o de **Hassen e Amin (2025)**, demonstram que variantes híbridas de PSO continuam a deter o recorde de eficiência energética em mapas estáticos. Os resultados indicam que, quando o ambiente não muda, a otimização *offline* converge para soluções com 98% de otimalidade, servindo como uma *baseline* extremamente difícil de bater para o RL. Contudo, estes mesmos estudos reportam quebras de performance superiores a 40% quando são introduzidos obstáculos móveis não previstos no treino inicial [7].

3.3.2. Subgrupo B: MARL e Escalabilidade (O Estado da Arte)

A literatura de MARL abandonou abordagens simplistas (como Q-Learning tabular) em favor de arquiteturas baseadas em grafos. O trabalho de destaque de **Sun et al. (2024)** prova que o uso de **Graph Neural Networks (GNNs)** permite reduzir o erro de estimação em 25% comparado com métodos de atenção padrão. Mais importante, demonstraram que uma política treinada com apenas 10 agentes mantém a coerência operacional com 100 agentes (*Zero-Shot Transfer*), validando o uso de GNNs para resolver o problema da dimensionalidade dos modelos de Markov [16].

Recentemente, Xiao et al. (2026) propuseram o método CSPER, destacando que abordagens de RL sofrem de fraca exploração em ambientes complexos de navegação devido a recompensas esparsas [20]. Este trabalho reforça a necessidade de mecanismos de recompensa densos, como os propostos nesta tese. Paralelamente, Roveda (2026) explorou a hibridização entre RL e Algoritmos Evolutivos para manipulação adaptativa, sugerindo que a combinação dos dois mundos pode mitigar a incerteza em ambientes não estruturados [21].

3.4. Lacunas Identificadas e Oportunidade de Melhoria

A revisão sistemática da literatura permitiu consolidar a evidência de que a principal barreira ao avanço da robótica de enxame não reside na escassez de algoritmos, mas sim na **falha sistemática de rigor comparativo** entre paradigmas distintos. Observou-se que as comunidades de *Multi-Agent Reinforcement Learning* (MARL) e de Otimização Bio-inspirada operam em silos metodológicos quase estanques:

- A comunidade de aprendizagem foca-se primordialmente na estabilidade do treino e na superação da não-estacionaridade, testando novos algoritmos (ex: MAPPO, QMIX) contra variantes de RL, negligenciando baselines de otimização consolidada [13].
- A comunidade de otimização foca-se na eficiência energética e otimalidade em cenários estáticos, ignorando a flexibilidade que a aprendizagem adaptativa pode oferecer em tempo real [8].

Esta fragmentação resulta numa negligência crítica de testes de *stress* dinâmico, como a falha súbita de 10% do enxame ou alterações abruptas na topologia de comunicação. Conforme identificado por Kegeleirs et al. (2025), esta ausência de testes em ambientes ruidosos e imprevisíveis constitui o principal entrave à transição dos enxames para aplicações industriais e de busca e salvamento [15].

Esta tese pretende melhorar este cenário ao propor um *benchmark* que transcende a simples métrica de performance final, focando-se na **capacidade de recuperação e adaptação** perante perturbações dinâmicas. A oportunidade de melhoria reside na utilização de *Graph Neural Networks* (GNNs), que permitem modelar o enxame como um grafo dinâmico $G = (V, E)$ [16]. Esta abordagem garante a invariância à permutação e a escalabilidade necessárias para superar a rigidez dos métodos bio-inspirados, permitindo

que o sistema mantenha a coesão e a eficácia mesmo quando a estrutura do coletivo é alterada por eventos externos imprevistos.

3.5. Artigos-Chave e Ligação ao Problema

Para fundamentar cientificamente a definição do problema desta tese, foram selecionados seis artigos críticos que mapeiam os avanços e as limitações tecnológicas de 2020 a 2025:

- (1) **Sun et al. (2024)**: Este trabalho é fundamental por demonstrar a eficácia das **GNNs** na minimização do erro de estimação em enxames totalmente descentralizados, validando a arquitetura tecnológica de base escolhida para o simulador desta tese [16].
- (2) **Elrod et al. (2025)**: Explora o potencial de arquiteturas baseadas em **Transformers** para a coordenação multiagente, destacando como a atenção espacial é superior aos métodos de agregação simples para manter a coesão do grupo em tarefas dinâmicas [22].
- (3) **Heimann et al. (2024)**: Introduce o conceito de **Safe MARL**, integrando métodos de verificação em tempo real no processo de aprendizagem para mitigar o risco de colisões catastróficas, uma preocupação central para a implantação em sistemas físicos reais [18].
- (4) **Iskandar et al. (2024)**: Realiza um dos raros **benchmarking diretos** entre Q-Learning e PSO, concluindo que o RL atinge maior eficiência energética após treino extensivo, o que reforça a hipótese de que a aprendizagem adaptativa justifica a sua complexidade computacional [12].
- (5) **Kegeleirs et al. (2025)**: Identifica criticamente as limitações na transição da simulação para a realidade (*sim-to-real*), apontando a ausência de testes em ambientes ruidosos e com falhas de comunicação como o principal obstáculo à adoção industrial [15].
- (6) **Zheng et al. (2025)**: Propõe o *framework* **LNS2+RL**, demonstrando que a hibridização entre pesquisa local e aprendizagem por reforço é a via mais eficaz para resolver problemas de *pathfinding* em larga escala com obstáculos móveis [19].

3.6. Conclusão Parcial

O Estado da Arte validou a escolha da aprendizagem automática avançada, particularmente através de modelos de MARL descentralizados, como o paradigma com maior potencial para o desenvolvimento de sistemas de controlo verdadeiramente adaptativos [5]. A literatura recente confirma que, embora os métodos bio-inspirados continuem a definir linhas de base robustas para tarefas estáticas, a sua limitação de adaptação *online* restringe a sua utilidade em ambientes de alta incerteza [5].

No entanto, a manifesta escassez de dados comparativos quantitativos entre as versões modernas de MARL (utilizando GNNs e Transformers) e variantes avançadas de PSO e Algoritmos Evolutivos em tarefas dinâmicas justifica a necessidade da metodologia

proposta no capítulo seguinte [12]. Este trabalho propõe-se a preencher este vazio, fornecendo as métricas necessárias para determinar quando a complexidade computacional da aprendizagem compensa, de facto, a robustez pré-programada da otimização tradicional.

3.7. Síntese Comparativa da Literatura

A Tabela 3.1 apresenta uma síntese dos estudos mais relevantes analisados, destacando a abordagem utilizada e as limitações que motivam a presente dissertação.

TABELA 3.1. Resumo dos artigos mais relevantes e identificação de lacunas.

Referência	Paradigma	Contributo Principal	Limitação / Gap Identificada
Sun et al. (2024) [16]	MARL (GNN)	Demonstra escalabilidade (Zero-Shot) de 10 para 100 agentes usando GNNs.	Foca-se apenas na minimização do erro de estimação, sem obstáculos físicos complexos.
Hassen & Amin (2025) [7]	Bio-inspirado (PSO)	Alta eficiência energética (98% otimalidade) em mapas estáticos.	Performance degrada-se 40% com obstáculos móveis (falta de adaptação online).
Heimann et al. (2024) [18]	Safe MARL	Introduz verificação em tempo real para evitar colisões durante o treino.	Avaliado em ambientes simplificados, sem comparação com métodos evolutivos.
Iskandar et al. (2024) [12]	Híbrido	Comparação direta inicial entre Q-Learning e PSO.	Cenário de navegação simples; não testa falhas de agentes ou "stress" do enxame.
Kegeleirs et al. (2025) [15]	Review	Identifica o "Deployment Gap" como barreira principal.	Trabalho teórico; não propõe uma solução algorítmica direta.

Esta análise tabular reforça que, embora existam soluções robustas para problemas isolados (escalabilidade ou segurança), falta uma validação integrada que compare a **adaptabilidade dinâmica** do MARL contra a **eficiência estática** do PSO sob condições de falha.

[Página intencionalmente deixada em branco.]

Implementação e Metodologia Experimental

4.1. Arquitetura de Software e Stack Tecnológica

Para assegurar a viabilidade técnica e a reprodutibilidade dos resultados, a implementação do sistema foi desenhada com base nas tecnologias padrão da indústria para Inteligência Artificial. A arquitetura proposta privilegia a flexibilidade e o desempenho computacional.

4.1.1. Ambiente de Simulação e Interação

O desenvolvimento será centralizado na linguagem **Python** (versão 3.x), escolhida pela sua vasta comunidade e suporte a bibliotecas científicas.

- **Motor de Simulação:** Prevê-se a utilização de ambientes compatíveis com a norma **OpenAI Gym** ou **PettingZoo**. Estas interfaces padronizadas permitem a abstração da física dos agentes, facilitando a troca entre diferentes cenários (Vigilância ou *Foraging*) sem reescrever o código base do algoritmo.
- **Observação Local:** O ambiente será configurado para fornecer observações parciais baseadas no raio de comunicação r_c , garantindo que os agentes operam num regime descentralizado real.

4.1.2. Implementação dos Algoritmos (Deep Learning)

A construção das redes neuronais e o treino dos agentes MARL apoiar-se-ão em *frameworks* de computação tensorial de alto desempenho:

- **Framework de Aprendizagem:** A implementação de referência utilizará bibliotecas como **PyTorch** ou **TensorFlow**. A escolha recairá preferencialmente sobre o PyTorch devido ao seu suporte nativo para grafos dinâmicos (essencial para GNNs) e facilidade de depuração.
- **Aceleração de Hardware:** O código será otimizado para tirar partido de aceleração por GPU (e.g., via CUDA), permitindo a execução paralela de múltiplos ambientes para recolha massiva de experiências em tempo útil.

4.2. Pipeline de Testes e Recolha de Dados

Para garantir a integridade estatística, o *pipeline* experimental será automatizado para executar múltiplas *runs* independentes (com diferentes sementes aleatórias). Os dados de telemetria da simulação — posições, recompensas acumuladas e colisões — serão armazenados em formatos estruturados (como CSV ou HDF5) para posterior análise de dados e geração de gráficos comparativos.

4.3. O Ambiente de Simulação

Para garantir uma comparação justa e cientificamente rigorosa, todos os algoritmos são testados num ambiente de simulação de alta fidelidade desenvolvido especificamente em linguagem **Python** [13]. O simulador foi projetado para colmatar o *Deployment Gap* (fosso de implantação), modelando com precisão a física dos agentes, os limites de comunicação representados pelo raio crítico (r_c) e as restrições sensoriais do ambiente da tarefa [15].

A escolha de um ambiente de simulação controlado permite a execução de múltiplos ensaios estatísticos necessários para validar a robustez dos algoritmos. O modelo físico considera as dinâmicas de movimento e a detecção de colisões, assegurando que os resultados obtidos sejam transponíveis para aplicações reais de robótica de enxame.

4.3.1. Cenários de Tarefa

Para garantir uma avaliação exaustiva das capacidades de controlo descentralizado, a metodologia propõe a segmentação dos testes em dois cenários experimentais fundamentais [8]. Estes cenários foram desenhados para isolar e medir diferentes facetas da inteligência coletiva, permitindo comparar de forma direta a otimalidade em condições ideais versus a adaptabilidade em condições de stress.

- **Vigilância Cooperativa (Cenário Estático):** Neste cenário, o enxame composto por N agentes tem como objetivo primordial maximizar a cobertura visual de uma área geográfica delimitada. Esta tarefa representa um problema clássico de otimização espacial, onde os robôs devem dispersar-se de forma eficiente para minimizar a sobreposição sensorial. A métrica central é a percentagem da área total observada no final de um intervalo de tempo T [7]. Este cenário serve para estabelecer a *baseline* de desempenho máximo atingível em condições ideais, sem perturbações externas, permitindo avaliar se os algoritmos bio-inspirados (como o PSO), conhecidos pela sua eficácia em problemas de otimização estática, conseguem atingir a otimalidade de Pareto de forma mais célere que o MARL [3].
- **Foraging Dinâmico (Cenário Adaptativo):** Este cenário constitui o núcleo da investigação sobre a resiliência do sistema e a capacidade de adaptação em tempo real [23]. O enxame é incumbido de localizar e recolher recursos num ambiente inicialmente conhecido, mas que sofre alterações estruturais imprevistas durante a missão. As perturbações introduzidas incluem o surgimento súbito de obstáculos móveis e a falha catastrófica de agentes (10% do enxame), simulando as condições adversas identificadas por Kegeleirs et al. (2025) como críticas para a viabilidade industrial [15]. Este cenário é fundamental para testar a hipótese central desta tese: que a política adaptativa do MARL, fundamentada em aprendizagem *online*, demonstra uma superioridade operacional ao superar a

rigidez das heurísticas otimizadas *offline*, as quais tendem a degradar-se significativamente quando confrontadas com contingências não previstas na sua fase de treino [5].

Para assegurar a validade estatística e a escalabilidade das soluções, ambos os cenários são submetidos a testes de *stress* variando o número de agentes ($N \in \{10, 20, 50, 100\}$) sem necessidade de retreino (*Zero-Shot Transfer*) [16]. Cada experiência é executada 30 vezes ($N_{runs} = 30$), permitindo um tratamento estatístico rigoroso através de testes de hipótese com um nível de significância de 5% ($p < 0.05$), conforme recomendado para investigações de Aprendizagem Automática Avançada [13].

4.4. Algoritmo 1: Multi-Agent Reinforcement Learning (RS2C)

A primeira abordagem investigada nesta tese fundamenta-se no paradigma de Aprendizagem Automática Avançada, materializado no *framework* **Robust and Scalable Swarm Control (RS2C)**. Este algoritmo foi desenhado para superar as limitações de rigidez das heurísticas manuais, utilizando a arquitetura de **Treino Centralizado com Execução Descentralizada (CTDE)**.

Esta arquitetura permite que, durante a fase de treino, o sistema tenha acesso a informações globais para estabilizar a aprendizagem — mitigando o problema da não-estacionaridade intrínseco a sistemas multiagente — enquanto na fase de execução os agentes operam de forma puramente autónoma, baseando as suas decisões exclusivamente em observações locais e processamento distribuído.

4.4.1. Formulação do Problema (Dec-POMDP)

A coordenação de um enxame robótico é formalizada nesta investigação como um **Processo de Decisão de Markov Parcialmente Observável Cooperativo (Dec-POMDP)**. Esta formalização é essencial, pois assume que nenhum agente possui uma visão completa do estado global do sistema ($\mathcal{S}$), mas sim uma perceção local e potencialmente ruidosa ($\mathcal{O}$). O modelo é definido pela tupla matemática:

$$\langle \mathcal{N}, \mathcal{S}, \{\mathcal{A}_i\}_{i \in \mathcal{N}}, \mathcal{P}, \mathcal{R}, \Omega, \{\mathcal{O}_i\}_{i \in \mathcal{N}}, \gamma \rangle \quad (4.1)$$

Onde os componentes são detalhados da seguinte forma:

- $\mathcal{N}$: Representa o conjunto de n agentes homogêneos que compõem o enxame;
- $\mathcal{S}$: O espaço de estados globais que descreve a configuração completa do ambiente e dos agentes;
- $\mathcal{A}_i$: O espaço de ações disponíveis para cada agente i ;
- $\mathcal{P}(s'|s, \mathbf{a})$: A função de transição que define a probabilidade do sistema transitar para o estado s' dada a ação conjunta $\mathbf{a}$;
- $\mathcal{R}(s, \mathbf{a})$: A função de recompensa global e partilhada por todos os membros do enxame;
- Ω e $\mathcal{O}_i$: Representam, respetivamente, o espaço de observações e a função que mapeia o estado global para a perceção local do agente i ;

- $\gamma \in [0, 1)$: O fator de desconto que determina a precedência de recompensas imediatas sobre ganhos a longo prazo.

O objetivo coletivo do enxame é convergir para uma política ótima π^* que maximize o retorno esperado acumulado, formalizado por:

$$J(\pi) = \mathbb{E}_\pi \left[\sum_{t=0}^{\infty} \gamma^t \mathcal{R}_t \right] \quad (4.2)$$

4.4.2. Design da Função de Recompensa

Para guiar a emergência de comportamentos coordenados, seguros e eficientes, a função de recompensa $\mathcal{R}$ foi estruturada de forma multi-objetivo e densa. Esta escolha visa facilitar a convergência em enxames de larga escala, equilibrando os objetivos da missão com restrições físicas:

$$\mathcal{R}(s, \mathbf{a}) = w_1 R_{\text{tarefa}} - w_2 R_{\text{colisão}} - w_3 R_{\text{controle}} \quad (4.3)$$

Onde w_n representam os pesos de importância de cada componente:

- R_{tarefa} : Atribui um valor positivo proporcional ao progresso da missão (ex: percentagem de área coberta ou itens recolhidos);
- $R_{\text{colisão}}$: Aplica uma penalização severa sempre que a distância entre agentes é inferior ao limiar de segurança, garantindo a integridade física do enxame;
- R_{controle} : Penaliza o gasto excessivo de energia ou mudanças bruscas de trajetória, promovendo a suavidade do movimento e a eficiência operacional.

4.4.3. Arquitetura do Modelo (RS2C-GAT)

O diferencial técnico do *framework* RS2C reside na integração de camadas de **Graph Attention Networks (GATs)** na arquitetura da rede neuronal profunda. Esta escolha metodológica aborda diretamente os desafios críticos de escalabilidade, generalização e robustez identificados na revisão da literatura, permitindo que o sistema processe informações relacionais de forma dinâmica.

A arquitetura do modelo foi desenhada com base nos seguintes princípios técnicos:

- **Modelação por Grafos Dinâmicos:** O enxame é formalizado como um grafo $G = (V, E)$, onde o conjunto de vértices V representa os robôs e as arestas E representam as ligações de comunicação ativas dentro do raio crítico r_c . Diferente de redes neurais tradicionais (MLP), esta estrutura permite que a rede processe um número variável de entradas, adaptando-se instantaneamente a mudanças na topologia do enxame.
- **Mecanismo de Atenção e Invariância à Permutação:** Através do uso de mecanismos de *self-attention*, cada agente i calcula coeficientes de atenção e_{ij} para os seus vizinhos $j \in \mathcal{N}_i$. Estes coeficientes permitem que o robô atribua pesos diferenciados à informação recebida (ex: priorizar robôs em rota de colisão iminente face a robôs distantes). Matematicamente, a operação de agregação é

simétrica, o que garante a **invariância à permutação**: a saída da rede é idêntica independentemente da ordem pela qual os dados dos vizinhos são processados. Esta propriedade é a base para o *Zero-Shot Transfer*, permitindo que o controlador treinado com $N = 10$ agentes mantenha a coerência operacional quando escalado para $N = 100$.

- **Treino Robusto via Dropout de Observação:** Para colmatar o *Deployment Gap* discutido por Kegeleirs et al. (2025), o RS2C incorpora uma camada de *dropout* estocástico nas observações locais durante a fase de treino. Este processo simula condições de mundo real, como falhas intermitentes nos sensores ou perda de pacotes de comunicação (*packet loss*). Ao aprender a operar com observações ruidosas ou incompletas $\tilde{o}_i$, a política π_θ desenvolve uma resiliência intrínseca que os controladores otimizados de forma determinística raramente apresentam.
- **Política Partilhada (*Parameter Sharing*):** De forma a otimizar a eficiência do treino e garantir a homogeneidade do enxame, todos os agentes partilham o mesmo vetor de parâmetros θ . Esta abordagem permite que a experiência de aprendizagem de um único agente seja instantaneamente generalizada para todo o coletivo, acelerando a convergência em ambientes de alta dimensionalidade e facilitando a emergência de comportamentos coordenados complexos.

4.5. Algoritmo 2: Otimização Bio-inspirada (Benchmark)

Para representar a classe de algoritmos de otimização estocástica e servir como *baseline* de robustez, será implementado um modelo baseado em **Neuroevolução**, utilizando um Algoritmo Evolutivo (AE). O objetivo desta abordagem é gerar um controlador otimizado *offline* que represente o estado da arte das soluções pré-programadas, permitindo aferir se a complexidade do MARL é justificada por ganhos de performance tangíveis.

4.5.1. Arquitetura do Controlador

Diferente do RS2C, que utiliza arquiteturas baseadas em grafos, o controlador do AE baseia-se num *Multilayer Perceptron* (MLP) clássico. Esta escolha é deliberada para isolar o efeito do paradigma de aprendizagem: enquanto o MARL utiliza a estrutura relacional das GNNs, o AE foca-se na descoberta de pesos ótimos θ_{AE} para uma política reativa fixa. O controlador recebe a observação local o_i e, através de transformações lineares e funções de ativação não-lineares, produz a ação $a_i = \pi(o_i; \theta_{AE})$.

4.5.2. Processo de Otimização

O processo de busca pelos parâmetros ótimos segue os princípios da computação evolutiva, operando num espaço de busca de alta dimensionalidade sem necessidade de gradientes:

- **População e Codificação:** O algoritmo mantém uma população de K indivíduos, onde cada "cromossoma" representa um conjunto de pesos e enviesamentos da rede MLP.

- **Avaliação de *Fitness*:** Cada indivíduo é avaliado no simulador ao longo de múltiplos episódios. A função de *fitness* F é definida de forma análoga à recompensa acumulada do MARL, garantindo a paridade na comparação: $F = \sum (R_{\text{tarefa}} - R_{\text{colisão}})$.
- **Mecanismos de Evolução:** Utiliza-se a seleção por torneio para identificar os controladores mais aptos, seguida de operadores de **cruzamento** (*crossover*) e **mutação**. A mutação é particularmente crítica, pois permite a exploração de novas regiões no espaço de parâmetros, mitigando a convergência prematura para ótimos locais.
- **Convergência:** O ciclo evolutivo repete-se por G gerações até que a *fitness* da população estabilize, resultando no controlador estático ótimo θ_{AE}^* que será submetido ao *benchmarking*.

4.6. Métricas de Avaliação

Para quantificar a superioridade de um paradigma sobre o outro, o desempenho do agente MARL (RS2C) e do agente evolutivo (θ_{AE}^*) será comparado através de três eixos fundamentais, respondendo diretamente aos objetivos específicos desta tese:

- **Performance da Tarefa (P_{task}):** Mede a eficiência absoluta na conclusão da missão (ex: taxa de cobertura ou taxa de recolha). É calculada como a média dos resultados obtidos em 100 simulações independentes com condições iniciais aleatórias.
- **Escalabilidade (S_{scale}):** Avalia a capacidade de *Zero-Shot Transfer*. Mede-se a degradação da performance quando o enxame é expandido para $N \in \{10, 20, 50, 100\}$ agentes, sem que os controladores sofram qualquer processo de ajuste ou retreino.
- **Robustez a Perturbações (R_{robust}):** Quantifica a resiliência do enxame perante condições adversas. O foco reside na capacidade de recuperação do sistema quando 10% dos agentes sofrem falhas críticas e deixam de operar, simulando a perda de redundância física.

4.7. Tratamento Estatístico

Para assegurar que as conclusões desta dissertação possuem validade científica e não são fruto de variabilidade estocástica inerente à simulação, cada cenário experimental será executado 30 vezes ($N_{\text{runs}} = 30$). Este volume de dados permite a aplicação do Teorema do Limite Central para a análise de médias. As diferenças observadas entre o RS2C e o AE serão validadas através de testes de hipótese rigorosos. Será utilizado o teste *t-Student* (ou o teste de *Wilcoxon* em caso de não-normalidade) para comparar as distribuições de performance. Os resultados serão considerados estatisticamente significativos apenas se o valor de p for inferior ao limiar de 0.05 ($p < 0.05$), garantindo um nível de confiança de 95% nas afirmações de superioridade de um algoritmo sobre o seu concorrente.

Conclusões e Trabalhos Futuros

5.1. Conclusões da Proposta

Esta proposta de tese incide sobre um dos desafios mais prementes na robótica contemporânea: a definição de paradigmas de controlo que garantam a operabilidade de enxames em ambientes de alta incerteza. A investigação preliminar aqui apresentada identificou uma lacuna crítica na literatura científica — o isolamento metodológico entre as comunidades de *Multi-Agent Reinforcement Learning* (MARL) e de Otimização Bio-inspirada. Esta fragmentação tem impedido a realização de um **benchmarking rigoroso e imparcial** que determine, de forma quantitativa, em que condições a adaptabilidade da aprendizagem automática compensa a robustez estática dos métodos tradicionais.

Através da análise do Estado da Arte (2020-2025), concluiu-se que, embora as soluções bio-inspiradas (como o PSO) ofereçam alicerces sólidos para tarefas reativas, elas carecem da flexibilidade necessária para lidar com o “Deployment Gap” identificado por Kegeleirs et al. (2025). Por outro lado, o MARL, especialmente quando potenciado por *Graph Neural Networks* (GNNs) e arquiteturas CTDE, emerge como o paradigma com maior potencial para garantir a escalabilidade e a resiliência do enxame perante falhas catastróficas.

A metodologia proposta neste documento visa preencher esta lacuna através do desenvolvimento de um simulador de alta-fidelidade e da implementação do *framework* RS2C, assegurando que a comparação entre paradigmas seja validada por testes de *stress* dinâmico e tratamento estatístico rigoroso.

5.2. Contributos Esperados

Com a execução deste plano de investigação, preveem-se os seguintes contributos para o avanço do conhecimento na área de Sistemas Multiagente e Robótica de Enxame:

- **Framework de Benchmarking Quantitativo:** A disponibilização de uma metodologia de teste padronizada que permita comparar algoritmos de naturezas distintas (aprendizagem vs. otimização) sob as mesmas métricas de performance, escalabilidade e robustez.
- **Validação da Adaptabilidade Zero-Shot:** A demonstração empírica de como arquiteturas baseadas em grafos permitem que políticas aprendidas via MARL escalem de $N = 10$ para $N = 100$ agentes sem degradação crítica de performance, respondendo aos desafios de escalabilidade propostos por Sun et al. (2024).
- **Identificação do Ponto de Inflexão Tecnológica:** O fornecimento de dados que permitam a investigadores e engenheiros determinar o limiar de complexidade

ambiental a partir do qual o investimento computacional no treino de modelos MARL se traduz numa vantagem operacional real face às heurísticas evolutivas.

- **Implementação de Referência:** A criação de um repositório de código contendo o simulador e as implementações dos algoritmos (RS2C e AE/PSO), servindo de base para futuros estudos de hibridização no ISCTE.

5.3. Trabalhos Futuros (Roadmap)

O plano de trabalhos para a conclusão desta dissertação está organizado em quatro fases principais, garantindo que o rigor científico é mantido em cada etapa do desenvolvimento:

- (1) **Fase 1: Consolidação do Ambiente (Mês 1-2):** Finalização do simulador em Python, incluindo a modelação física detalhada, a definição dos raios de comunicação (r_c) e a implementação dos cenários de Vigilância e *Foraging*.
- (2) **Fase 2: Implementação e Treino (Mês 3-5):** Desenvolvimento do *pipeline* RS2C (incluindo as camadas GAT e CTDE) e otimização dos controladores evolutivos de referência (θ_{AE}^*). Esta fase foca-se na convergência e estabilidade dos modelos.
- (3) **Fase 3: Benchmarking e Stress Tests (Mês 6-7):** Execução das 30 baterias de testes para cada cenário, variando o número de agentes e introduzindo perturbações dinâmicas (falhas de agentes e obstáculos).
- (4) **Fase 4: Análise Estatística e Redação Final (Mês 8-9):** Aplicação de testes de hipótese ($p < 0.05$) aos dados recolhidos, discussão dos resultados à luz da literatura e redação final da dissertação para defesa pública.

Referências

- [1] B. Riviere et al., «Deep Reinforcement Learning for Swarm Systems,» *Journal of Machine Learning Research*, vol. 20, n.º 240, 2020.
- [2] M. Dorigo, «Optimization, Learning and Natural Algorithms,» tese de doutoramento, Politecnico di Milano, 1992.
- [3] J. Kennedy e R. Eberhart, «Particle swarm optimization,» em *Proceedings of ICNN'95 - International Conference on Neural Networks*, IEEE, vol. 4, 1995, pp. 1942–1948.
- [4] Y. Lin, R. Zhao e H. Gong, «A Survey on UAV Control with Multi-Agent Reinforcement Learning,» *Drones*, vol. 9, n.º 7, p. 484, 2025.
- [5] J. He et al., «Towards Self-Adaptive Resilient Swarms Using Multi-Agent Reinforcement Learning,» *SciTePress*, 2024.
- [6] A. Y. Majid e F. Van Diggelen, «Deep Reinforcement Learning Versus Evolution Strategies: A Comparative Survey,» *IEEE Transactions on Neural Networks and Learning Systems*, 2023.
- [7] T. Hassen e S. Amin, «Dynamic Window Approach for Mobile Robot Path Planning based on Hybrid Swarm Algorithms,» *Journal of Information Hiding and Multimedia Signal Processing*, vol. 16, n.º 2, 2025.
- [8] Y. Wang et al., «A Comparative Study of Reinforcement Learning and Particle Swarm Optimization for Multi-Robot Obstacle Avoidance,» *Sensors*, vol. 22, n.º 3, 2022.
- [9] A. Gupta et al., «A Review on Influx of Bio-Inspired Algorithms: Critique and Improvement Needs,» *arXiv preprint arXiv:2506.04238*, 2025.
- [10] R. S. Sutton e A. G. Barto, *Reinforcement Learning: An Introduction*, 2ª ed. MIT Press, 2018.
- [11] D. Huh e P. Mohapatra, «Multi-agent Reinforcement Learning: A Comprehensive Survey,» *arXiv preprint arXiv:2312.10256*, 2023.
- [12] A. Iskandar et al., «Swarm Robotics Navigation Task: A Comparative Study of Reinforcement Learning and Particle Swarm Optimization,» *ResearchGate Publication 383857358*, 2024.
- [13] M. Bettini, A. Prorok e V. Moens, «BenchMARL: Benchmarking Multi-Agent Reinforcement Learning,» *Journal of Machine Learning Research*, vol. 25, n.º 161, 2024.
- [14] S. Li et al., «RACE: Improve Multi-Agent Reinforcement Learning with Representation Asymmetry and Collaborative Evolution,» em *Proceedings of ICML*, 2023.
- [15] A. Kegeleirs et al., «Towards applied swarm robotics: current limitations and enablers,» *Frontiers in Robotics and AI*, vol. 12, 2025.

- [16] Y. Sun et al., «Decentralized Learning Strategies for Estimation Error Minimization with Graph Neural Networks,» *arXiv preprint arXiv:2404.03227*, 2024.
- [17] T. Schmickl et al., «Scaling Swarm Coordination with GNNs—How Far Can We Go?» *MDPI Robotics*, vol. 6, n.^o 11, 2025.
- [18] D. Heimann et al., «Runtime Verification-Based Safe MARL for Optimized Safety Policy Generation,» *MDPI Big Data and Cognitive Computing*, vol. 8, n.^o 5, 2024.
- [19] L. Zheng et al., «LNS2+RL: A Hybrid Approach for Multi-Agent Path Finding,» *arXiv preprint arXiv:2405.17794*, 2025.
- [20] W. Xiao, L. Yuan, T. Ran, L. He, J. Zhang e J. Cui, «CSPER: Curiosity-driven Safety-Prioritized Experience Replay for Mapless Navigation using Deep Reinforcement Learning,» *IEEE Transactions on Cognitive and Developmental Systems*, 2026.
- [21] L. Roveda, «Hybrid Reinforcement Learning and Evolutionary Algorithms for Adaptive Robotic Manipulation,» *Robotics and Computer-Integrated Manufacturing*, 2026.
- [22] J. Elrod et al., «Graph Based Deep Reinforcement Learning Aided by Transformers for Multi-Agent Cooperation,» *arXiv preprint arXiv:2504.08195*, 2025.
- [23] H. Liu et al., «Bio-Inspired Fission–Fusion Control and Planning via Reinforcement Learning,» *MDPI Applied Sciences*, vol. 14, n.^o 3, 2024.